Évaluation – Concepts et usages des IA génératives

Durée : 1h30

Partie A – Compréhension des concepts fondamentaux (6 points)

Q1 – Génération autorégressive (1 point)

Expliquez brièvement ce que signifie la génération autorégressive dans les grands modèles de langage (LLM).

Q2 – Composants essentiels des LLM (1,5 point)

Associez chaque composant d'un LLM à son rôle principal :

(a) Tokenisation

(b) Embedding

(c) Attention

1. Calculer un vecteur caractéristique pour chaque jeton en tenant compte du contexte de la phrase dans laquelle il apparaît
2. Transformer un jeton (un entier) en une représentation vectorielle continue, dépendant uniquement du jeton et indépendante du contexte
3. Découper un texte en groupes de caractères et associer un jeton (entier) à chaque groupe afin de permettre au modèle de traiter le texte

Q3 – Comportement des LLM après l'entraînement initial (1,5 point)

Lors de l'entraînement initial, un LLM est entraîné à prédire le mot (ou jeton) suivant à partir d'un grand ensemble de textes, en maximisant la probabilité du prochain jeton correct. En vous appuyant sur cette description, décrivez le comportement d'un LLM après cet entraînement initial.

Q4 – Du moteur de saisie automatique à l'assistant (2 points)

Expliquez le processus qui permet de transformer un LLM entraîné initialement comme moteur de saisie automatique en un assistant capable de suivre des instructions et d'aider un utilisateur.

Partie B – Raisonnement et analyse (6 points)

Q5 – Stratégies de génération (2 points)

On considère les stratégies suivantes pour choisir le prochain mot :

- greedy sampling (échantillonnage glouton)
- beam search (recherche en faisceau)
- top-k sampling

Expliquez :

- laquelle est la plus déterministe
- laquelle favorise la diversité
- un avantage et un inconvénient de l'une de ces stratégies

Q6 – Chaîne de pensée (Chain-of-Thought) (2 points)

La chaîne de pensée (Chain-of-Thought) consiste à demander à un LLM de produire une suite de raisonnements intermédiaires avant de générer la réponse finale.

- Quel est l'avantage de demander au LLM de générer une chaîne de pensée avant la réponse finale ?
- À partir d'un LLM assistant déjà entraîné pour tenir une conversation avec un utilisateur, décrivez brièvement comment on peut l'entraîner à générer des chaînes de pensée.

Q7 – Hallucinations et apprentissage par renforcement (2 points)

1. Donnez une définition de l'hallucination dans le contexte des LLM.
2. Expliquez pourquoi l'apprentissage par renforcement à partir de retours humains (RLHF), utilisé pour transformer les LLM de moteurs de saisie automatique en assistants, peut augmenter la fréquence des hallucinations.

Partie C – Usages et études de cas (8 points)

Q8 – RAG et réduction des hallucinations (2 points)

On souhaite créer un assistant capable de répondre à des questions sur une documentation interne récente, absente des données d'entraînement du modèle.

1. Pourquoi un LLM seul est-il insuffisant ?
2. Expliquez le principe du RAG (Retrieval-Augmented Generation).
3. En quoi le RAG permet-il de réduire les hallucinations ?

Q9 – Agent IA et approche ReAct (2 points)

Un agent IA basé sur un LLM ne se contente pas de produire du texte : il peut également agir dans un environnement (par exemple en appelant des outils ou en exécutant du code). Pour cela, les outils disponibles sont décrits explicitement à l'agent (leur rôle et la manière de les appeler), afin qu'il puisse comprendre quelles actions sont possibles et comment les utiliser. L'approche ReAct (Reasoning + Acting) organise cette interaction entre le raisonnement du LLM et les actions dans l'environnement.

1. Décrivez les quatre étapes principales du cycle ReAct.
2. Expliquez pourquoi ce cycle ReAct permet d'éviter d'entraîner un modèle différent pour chaque tâche.

Q10 – Model Context Protocol (2 points)

Quel est l'intérêt du Model Context Protocol (MCP) pour :

1. la découverte des outils
2. la robustesse de l'interaction entre un agent IA et son environnement

Q11 – Enjeux de l'IA (2 points)

Quels sont les impacts environnementaux de l'IA générative ?