Concepts et usages des IA génératives

Minh-Quan Dao

La naissance du domaine de l'IA

Le terme « intelligence artificielle » a été inventé lors de la conférence de Dartmouth en 1956.

Cette conférence se déroulera en partant du principe que chaque aspect de l'apprentissage ou toute autre caractéristique de l'intelligence peut en principe être décrit avec une telle précision qu'il est possible de créer une machine capable de le simuler.

Objectif : créer une machine capable de simuler l'intelligence

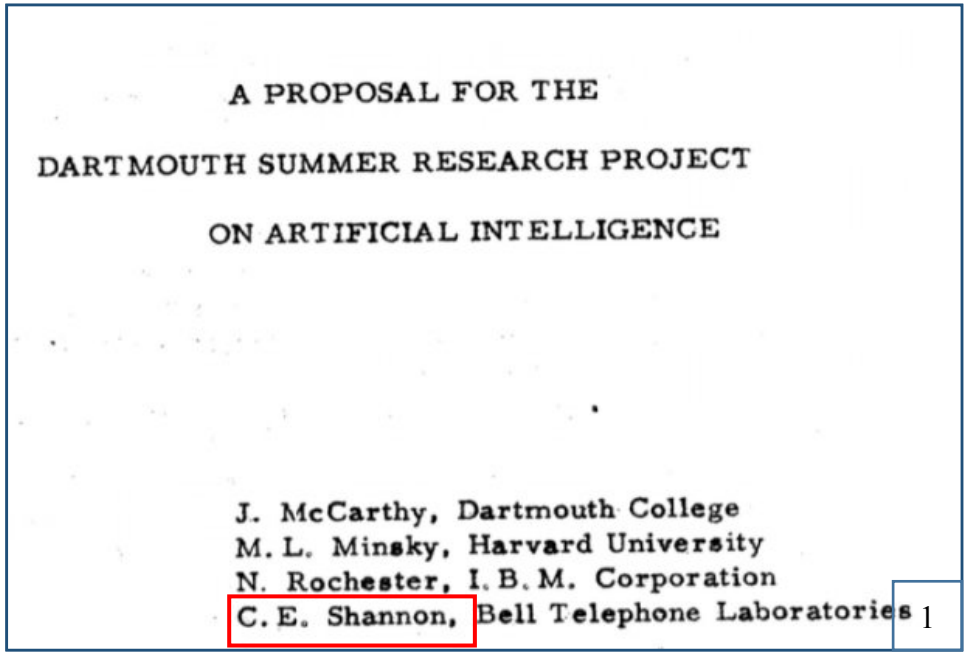
A PROPOSAL FOR THE

DARTMOUTH SUMMER RESEARCH PROJECT

ON ARTIFICIAL INTELLIGENCE

J. McCarthy, Dartmouth College
M. L. Minsky, Harvard University
N. Rochester, I. B. M. Corporation
C. E. Shannon, Bell Telephone Laboratories 1

1. https://home.dartmouth.edu/about/artificial-intelligence-ai-coined-dartmouth

IA symbolique (1956 - 1989)

l'IA symbolique := des règles écrites à la main.

1

Champion du monde
de 1985 à 2000

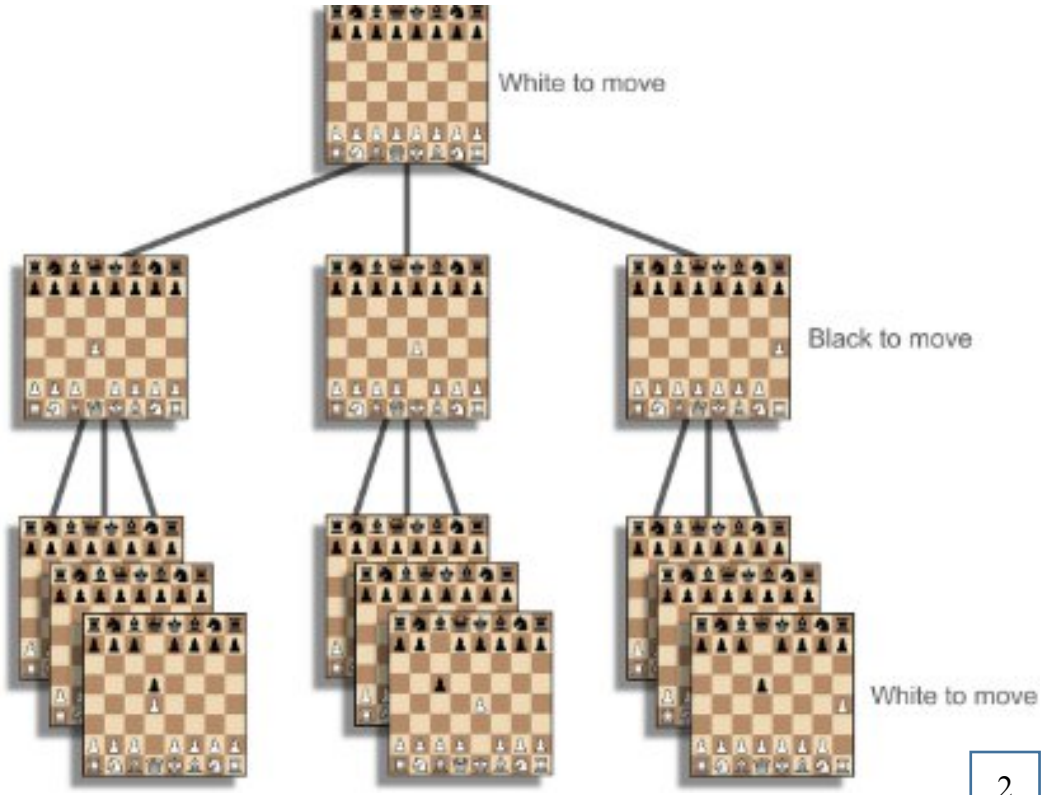

2

Machine à jouer aux échecs Deep Blue
(1989)

1. https://www.ibm.com/content/dam/connectedassets-adobe-cms/worldwide-content/arc/cf/ul/g/02/03/1997_deep-blue_rematch_323.component.crop-16by9-xl.ts=1702922125290.jpg/content/adobe-cms/us/en/history/deep-blue/jcr:content/root/table_of_contents/body/content_section_styled/content-section-body/tabs_container/tabs-item/item_1691073209282
2. https://www.chess.com/blog/Rinckens/how-does-the-deep-blue-algorithm-work

Réseau de neurones artificiels (fin des années 1950)

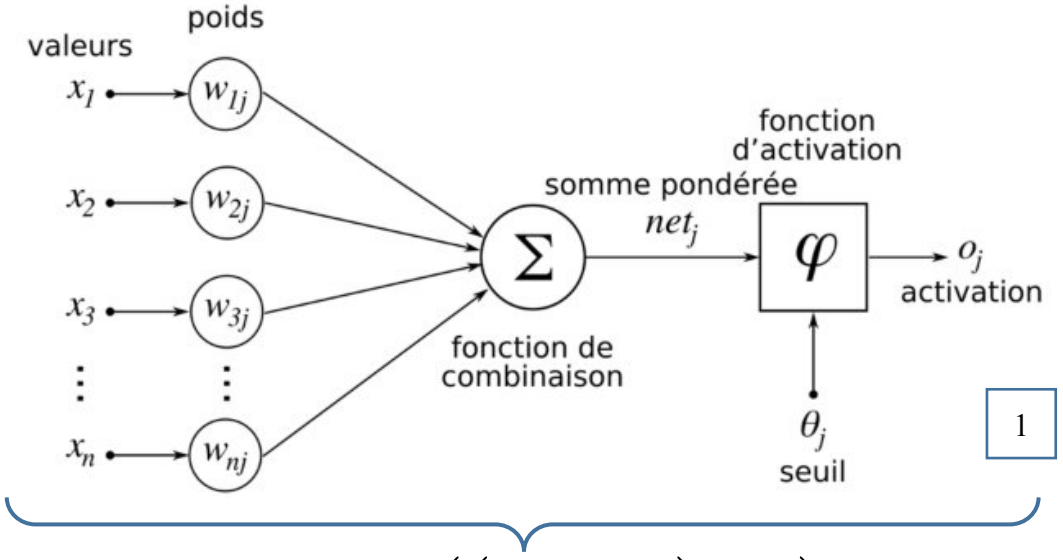

$$o = \varphi\left(\left(\sum_i w_i \cdot x_i\right) + \theta\right)$$

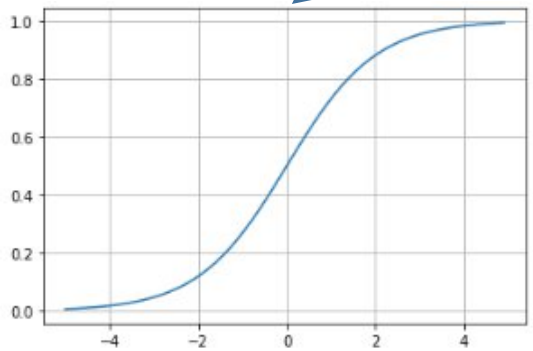

Paramètres à ajuster pour n'importe quelle fonction

$$x = [x_1 , x_2]$$

$$w_1 = 1, w_2 = 1$$

$$\theta = -1.5$$

$$\varphi(y) = \text{int}(y > 0)$$

x_1	x_2	$\left(\sum_i w_i \cdot x_i\right) + \theta$	o	AND
0	0	-1.5	0	0
0	1	-0.5	0	0
1	0	-0.5	0	0
1	1	0.5	1	1

1. https://commons.wikimedia.org/wiki/File:ArtificialNeuronModel_francais.png?uselang=fr

Le moteur de l'IA moderne : rétropropagation (1970)

Que représente cette image ?

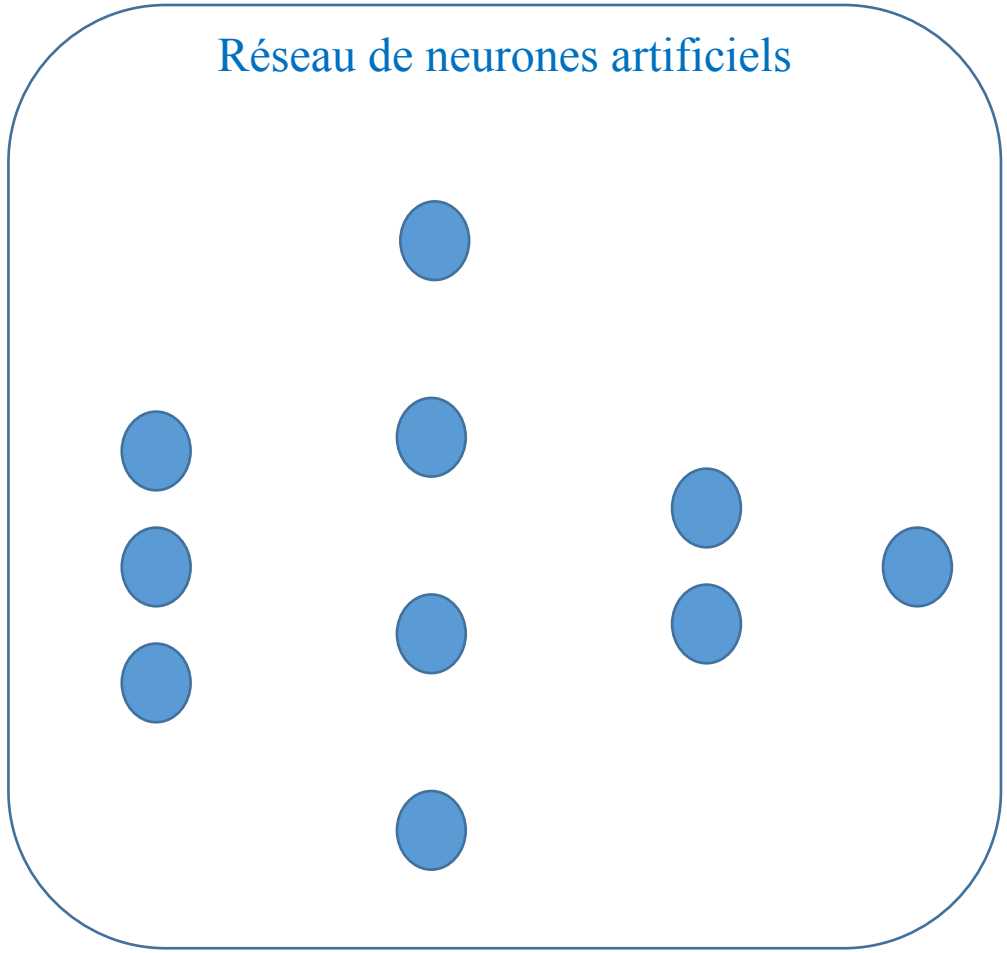

Le moteur de l'IA moderne : rétropropagation (1970)

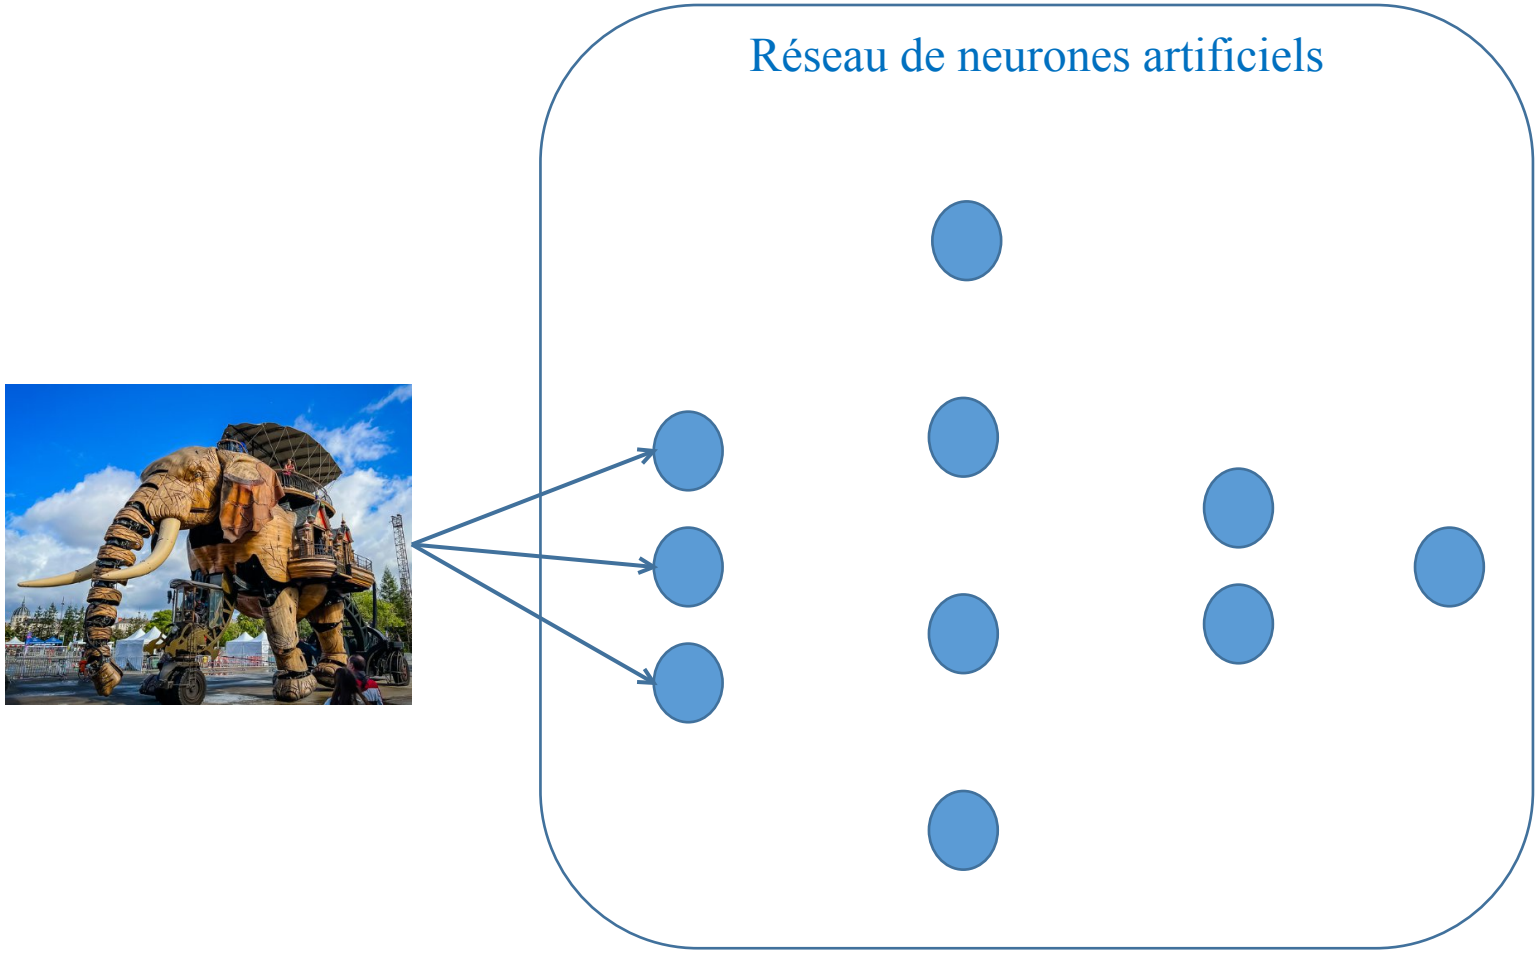

Le moteur de l'IA moderne : rétropropagation (1970)

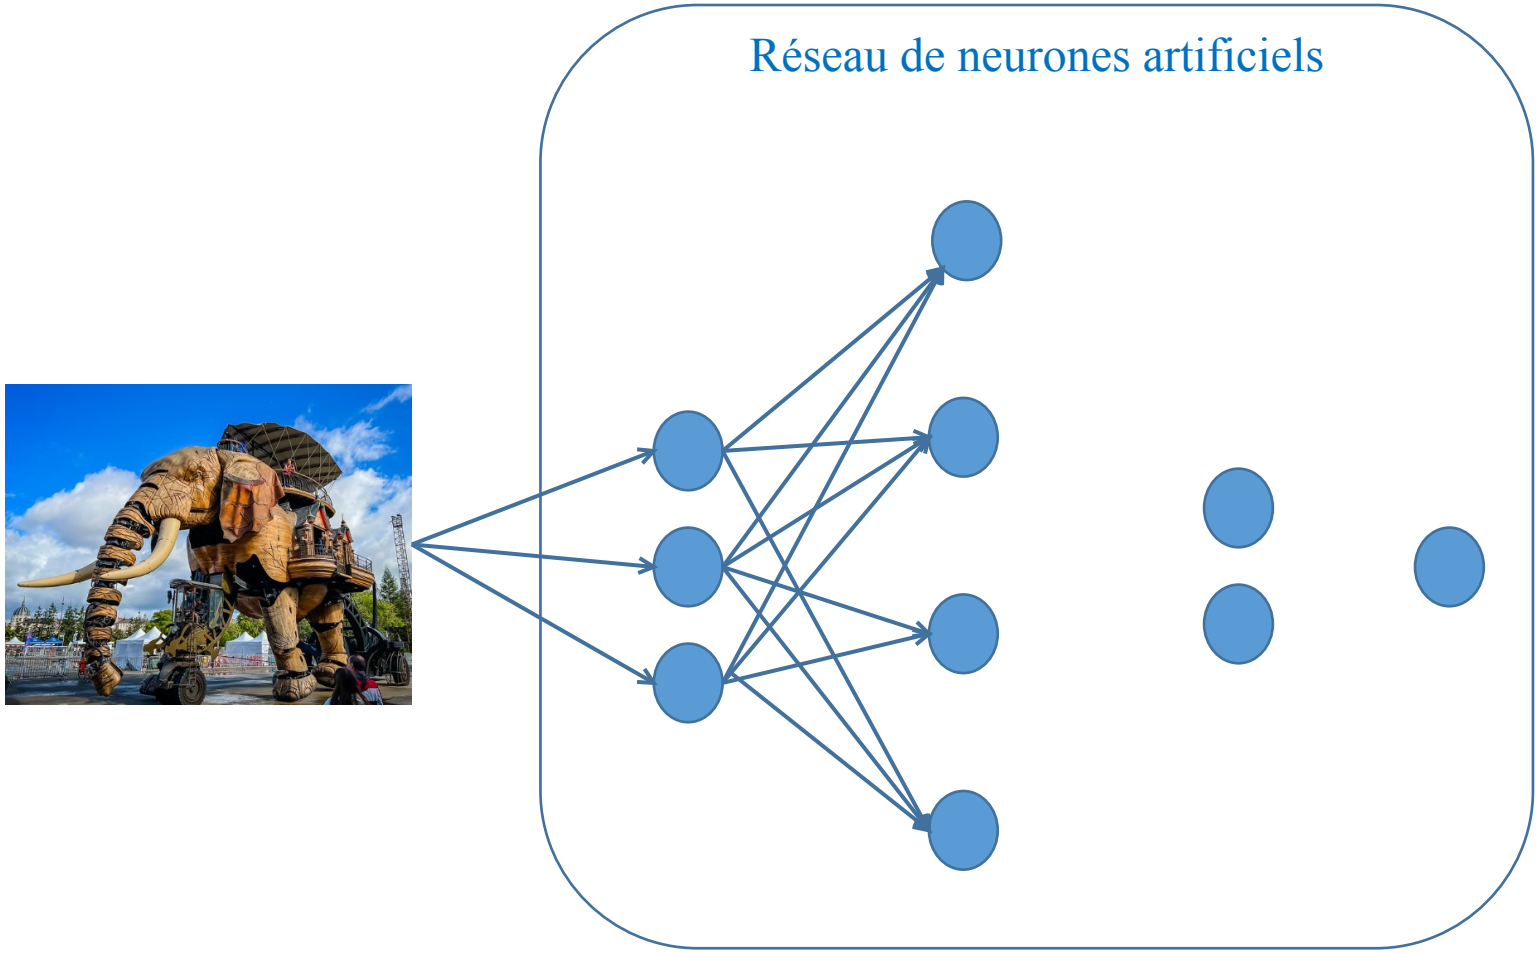

Le moteur de l'IA moderne : rétropropagation (1970)

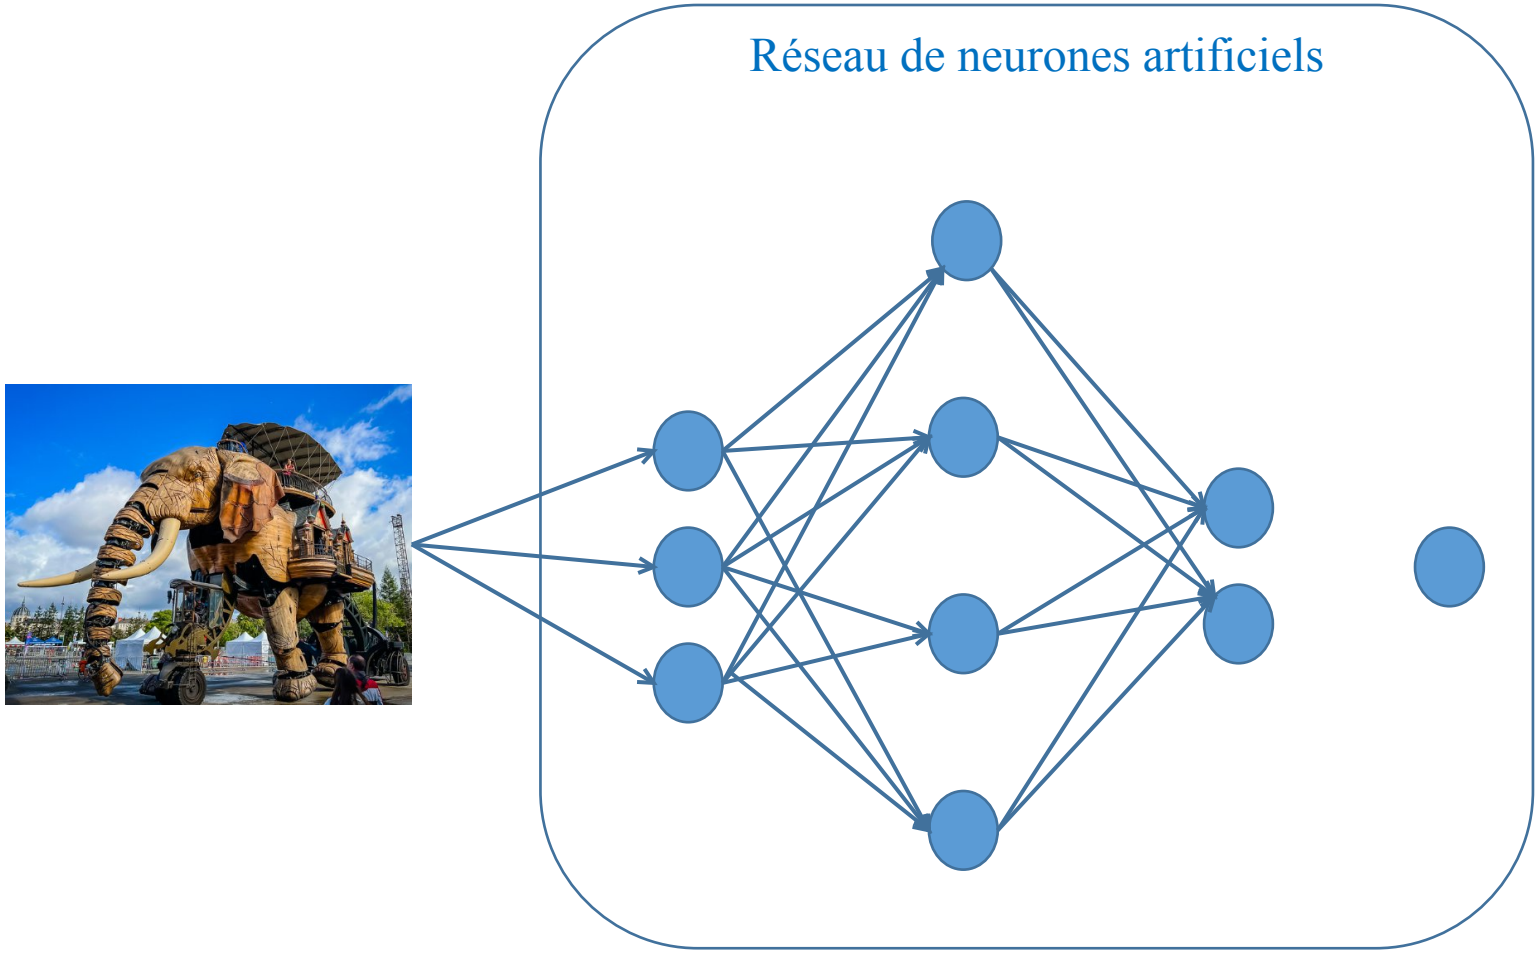

Le moteur de l'IA moderne : rétropropagation (1970)

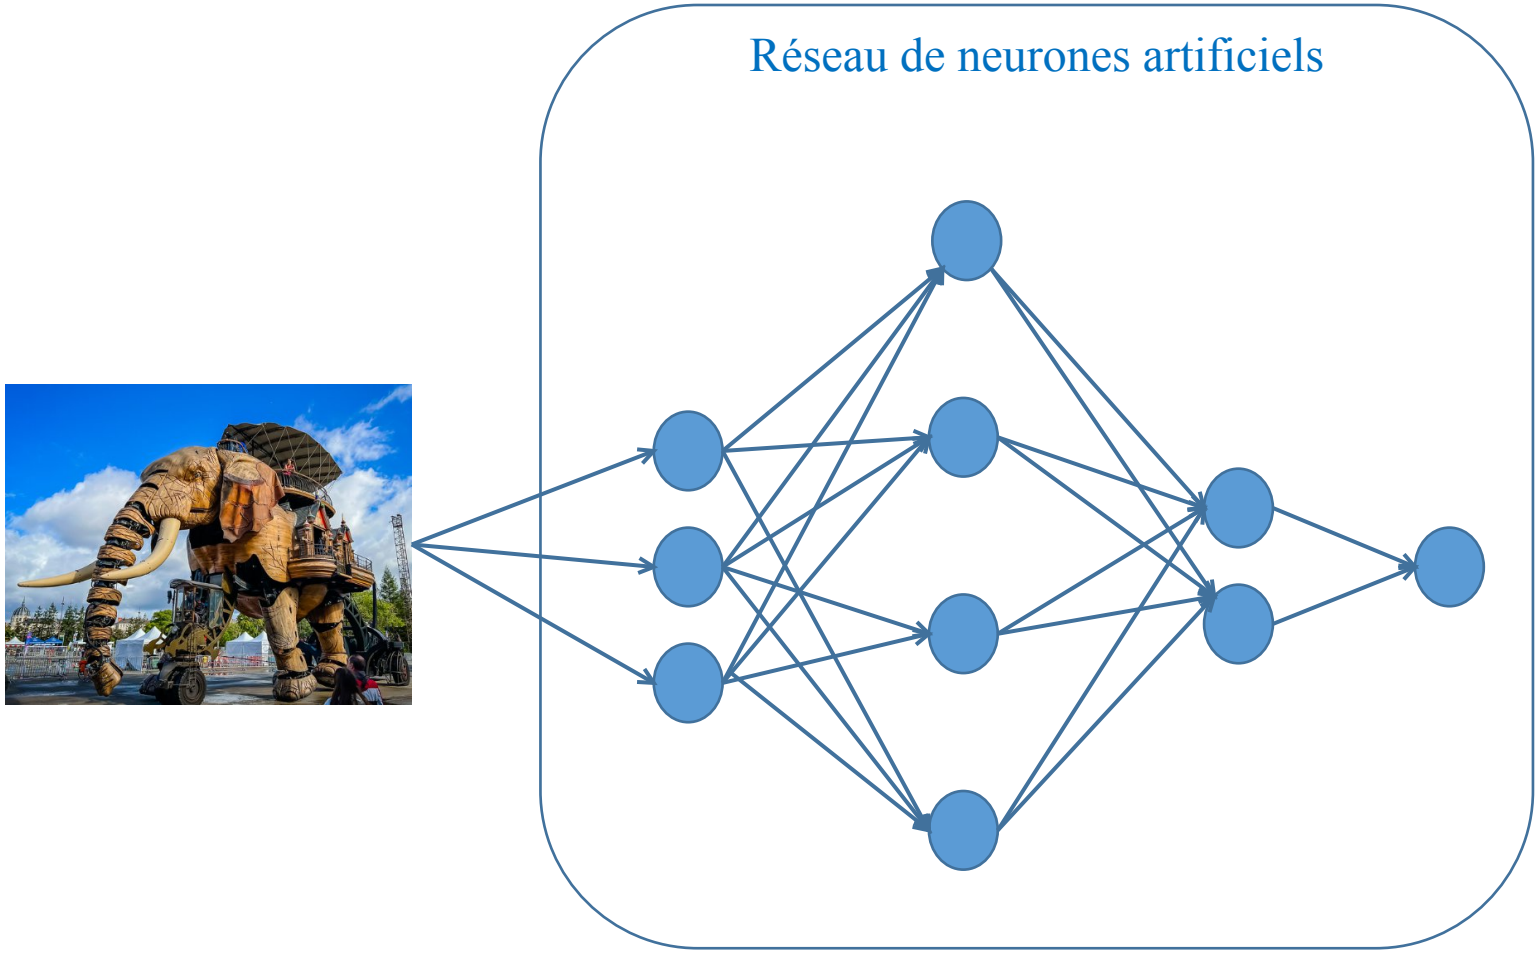

Le moteur de l'IA moderne : rétropropagation (1970)

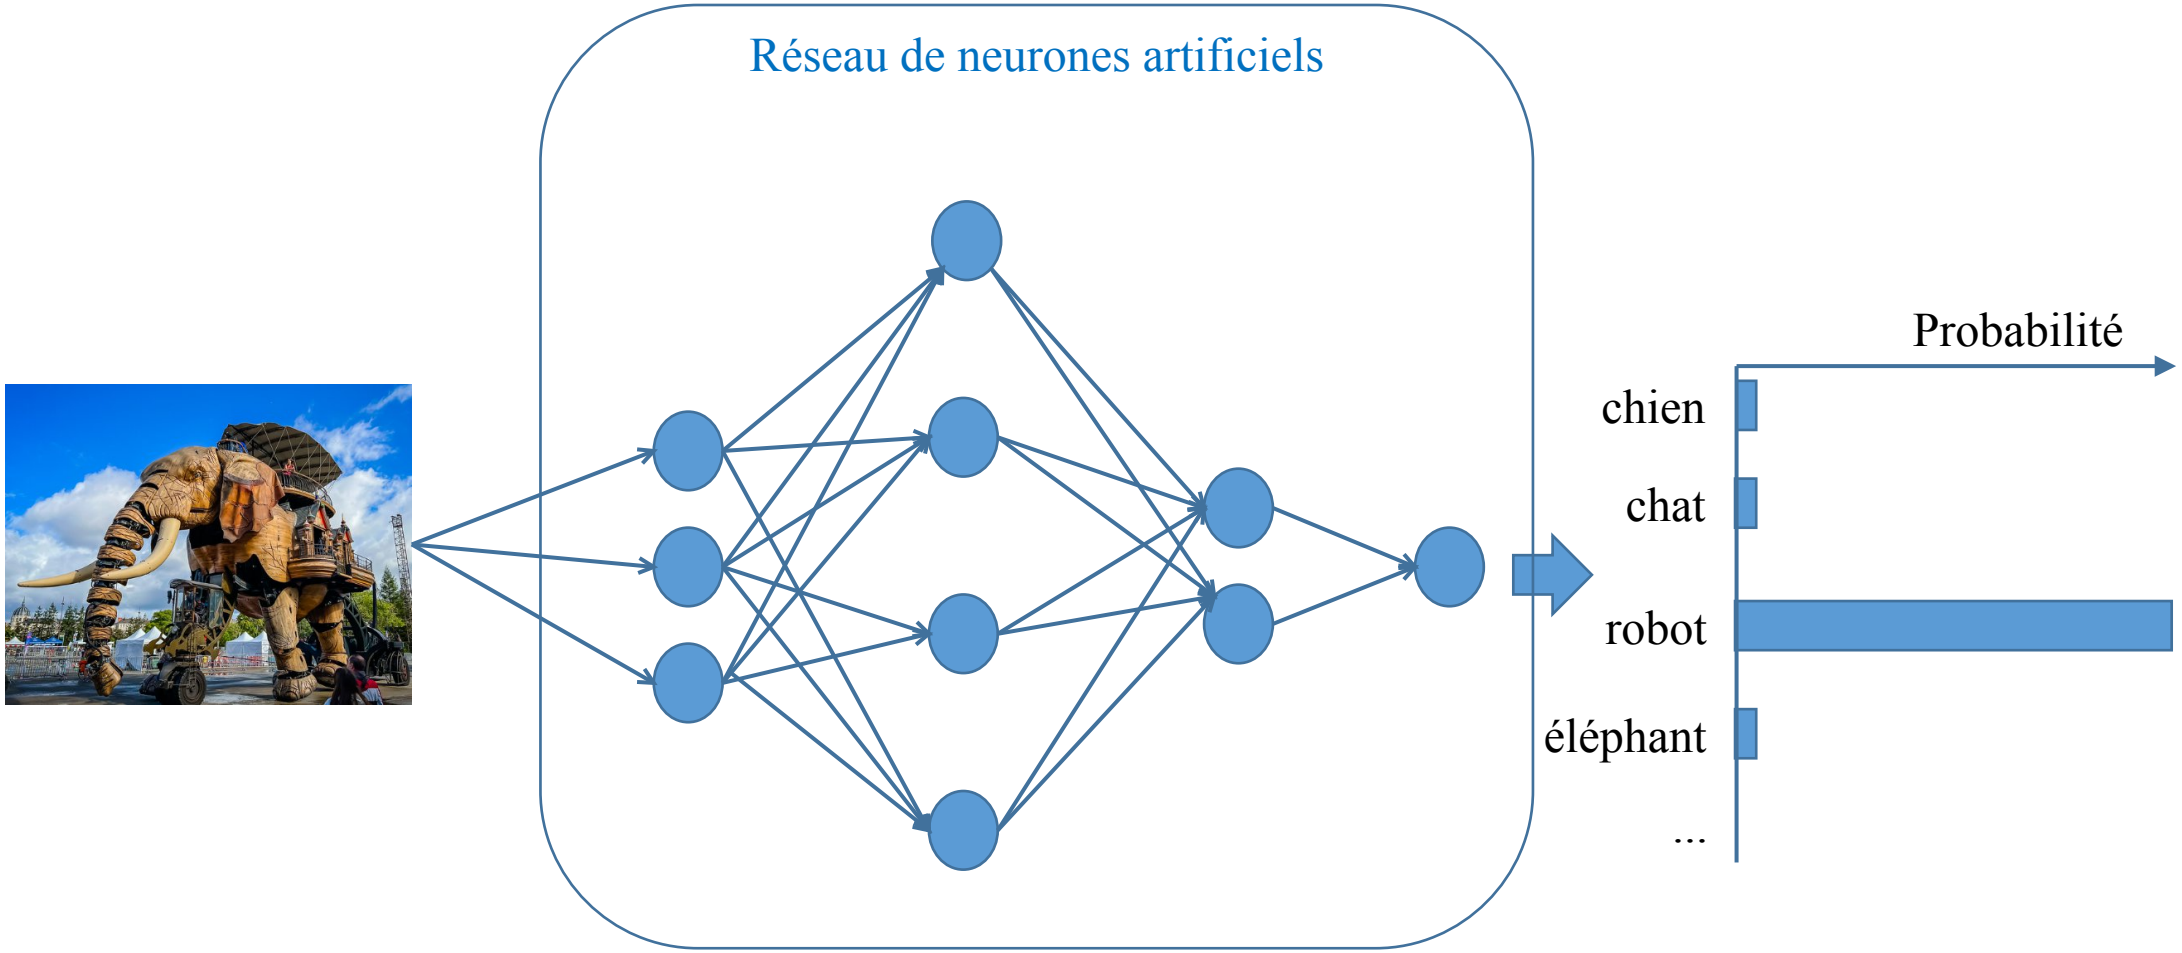

Le moteur de l'IA moderne : rétropropagation (1970)

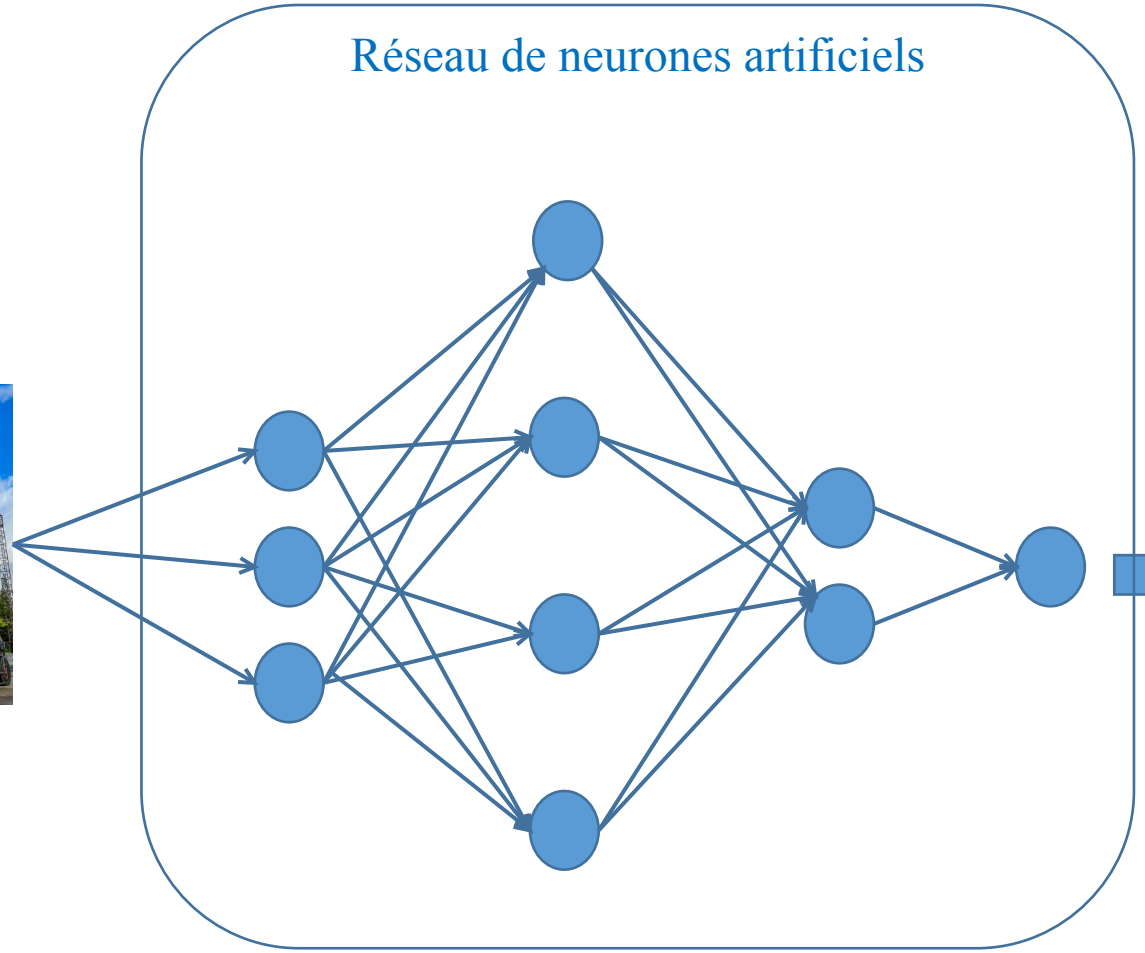

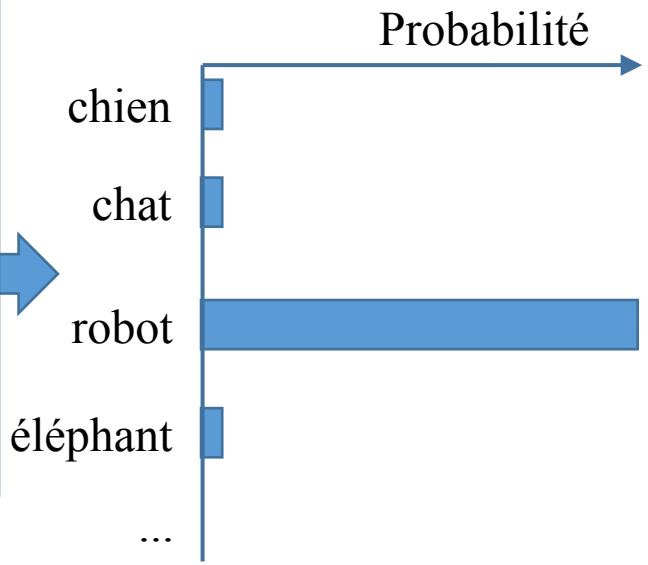

Le moteur de l'IA moderne : rétropropagation (1970)

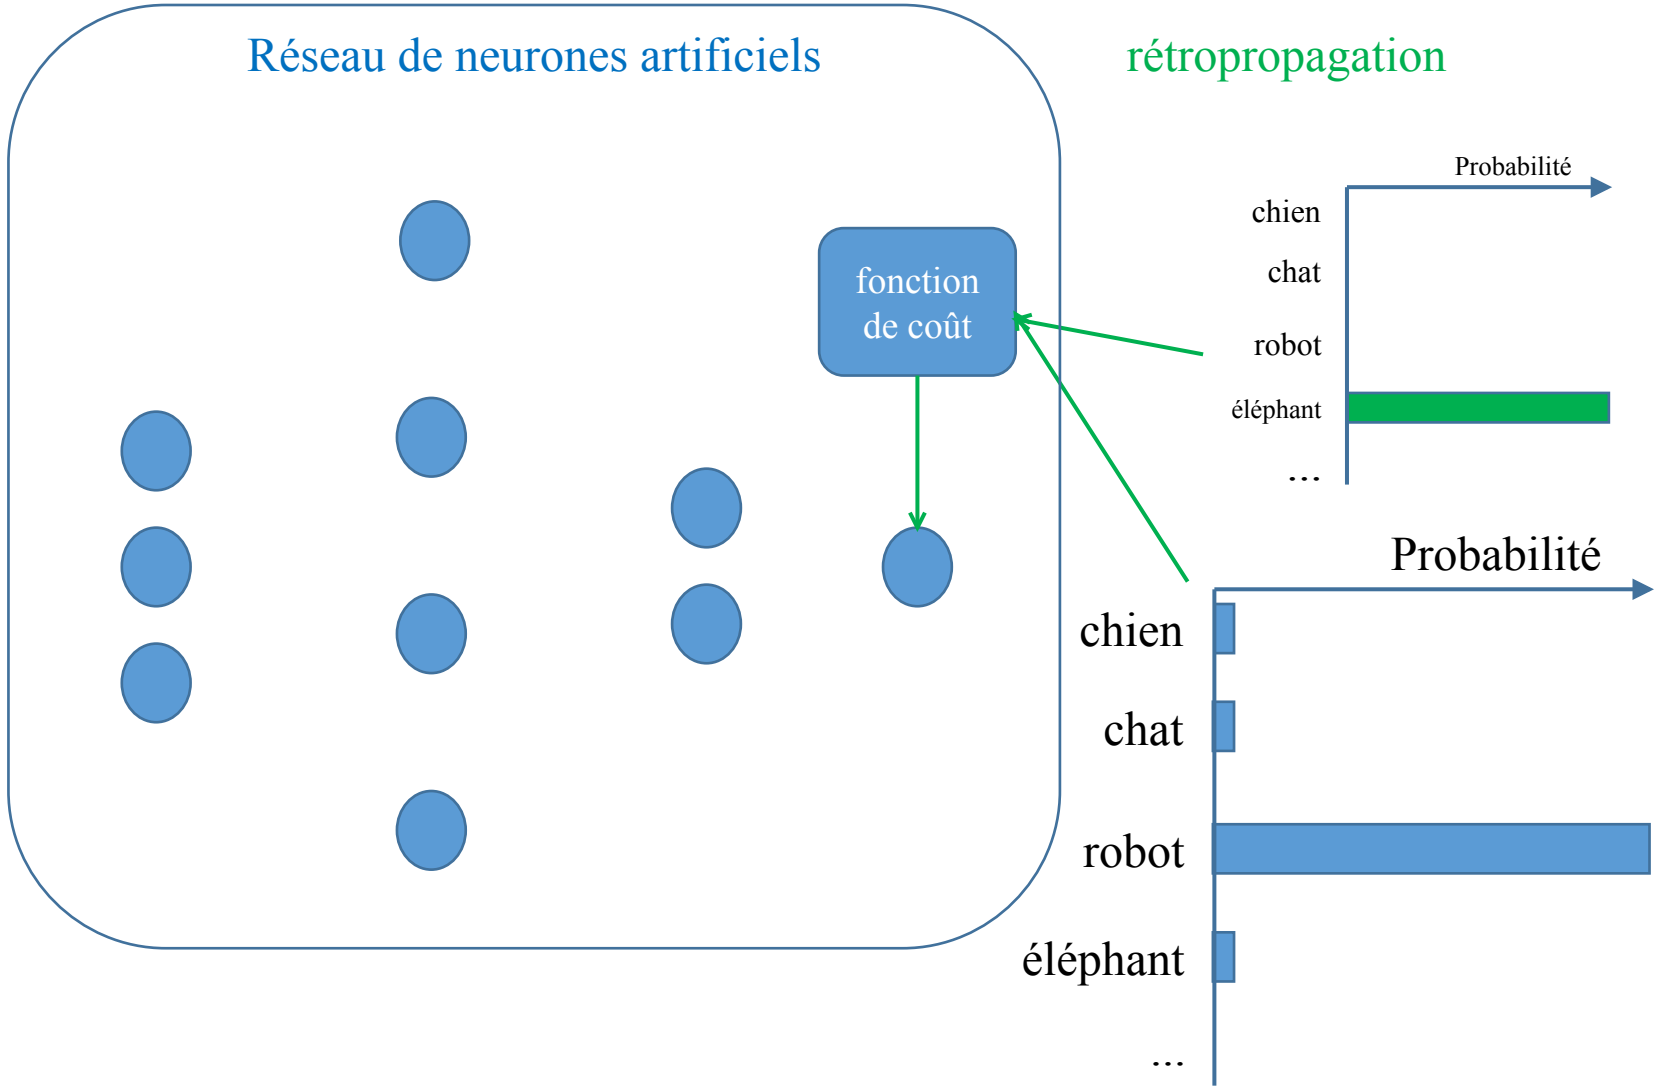

Le moteur de l'IA moderne : rétropropagation (1970)

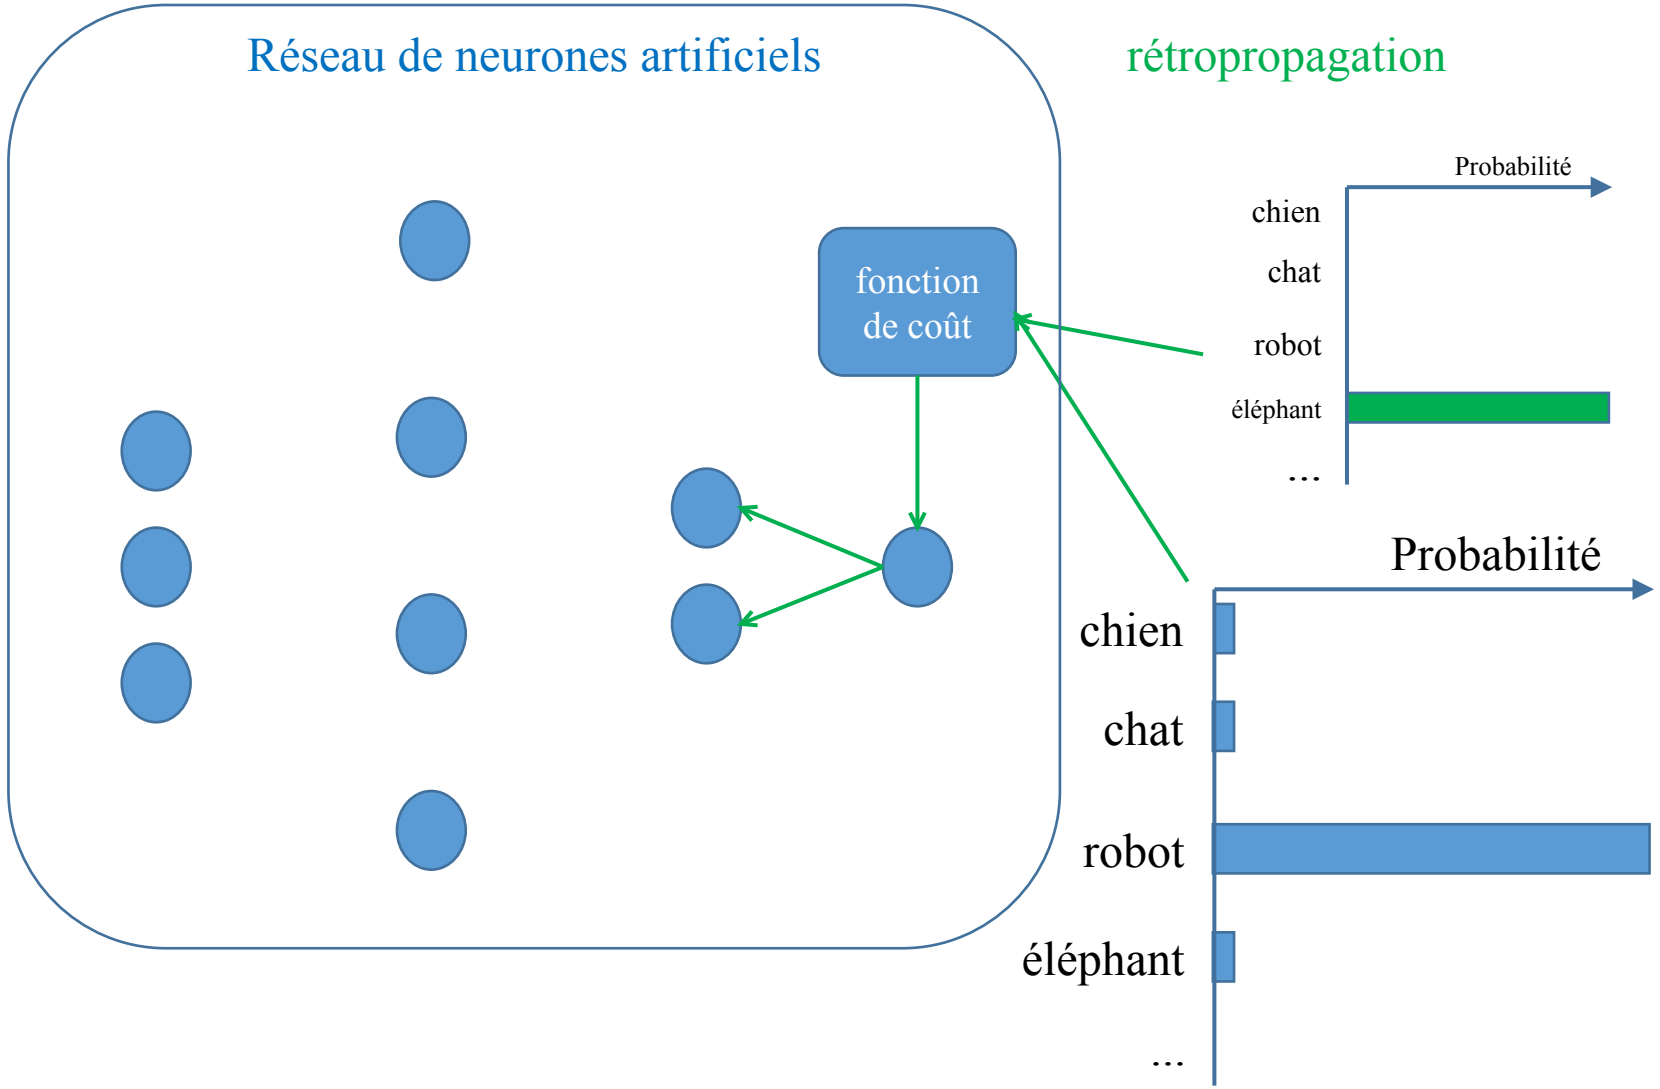

Le moteur de l'IA moderne : rétropropagation (1970)

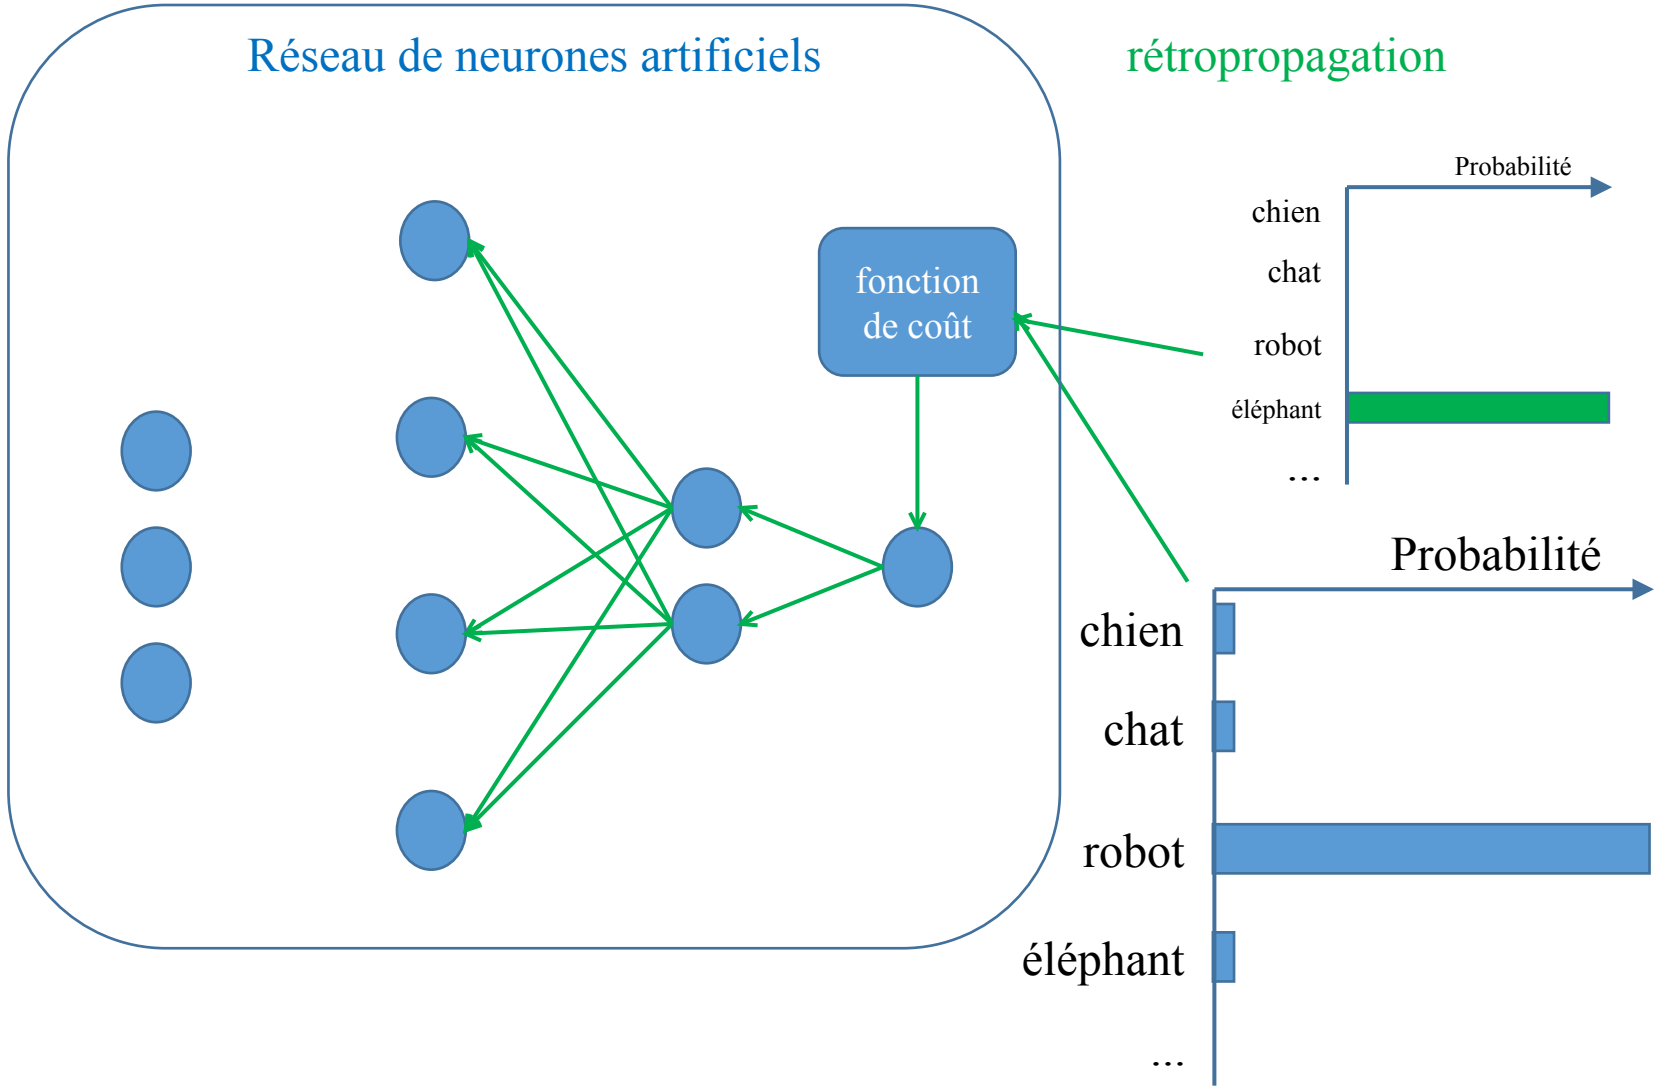

Le moteur de l'IA moderne : rétropropagation (1970)

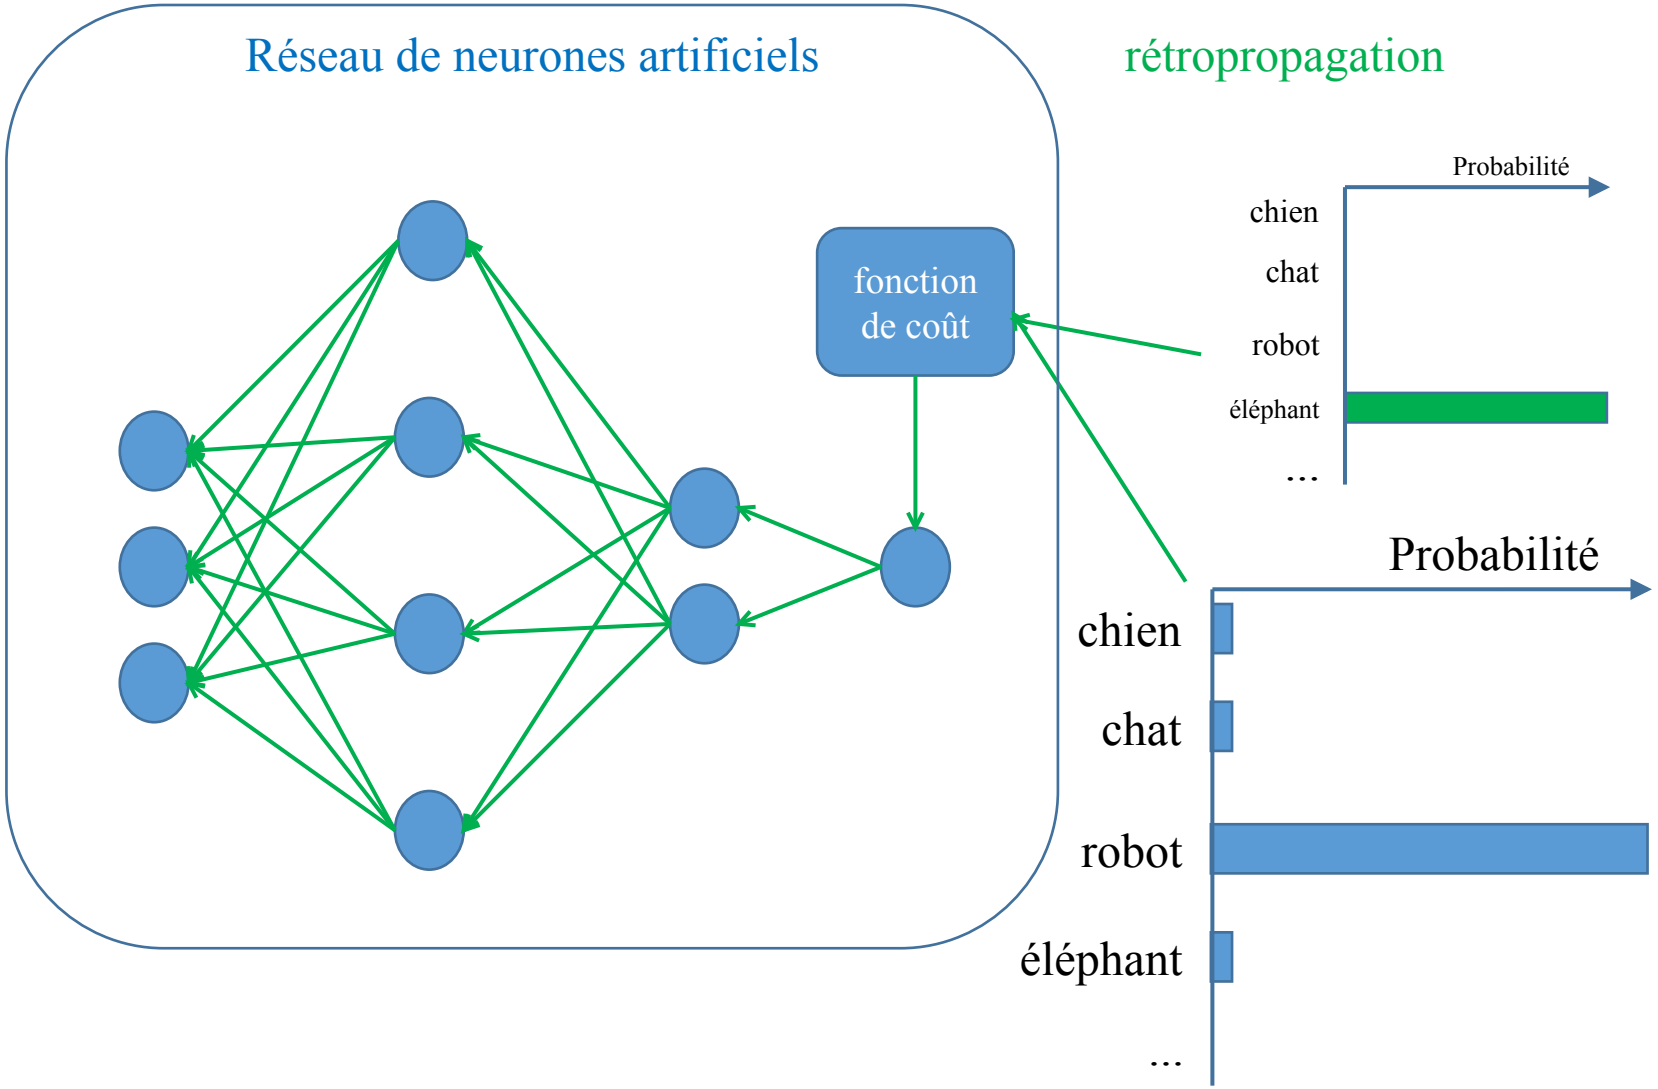

Le moteur de l'IA moderne : rétropropagation (1970)

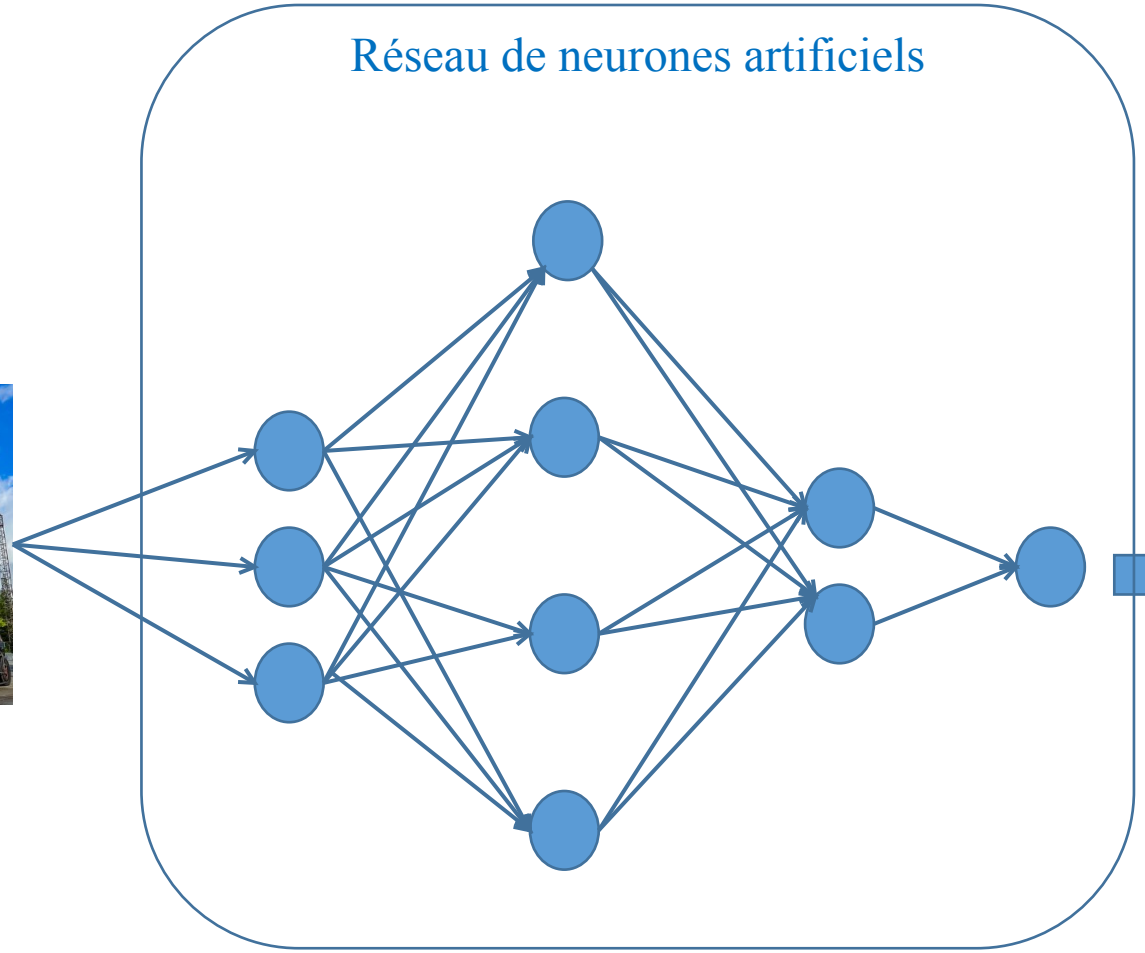

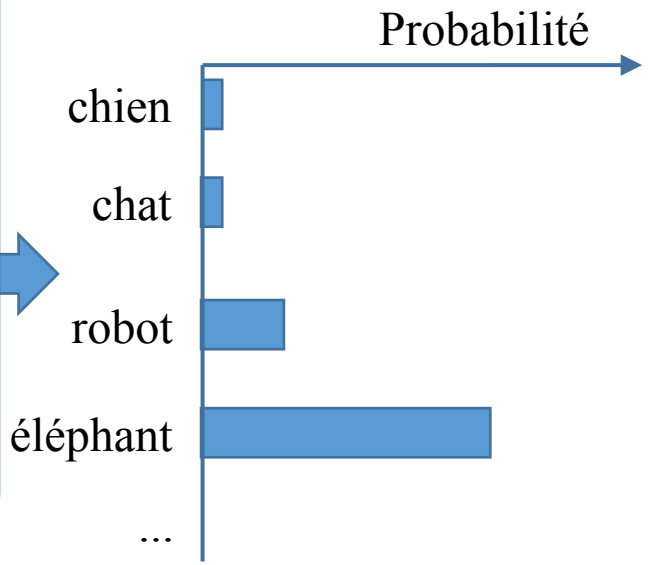

LeNet – un réseau capable de lire des chiffres manuscrits

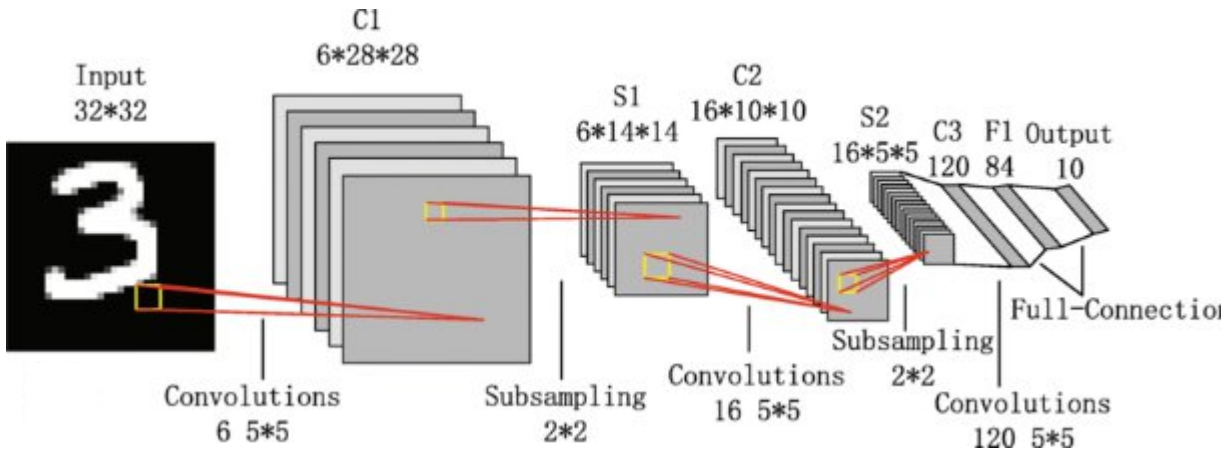

LeNet
(1989)

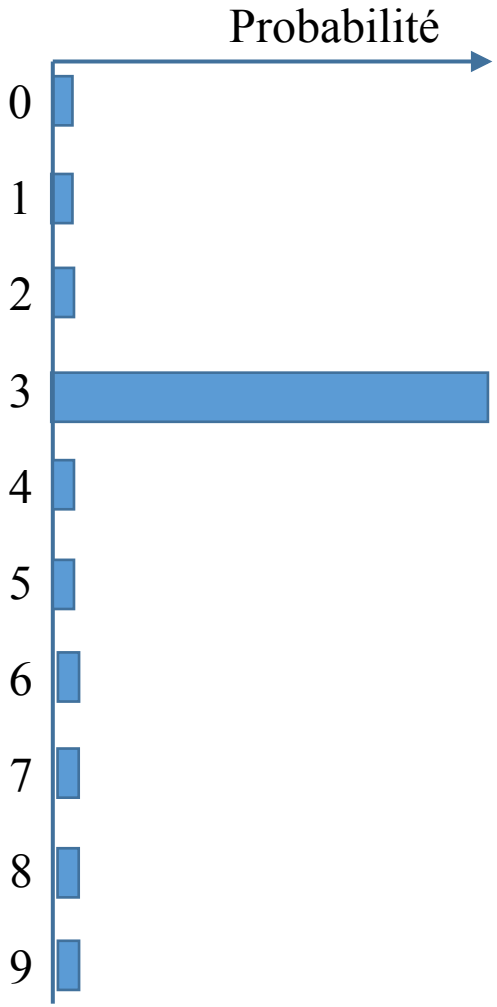

https://www.researchgate.net/publication/344437148/figure/fig1/AS:941673832013832@1601523945349/Overall-architecture-of-LeNet-5-The-dimensions-of-data-follow-the-format-number-of.png

AlexNet – le premier réseau qui surpasse les humains

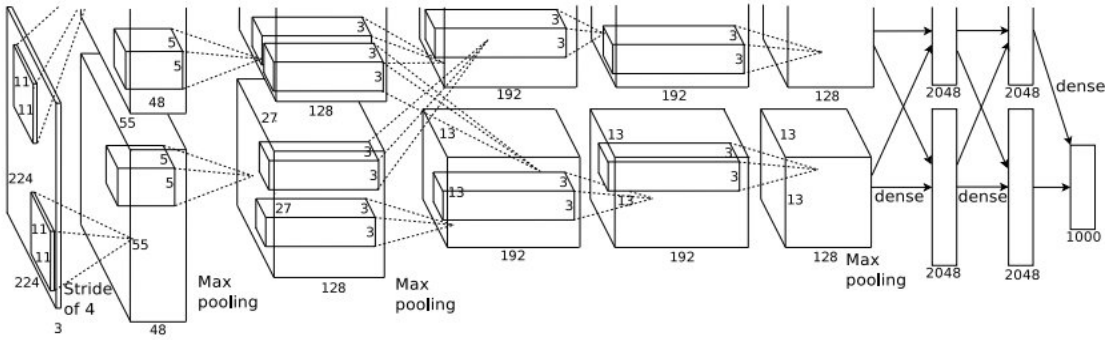

AlexNet
(2012)

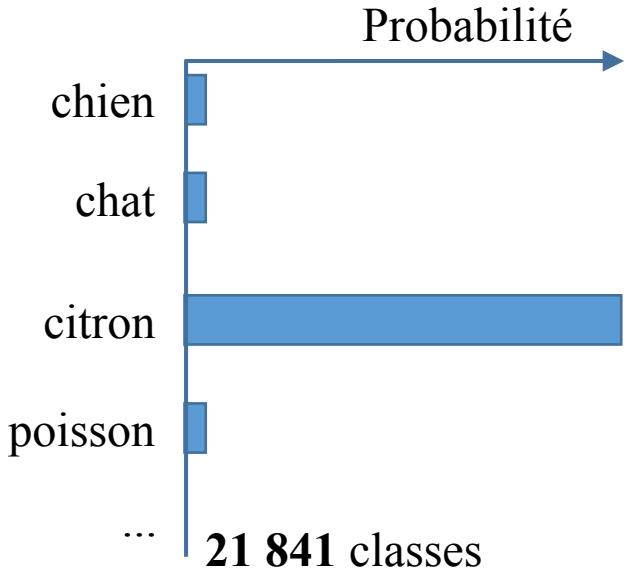

5.Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." Advances in neural information processing systems 25 (2012).

« Attention is all you need »

Harry Potter and the Philosopher's Stone (also known as ***Harry Potter and the Sorcerer's Stone*** in the United States, India, and the Philippines) is a 2001 fantasy film directed by Chris Columbus and written by Steve Kloves, based on the 1997 novel by J. K. Rowling. It is the first instalment in the *Harry Potter* film series, and stars Daniel Radcliffe as Harry Potter, with Rupert Grint as Ron Weasley, and Emma Watson as Hermione Granger. Its story follows Harry's first year at Hogwarts School of Witchcraft and Wizardry as he discovers that he is a famous wizard and begins his formal wizarding education.

https://en.wikipedia.org/wiki/Harry_Potter_and_the_Philosopher%27s_Stone_(film)#Plot

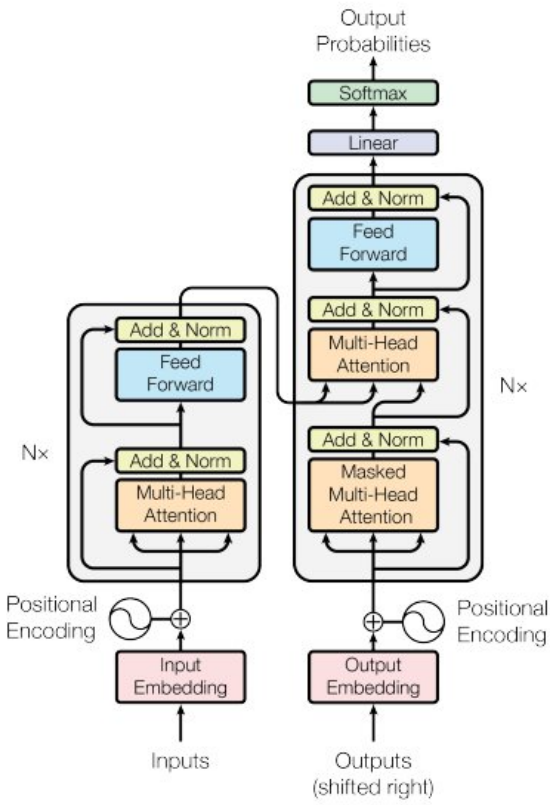

Transformeur (2017)

Traduction :
Harry Potter à l'école des sorciers (également connu sous le titre Harry Potter and the Sorcerer's Stone aux États-Unis, en Inde et aux Philippines) est un film fantastique de 2001 réalisé par Chris Columbus et écrit par Steve Kloves, d'après le roman de J.K. Rowling paru en 1997. Premier volet de la saga Harry Potter, il met en scène Daniel Radcliffe dans le rôle de Harry Potter, Rupert Grint dans celui de Ron Weasley et Emma Watson dans celui d'Hermione Granger. L'histoire suit la première année de Harry à Poudlard, l'école de sorcellerie, où il découvre son destin de sorcier et entame sa formation.

Résumé :
Harry Potter à l'école des sorciers est un film fantastique sorti en 2001, réalisé par Chris Columbus et adapté du roman de J.K. Rowling publié en 1997. Premier film de la saga, il met en vedette Daniel Radcliffe (Harry), Rupert Grint (Ron) et Emma Watson (Hermione). L'histoire raconte la première année de Harry à Poudlard, où il découvre qu'il est un sorcier et commence son apprentissage magique.

Analyse de sentiment :
Le texte que tu as fourni est neutre.

Réécriture
Harry Potter à l'école des sorciers — intitulé Harry Potter and the Sorcerer's Stone aux États-Unis, en Inde et aux Philippines — est un film fantastique paru en 2001, réalisé par Chris Columbus et scénarisé par Steve Kloves. Il constitue le premier opus de la franchise cinématographique adaptée de l'œuvre éponyme de J.K. Rowling, publiée en 1997. Le film met en scène Daniel Radcliffe, Rupert Grint et Emma Watson dans les rôles principaux de Harry Potter ...

L'IA est là (du moins, c'est ce qu'ils disaient).

ChatGPT
(2022)

Qu'apprendrons-nous dans ce cours ?

- Large Reasoning Models
- Agentic AI
- Vector database
- RAG
- MCP
- MOE
- ASI
- Vibe coding

Qu'apprendrons-nous dans ce cours ?

- Large Reasoning Models
- Agentic AI
- Vector database
- RAG
- MCP
- MOE
- ASI
- Vibe coding

1. Comment fonctionnent les grands modèles de langage (LLM)
2. Comment utiliser LLM de manière responsable

Qu'apprendrons-nous dans ce cours ?

1. Comment fonctionnent les grands modèles de langage (LLM)
2. Comment utiliser LLM de manière responsable

1. Les composants essentiels des LLM
2. La corrélation entre la performance et l'échelle
3. Les étapes de l'entraînement des LLM
4. Analyser les limitations des LLM et les solutions

Qu'apprendrons-nous dans ce cours ?

1. Comment fonctionnent les grands modèles de langage (LLM)
2. Comment utiliser LLM de manière responsable

1. Les principaux usages des LLM
2. Évaluation de la qualité et la fiabilité des réponses générées
3. Enjeux environnementaux et éthiques liés aux LLM

1.1 Composants essentiels des LLM

1.1.1 Un petit LM (modèle de langage)

Un modèle de traduction anglais-espagnol

Principe de fonctionnement des modèles de langages : génération autorégressive

```
def traduire(phrase d'entrée, modèle):
    phrase de sortie = list()
    mot = ''
    while mot != fin de la phrase:
        mot = modèle(phrase d'entrée, phrase de sortie)
        phrase de sortie.append(mot)
    return phrase de sortie
```

Principe de fonctionnement des modèles de langages : génération autorégressive

```
def traduire(phrase d'entrée, modèle):
    phrase de sortie = list()
    mot = ''
    while mot != fin de la phrase:
        mot = modèle(phrase d'entrée, phrase de sortie)
        phrase de sortie.append(mot)
    return phrase de sortie
```

Début de l'itération 0 :
Phrase de sortie = [« sos »]

Fin de l'itération 0 :
Phrase de sortie = [« sos », hola]

Principe de fonctionnement des modèles de langages : génération autorégressive

```
def traduire(phrase d'entrée, modèle):
    phrase de sortie = list()
    mot = ''
    while mot != fin de la phrase:
        mot = modèle(phrase d'entrée, phrase de sortie)
        phrase de sortie.append(mot)
    return phrase de sortie
```

Début de l'itération 1 :
Phrase de sortie = [« sos », hola]

Fin de l'itération 1 :
Phrase de sortie = [« sos », hola, mundo]

Principe de fonctionnement des modèles de langages : génération autorégressive

```
def traduire(phrase d'entrée, modèle):
    phrase de sortie = list()
    mot = ''
    while mot != fin de la phrase:
        mot = modèle(phrase d'entrée, phrase de sortie)
        phrase de sortie.append(mot)
    return phrase de sortie
```

Début de l'itération 2 :
Phrase de sortie = [« sos », hola, mundo]

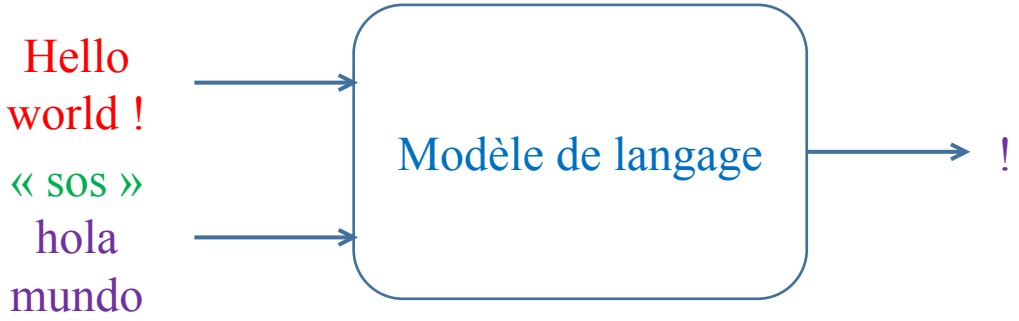

Fin de l'itération 2 :
Phrase de sortie = [« sos », hola, mundo, !]

Principe de fonctionnement des modèles de langages : génération autorégressive

```
def traduire(phrase d'entrée, modèle):
    phrase de sortie = list()
    mot = ''
    while mot != fin de la phrase:
        mot = modèle(phrase d'entrée, phrase de sortie)
        phrase de sortie.append(mot)
    return phrase de sortie
```

Début de l'itération 3 :
Phrase de sortie = [« sos », hola, mundo, !]

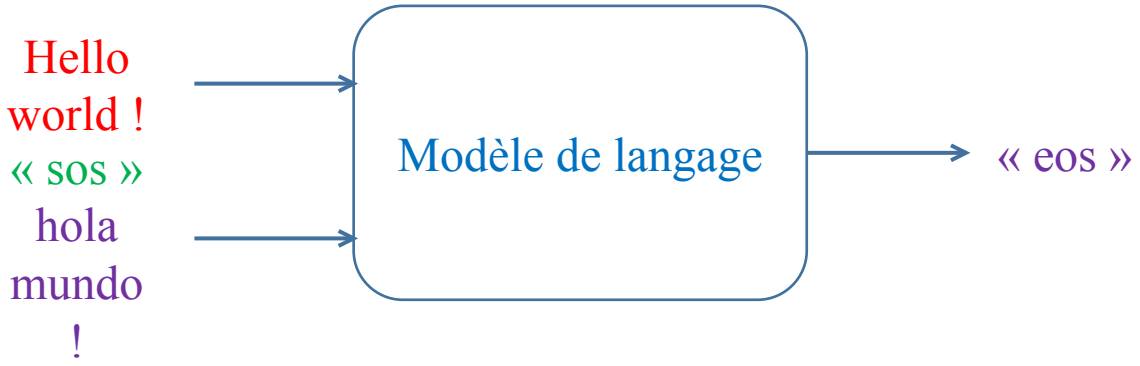

Fin de l'itération 3 :
Phrase de sortie = [« sos », hola, mundo, !, « eos »]

Composants essentiels des LLM

Génération autorégressive

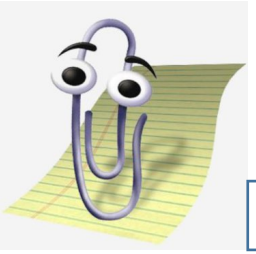

1

La qualité des réponses des LLM dépend fortement sur la qualité des « prompts ».
Nous pouvons améliorer la qualité de nos « prompts » en les ajoutant le contexte.

Démonstration : poser une question à Le Chat et observer sa réponse

Prompt : Je suis étudiant en informatique. Je suis en train d'apprendre les LLM. Peux-tu expliquer la stratégie de génération autorégressive ?

1.https://learn-attachment.microsoft.com/api/attachments/505892a2-ac22-43a1-87e1-5a5e181d1fdb?platform=QnA

Représentation des entrées et sorties des LLM

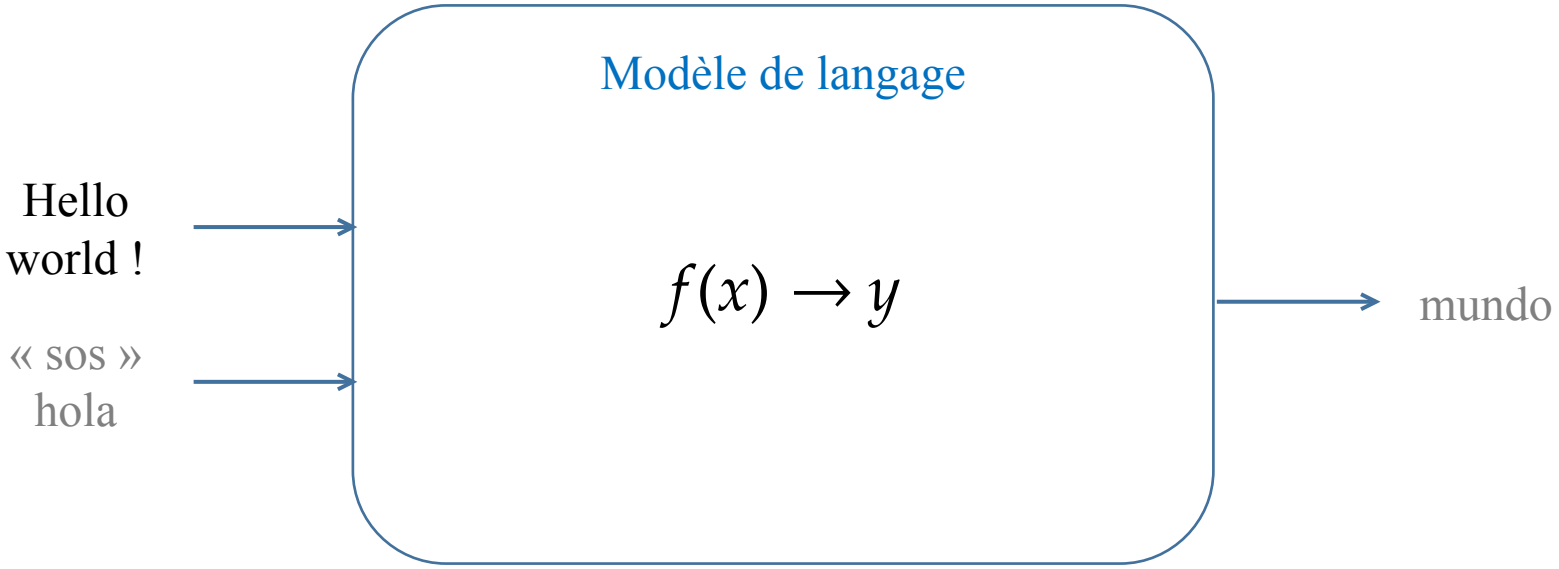

Représentation des entrées et sorties des LLM

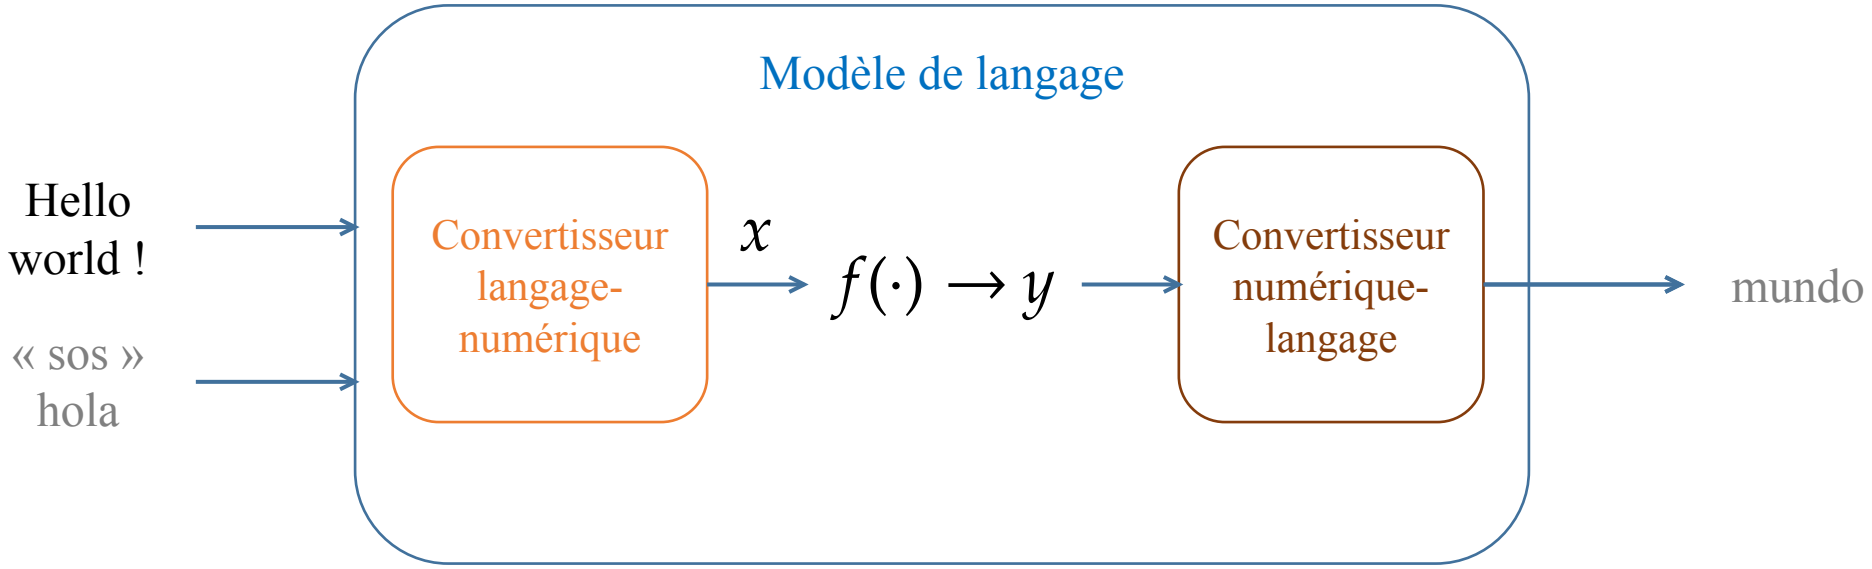

Convertisseur langage-numérique

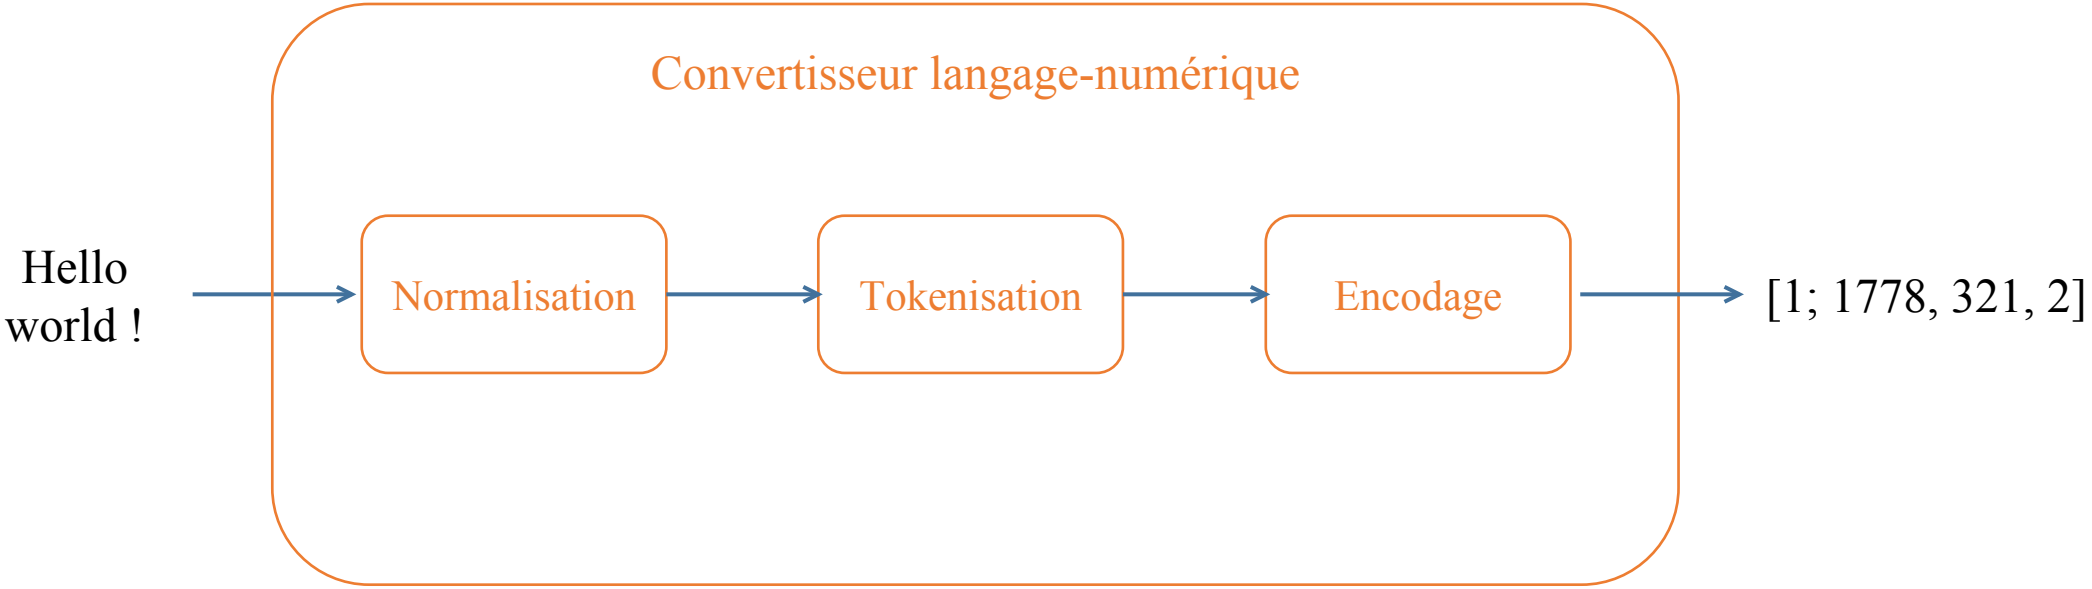

Convertisseur langage-numérique

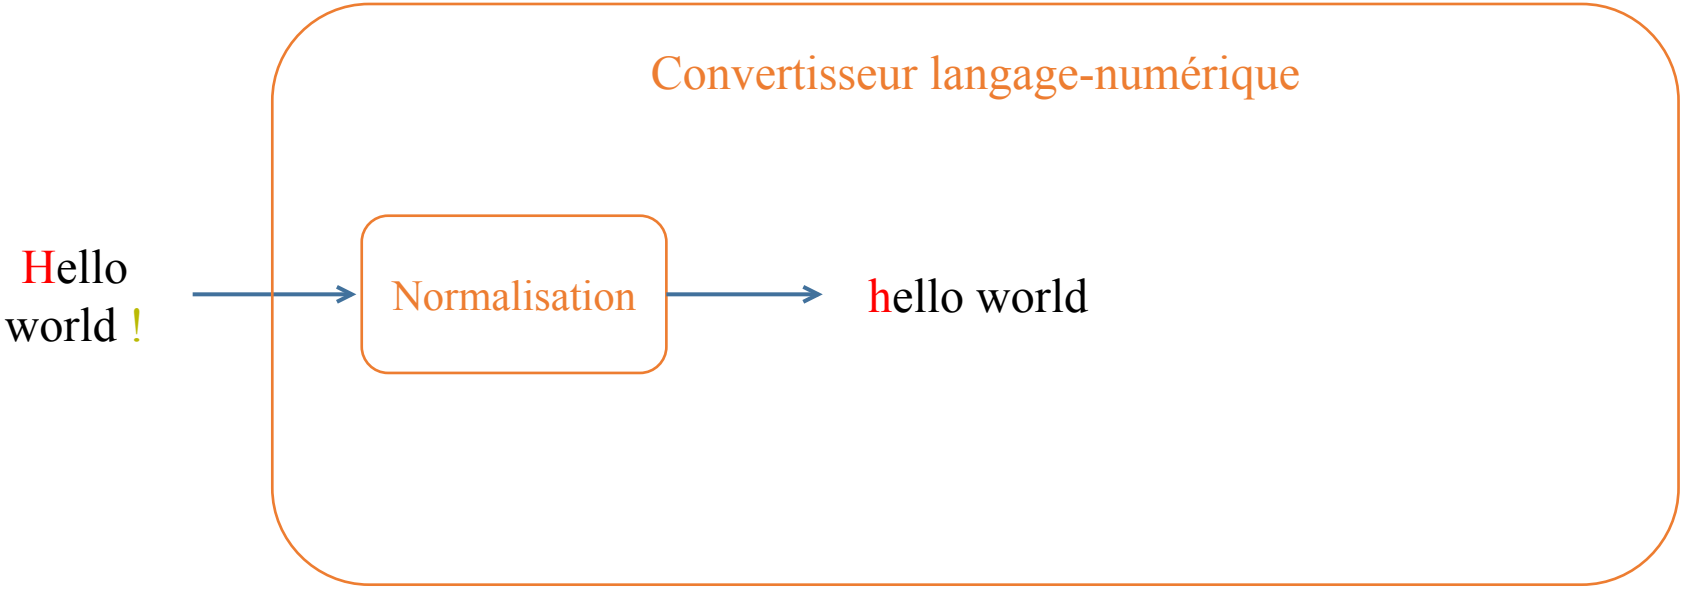

Convertisseur langage-numérique

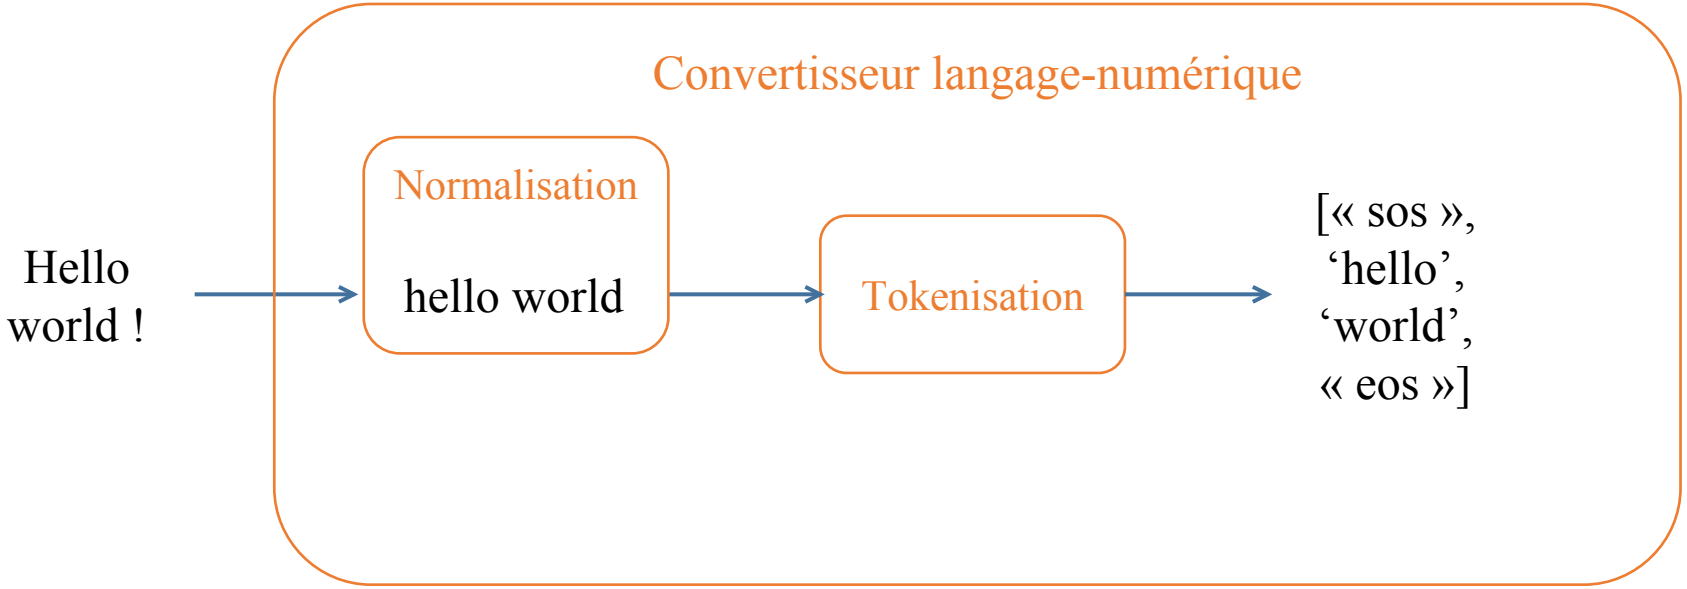

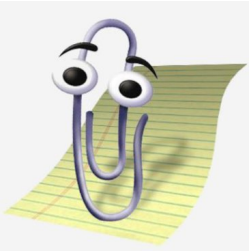

« sos » est un **jeton**
‘hello’ est un jeton
tous les mots sont les jetons.

Convertisseur langage-numérique

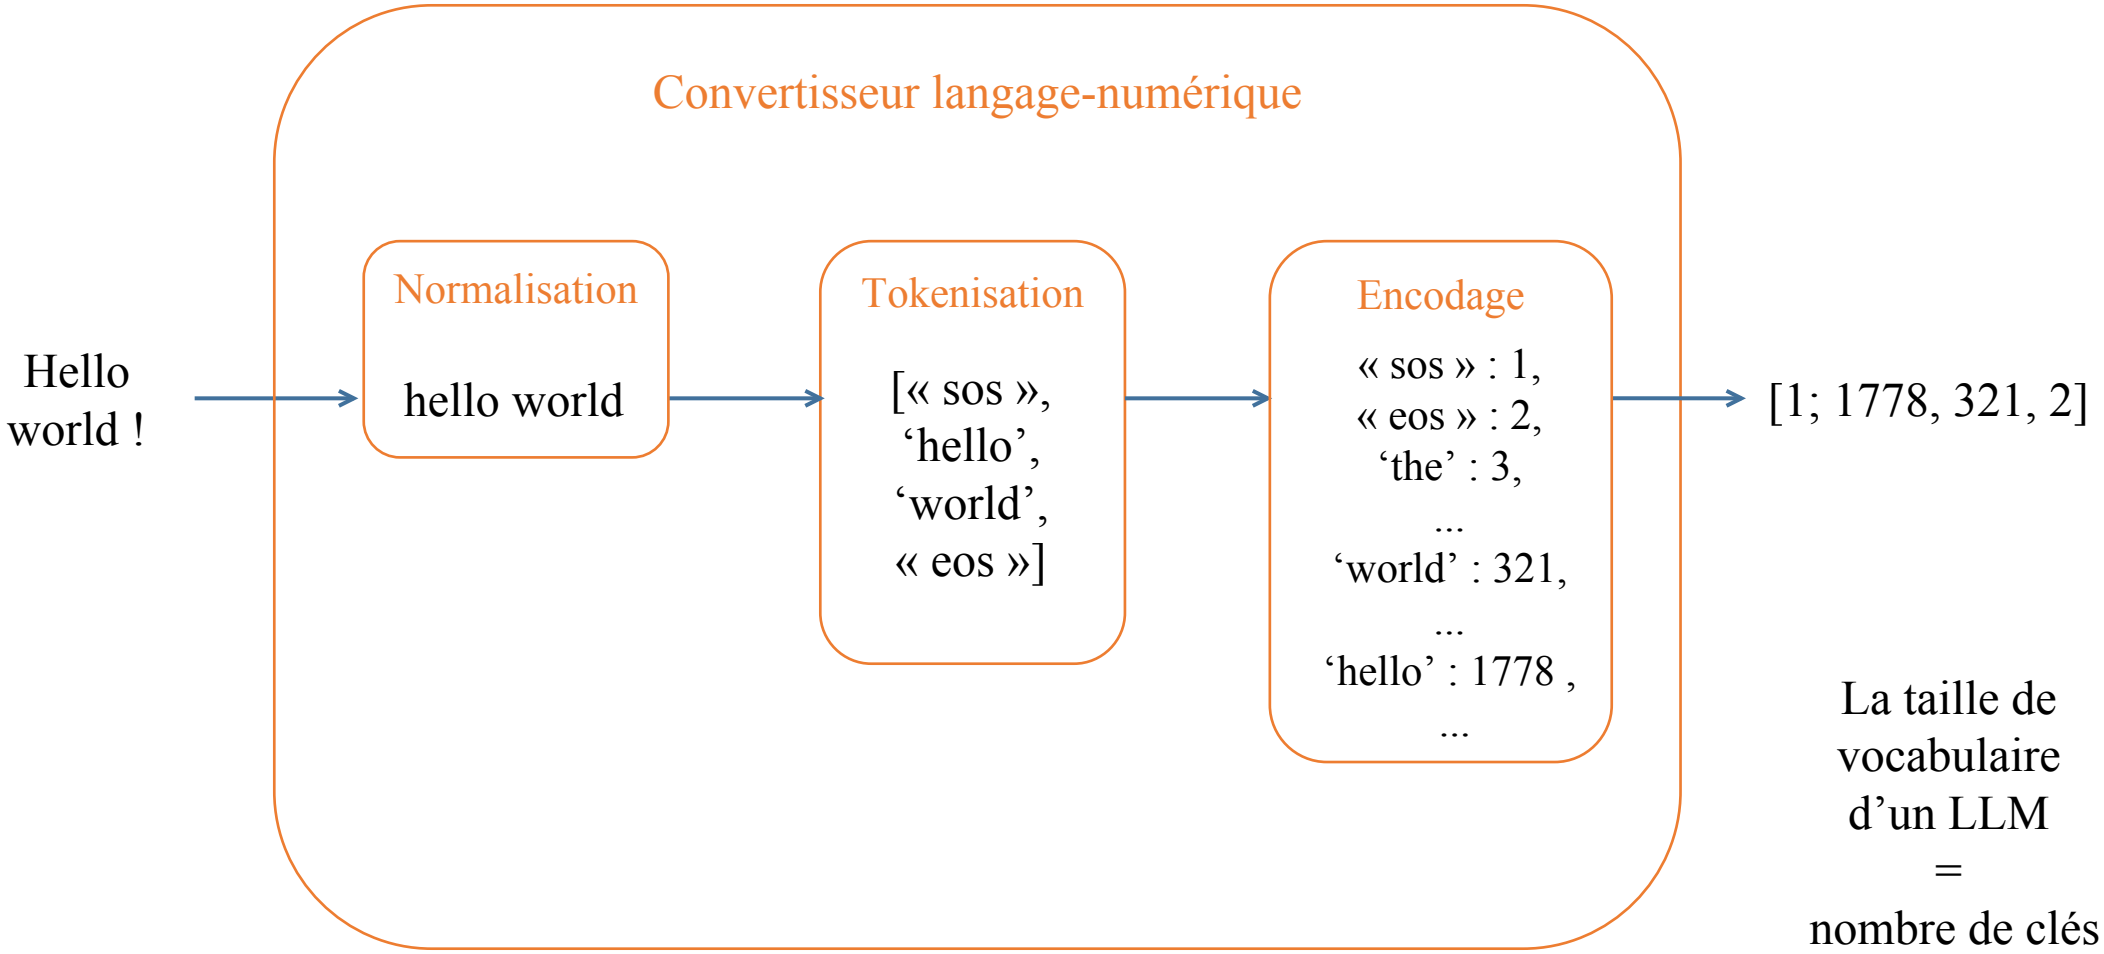

La taille de vocabulaire d’un LLM
=
nombre de clés

Le «GRAND» des grandes modèles de langage

Modèle	#paramêtres (milliards)	Taille du vocabulaire (# jetons)	#jetons de la base d'entraînement (milliards)	Fenêtre de contexte maximale (#jetons)	La date limite pour acquérir des connaissances
GPT-3	175	50,257	292	2048	
GPT-4	?	100,000	?	32,768	
GPT-5	?	?	?	400,000	
Mistral Large 2	123	32,768	?	128,000	
Llama 3	405	128,000	15,000	128,000	12/2023
Claude 2	130	?	?	100,000	
Claude 3	?	65,000	?	500,000	

Convertisseur langage-numérique

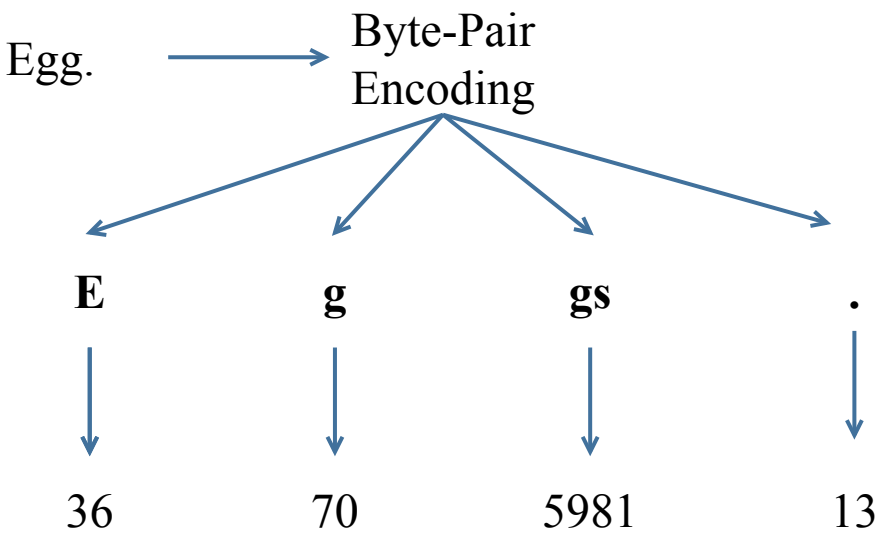

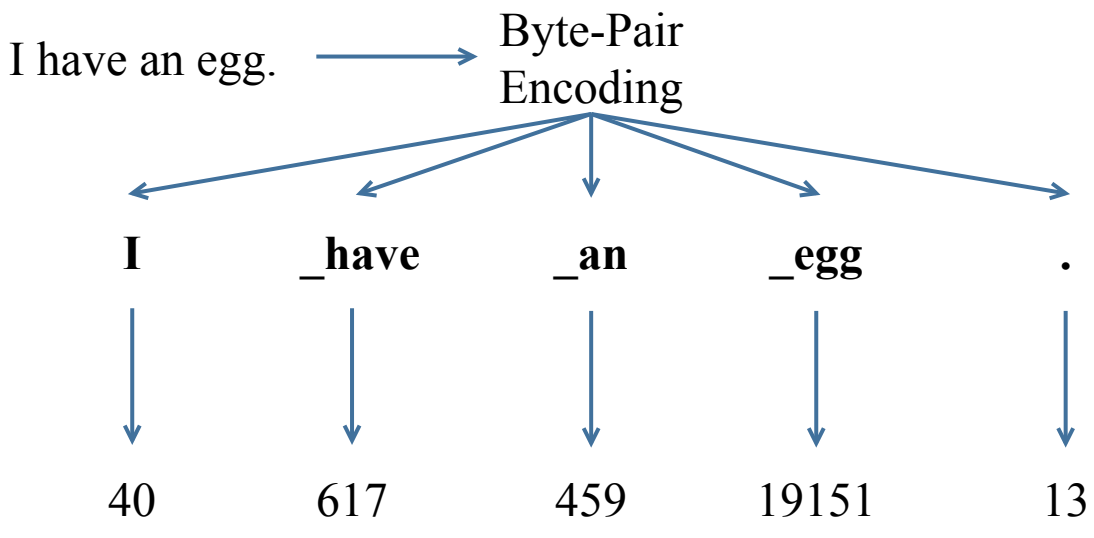

Démonstration : la tokenisation des LLM

https://tiktokenizer.vercel.app/?model=meta-llama%2FMeta-Llama-3-8B

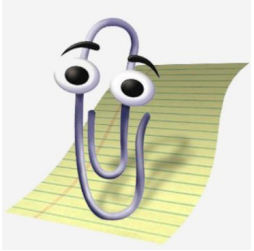

Le trait de soulignement représente un espace.

Convertisseur numérique-langage

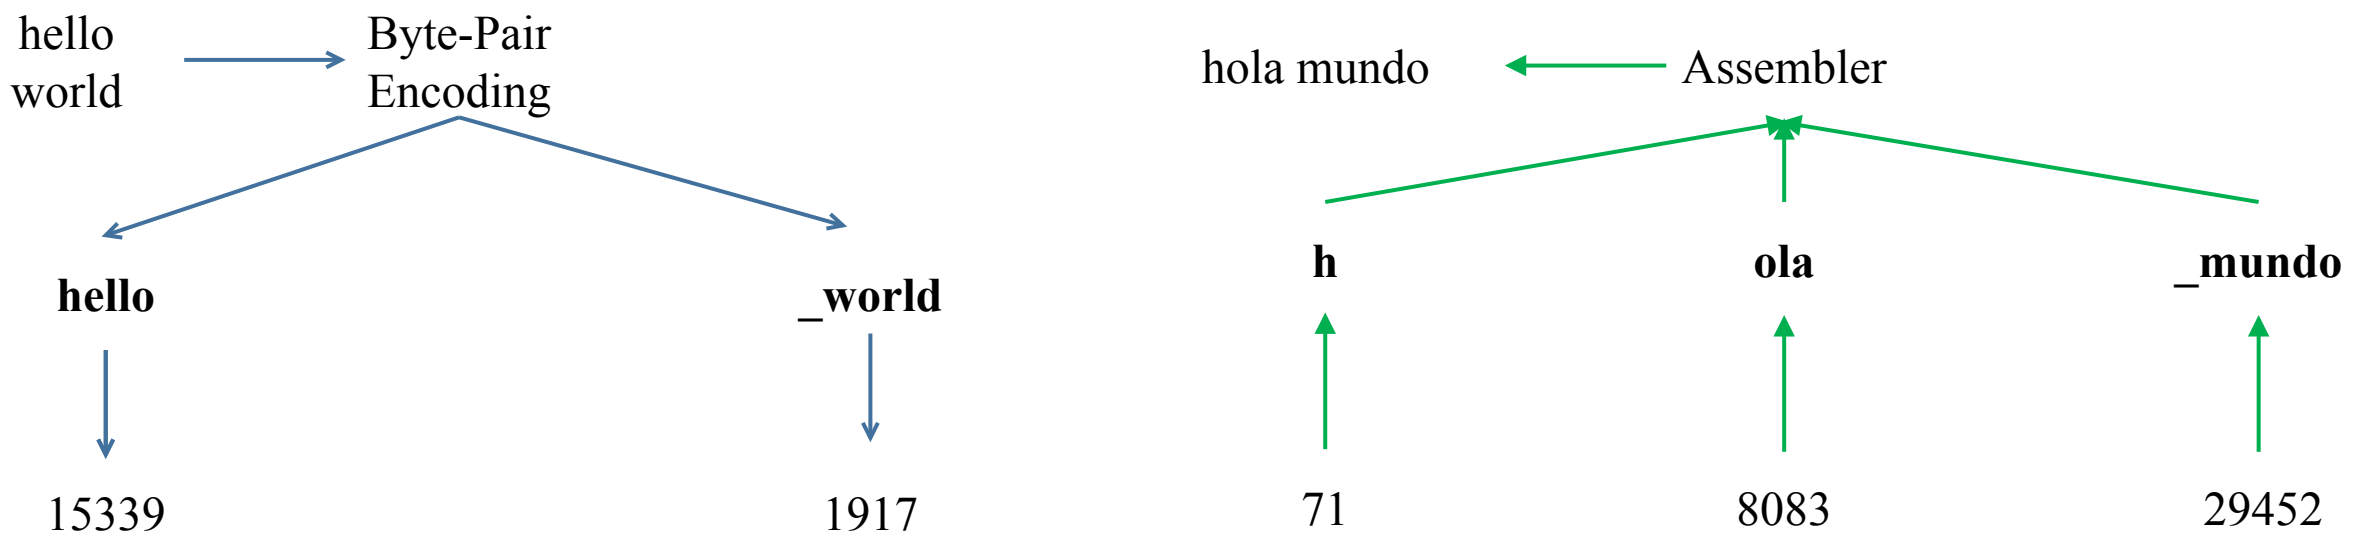

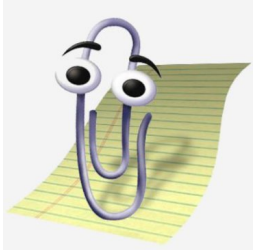

Le trait de soulignement représente un espace.

Composants essentiels des LLM

Génération autorégressive

Tokenisation

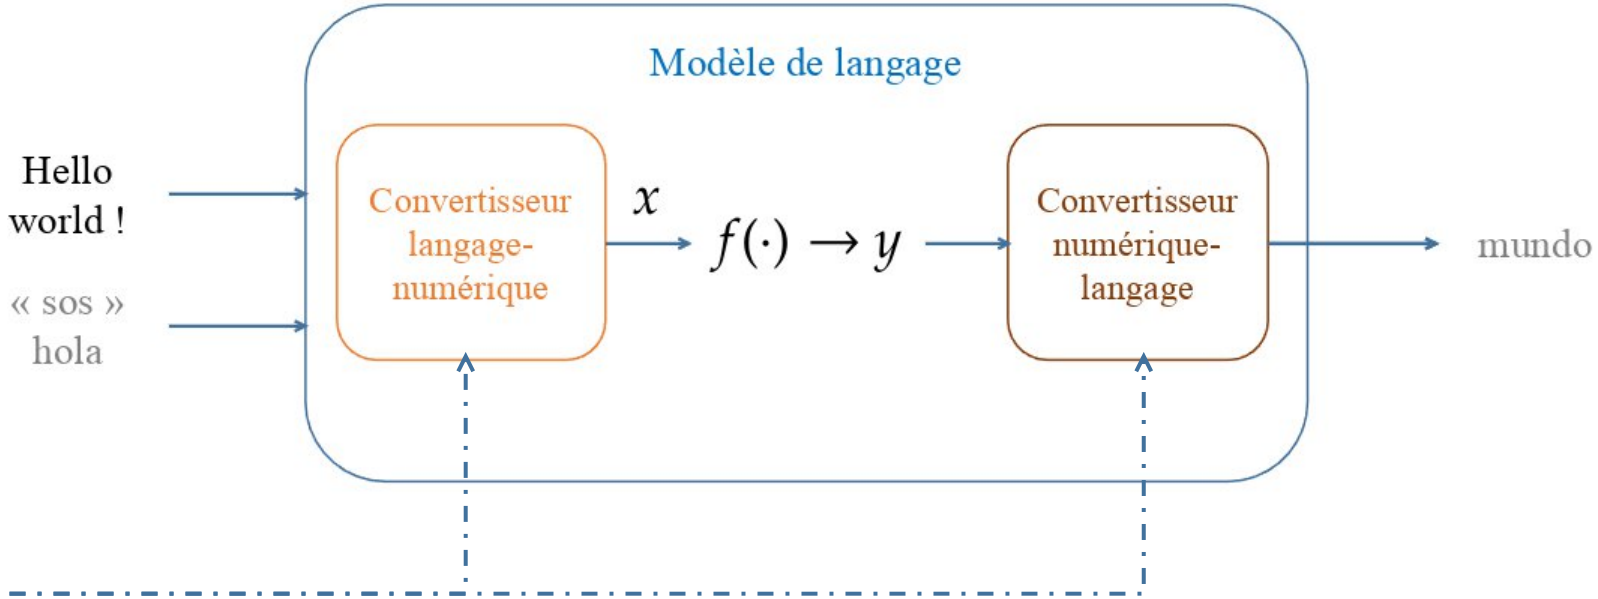

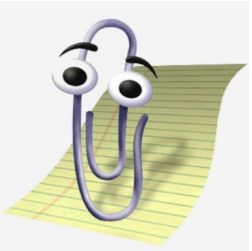

« tokenisation » = normalisation
+ tokenisation + encodage

Le calcul à l'intérieur des LLM

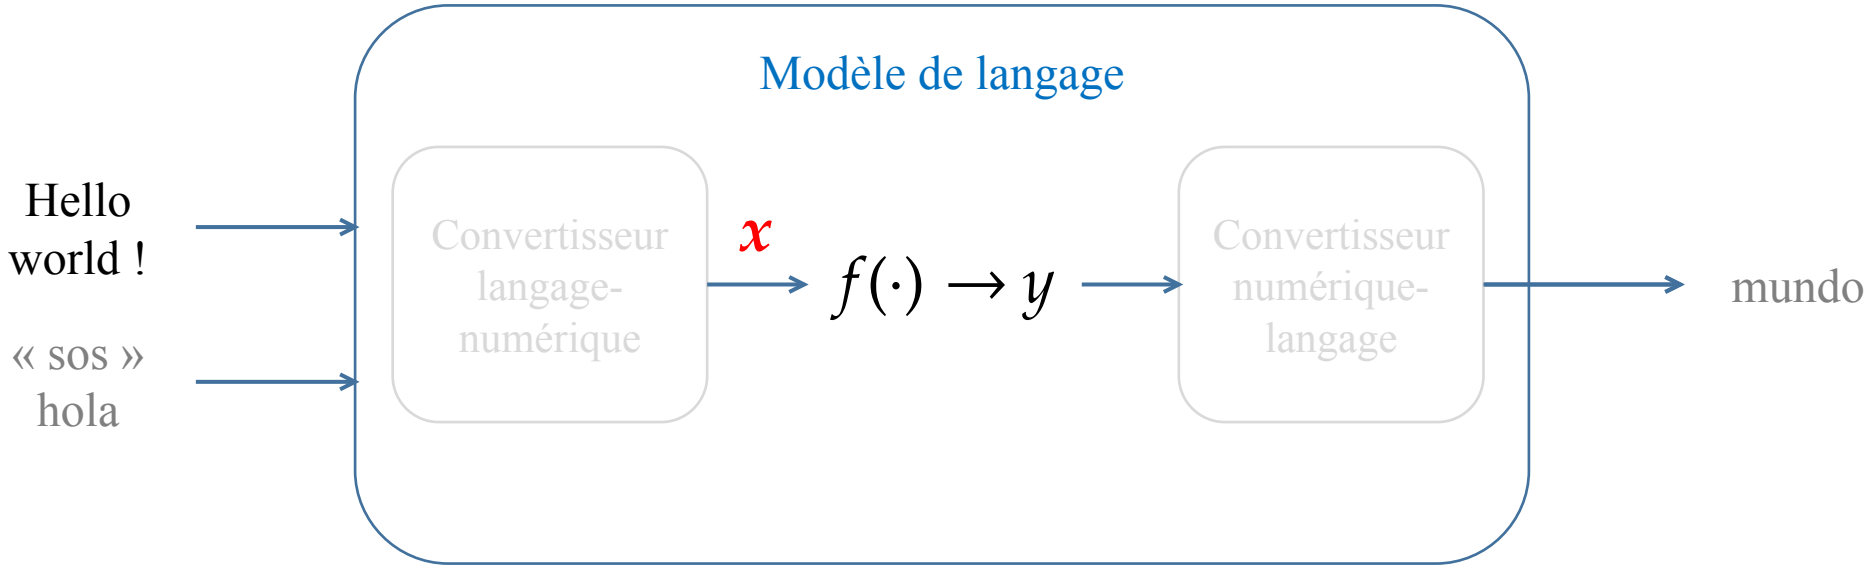

La limitation des jetons

Tokenisation de GPT-4

Mot	Jeton
dog	18964
cat	4719
bird	23414
see	4151
look	7349

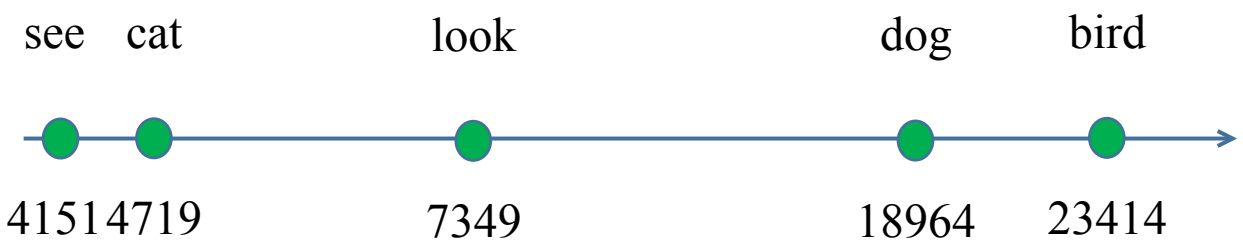

- le mot « dog » est plus proche du mot « bird » que du mot « cat ».
- le mot « cat » est plus proche du mot « see » que du mot « look »

Les jetons ne portent pas en eux la structure du langage naturel.

Embeddings vectoriels 2D

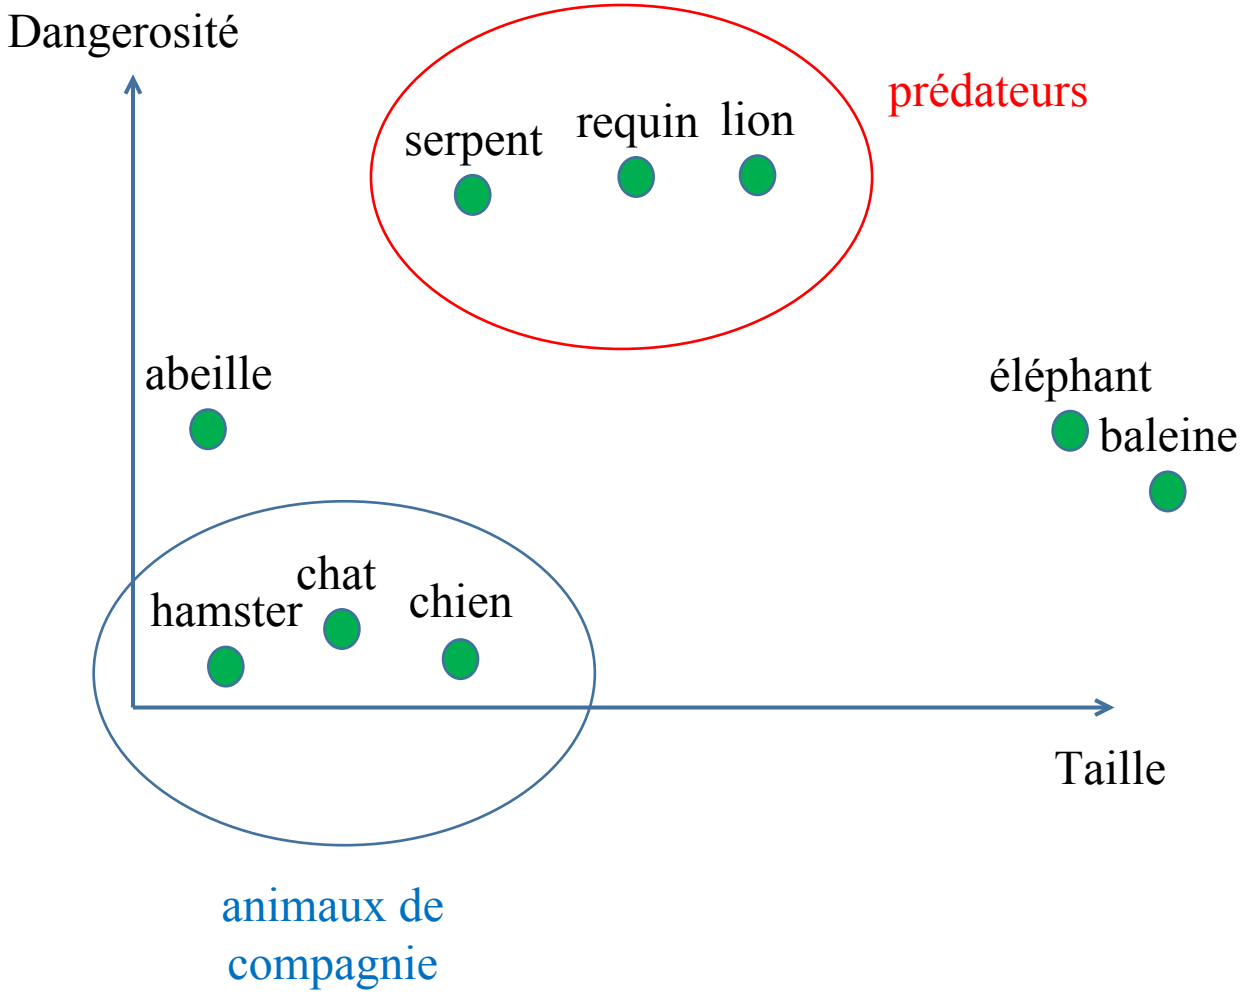

Embeddings vectoriels 2D

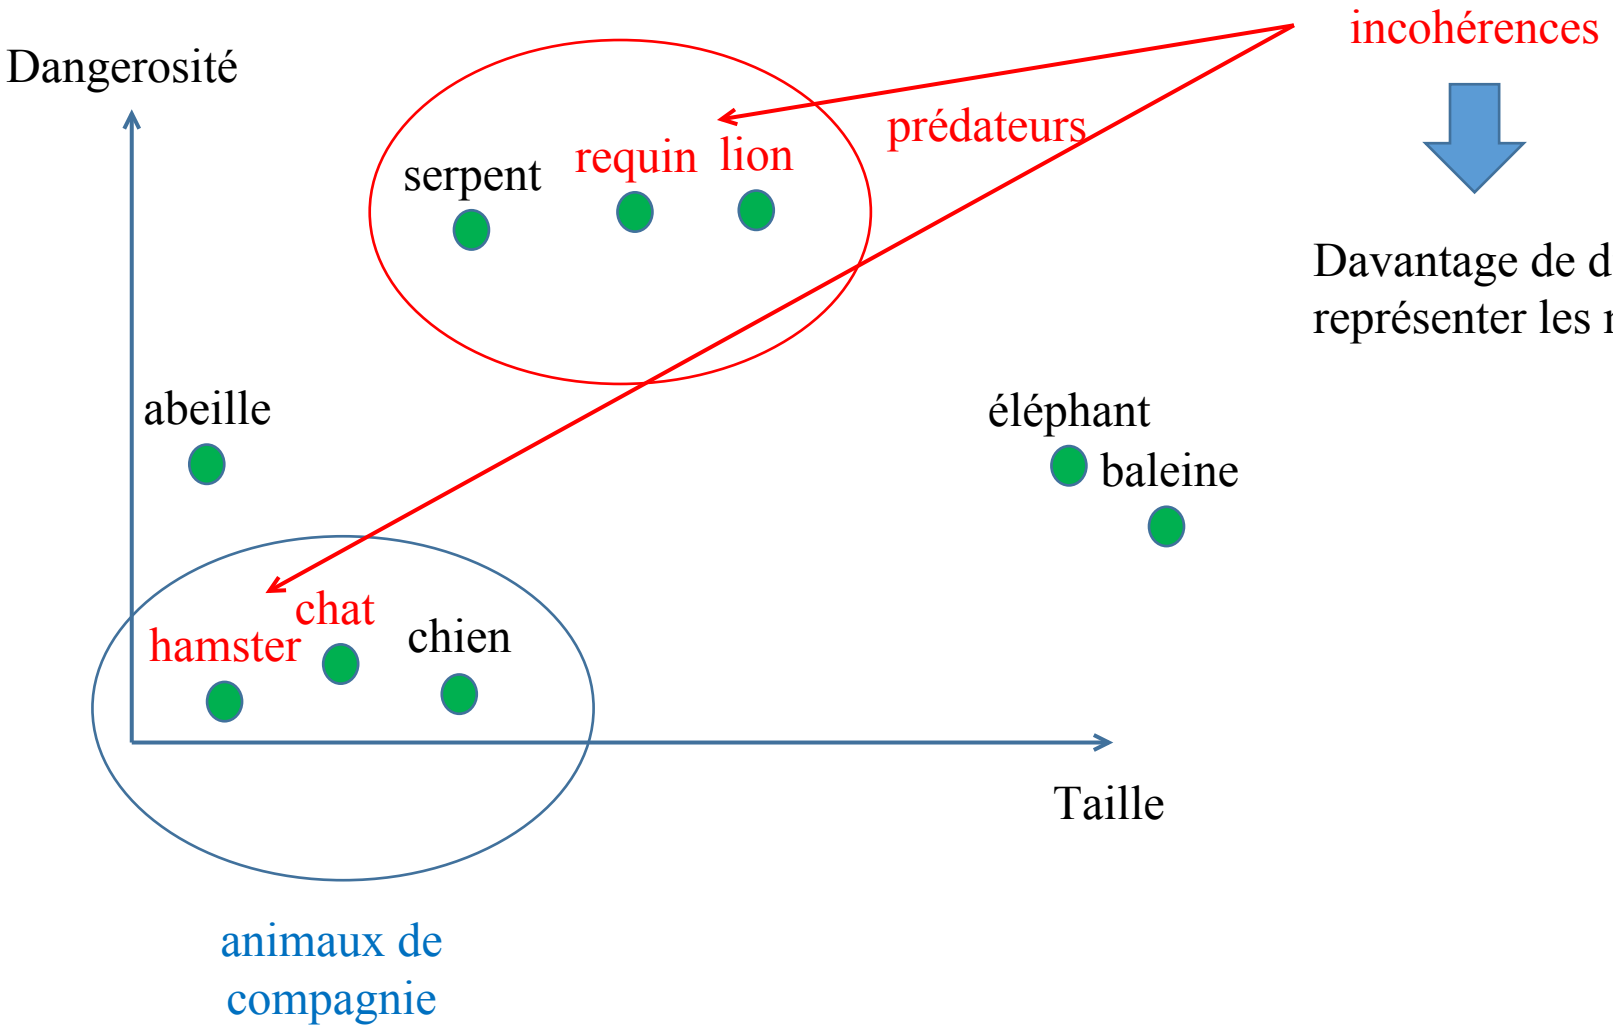

incohérences

Davantage de dimensions sont nécessaires pour représenter les nombreux concepts du langage naturel.

Embeddings vectoriels multidimensionnels

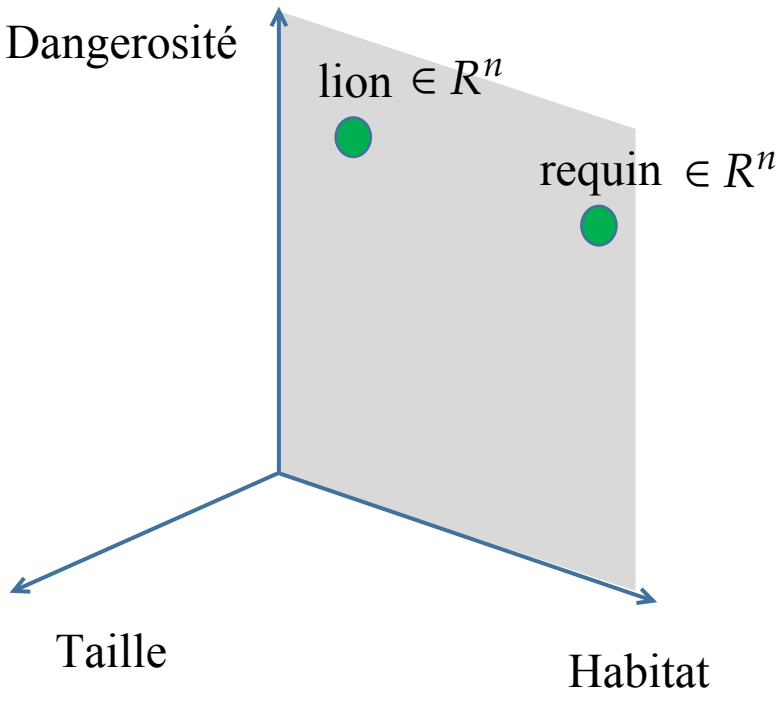

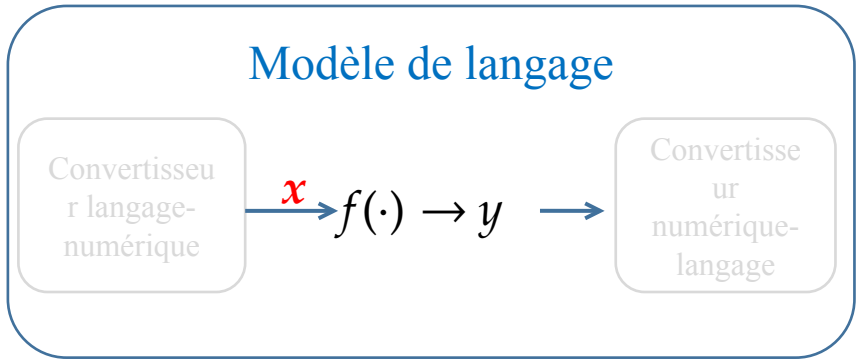

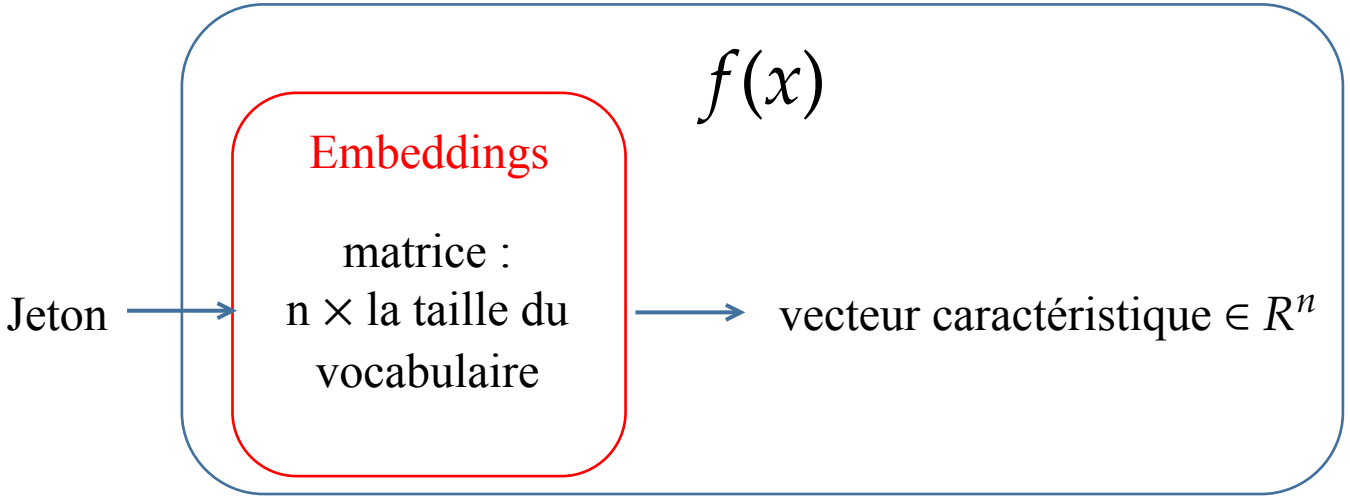

n = 4096 (Llama 3), 12288 (GPT-3), 7168 (DeepSeek)

Important du contexte

verre

une matière

un récipient

Important du contexte

Il a posé son verre sur la table.

une matière

un récipient

Prendre en compte le contexte grâce au mécanisme de self-attention

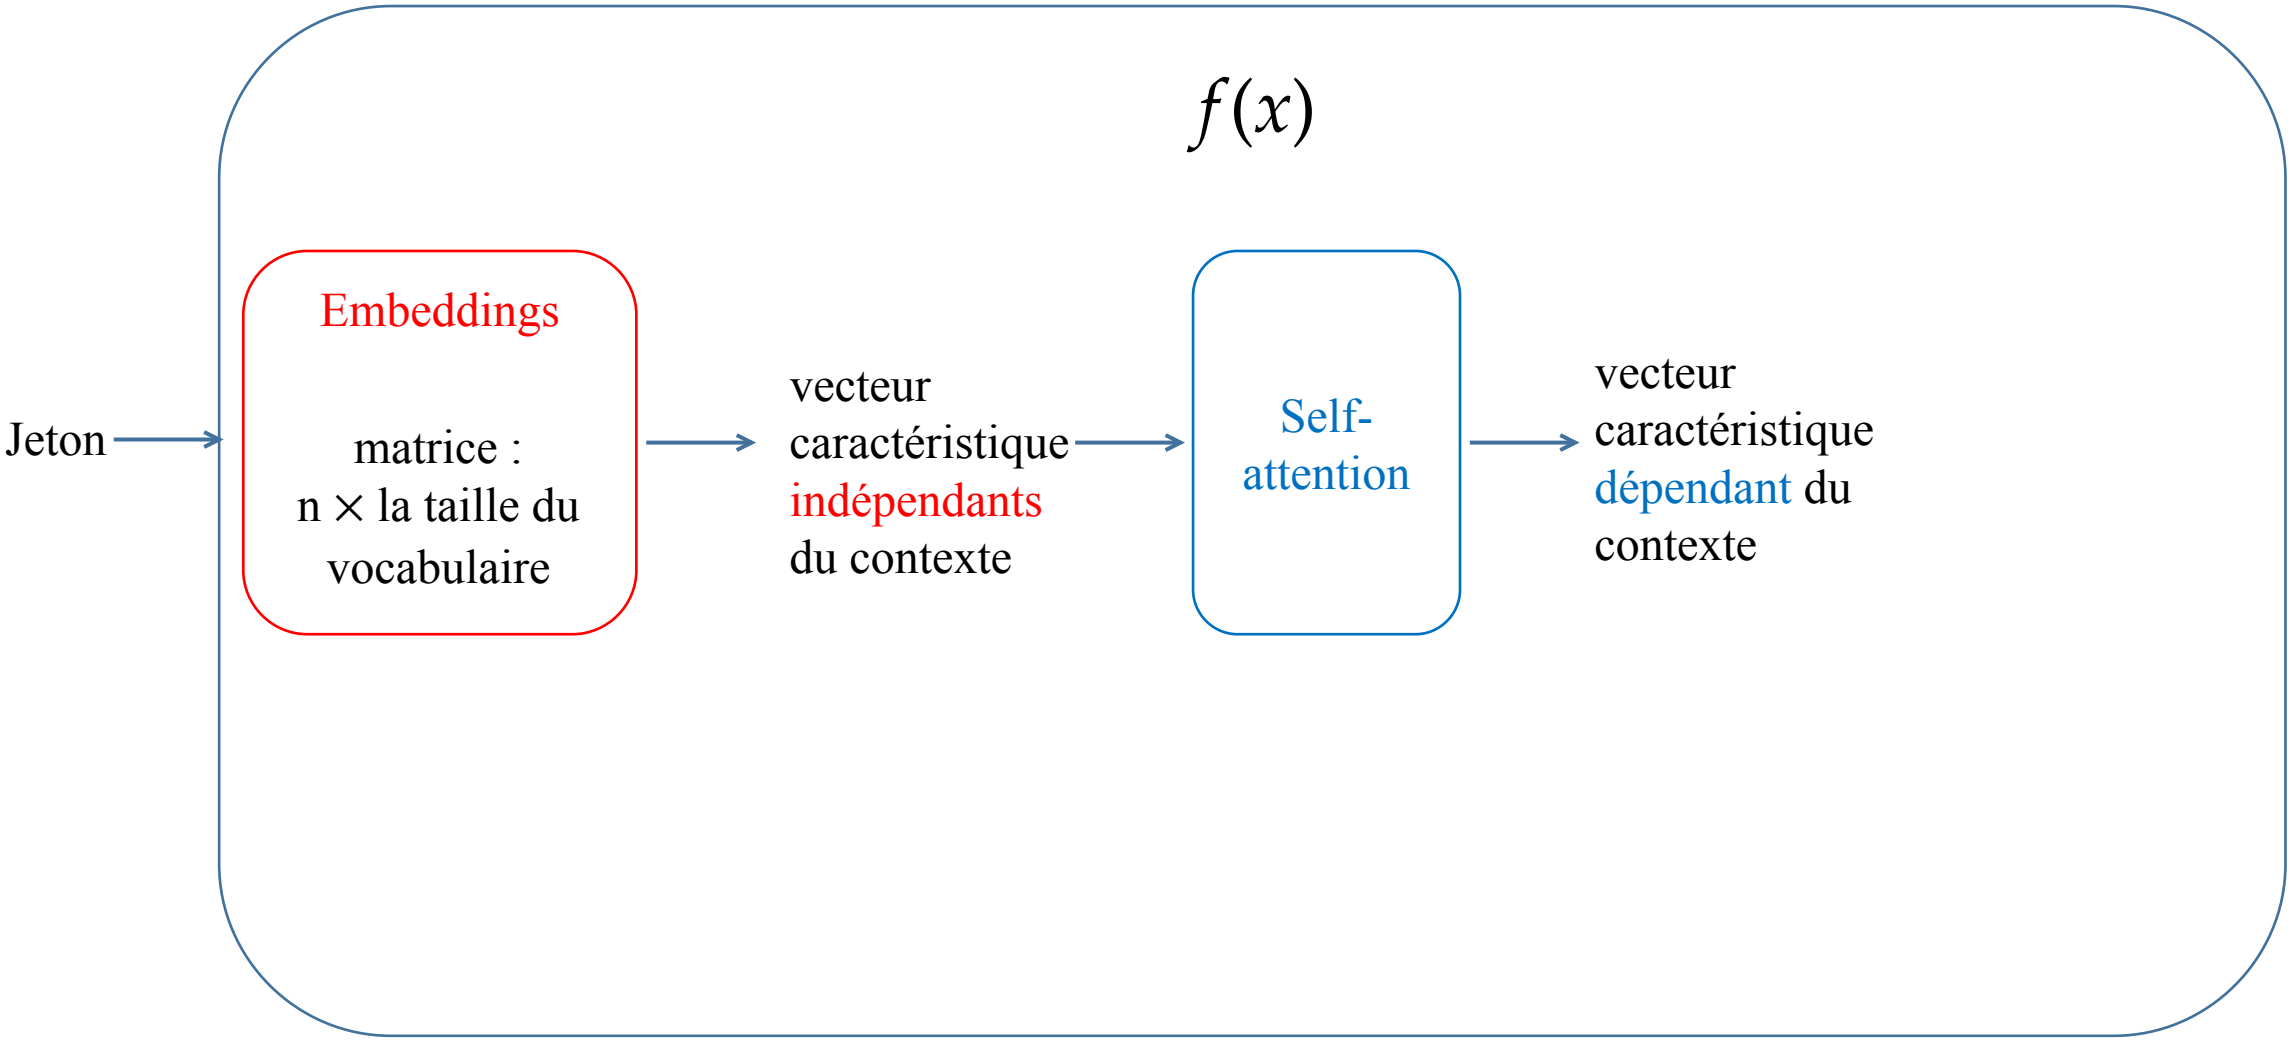

Self-attention : le contexte sous forme de scores d'attention

	il	a	posé	son	verre	sur	la	table
il	1.0	0.1	0.2	0.5	0.3	0.1	0.1	0.1
a	0.1	1.0	0.4	0.1	0.2	0.1	0.1	0.1
posé	0.2	0.4	1.0	0.1	0.6	0.4	0.1	0.5
son	0.5	0.1	0.1	1.0	0.5	0.1	0.1	0.1
verre	0.3	0.2	0.6	0.5	1.0	0.4	0.1	0.6
sur	0.1	0.1	0.4	0.1	0.4	1.0	0.1	0.6
la	0.1	0.1	0.1	0.1	0.1	0.1	1.0	0.5
table	0.1	0.1	0.5	0.1	0.6	0.6	0.5	1.0

$$\text{score}(\text{verre, table}) = \cos\left(\angle\left(E_{\text{verre}}, E_{\text{table}}\right)\right)$$

E_{verre} est le vecteur caractéristique du jeton verre

E_{table} est le vecteur caractéristique du jeton verre

$\angle(E_{\text{verre}}, E_{\text{table}})$ est l'angle entre les deux vecteurs

Self-attention : adapter les vecteurs caractéristiques en fonction du contexte

	verre
il	0.3
a	0.2
posé	0.6
son	0.5
verre	1.0
sur	0.4
la	0.1
table	0.6

Normaliser

	verre
il	0.10
a	0.09
posé	0.14
son	0.13
verre	0.21
sur	0.11
la	0.08
table	0.14

somme = 1.0

$$E^{sortie}_{\text{verre}} = \sum_{jeton \in \{il,\, a,\, \cdots,\, table\}} score\left(E^{entrée}_{jeton}, E^{entrée}_{\text{verre}}\right) \cdot E^{entrée}_{jeton}$$

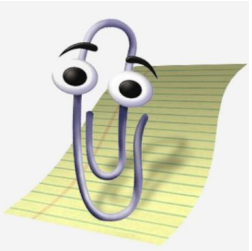

$E^{entrée}_{\text{verre}}$: « query »

$E^{entrée}_{jeton}$: « key » et « value »

Self-attention : adapter les vecteurs caractéristiques en fonction du contexte

	verre
il	0.3
a	0.2
posé	0.6
son	0.5
verre	1.0
sur	0.4
la	0.1
table	0.6

Normaliser

	verre
il	0.10
a	0.09
posé	0.14
son	0.13
verre	0.21
sur	0.11
la	0.08
table	0.14

somme = 1.0

$$E^{sortie}_{\text{verre}} = \Sigma_{jeton \in \{il,\, a,\, \cdots,\, table\}} score\left(E^{entrée}_{jeton}, E^{entrée}_{\text{verre}}\right) \cdot E^{entrée}_{jeton}$$

- linéaire
- E^{sortie} se trouve dans le même espace que $E^{entrée}$

La capacité du modèle entier est égale la capacité du module d'embedding, qui en est la toute première couche.

Souhaitée : plus le modèle est approfondi, plus sa capacité augmente.

Self-attention : ajouter les réseaux neuronal à propagation avant (FNN)

Souhaitée : plus le modèle est approfondi,
plus sa capacité augmente.

$$E_{\text{verre}}^{sortie} =$$

$$\sum_{jeton \in \{il,\, a,\, \cdots,\, table\}} score\left(FNN\left(E_{jeton}^{entrée}\right), FNN\left(E_{\text{verre}}^{entrée}\right)\right) \cdot FNN\left(E_{jeton}^{entrée}\right)$$

$$FNN(x) = ReLU(W \cdot x + b)$$

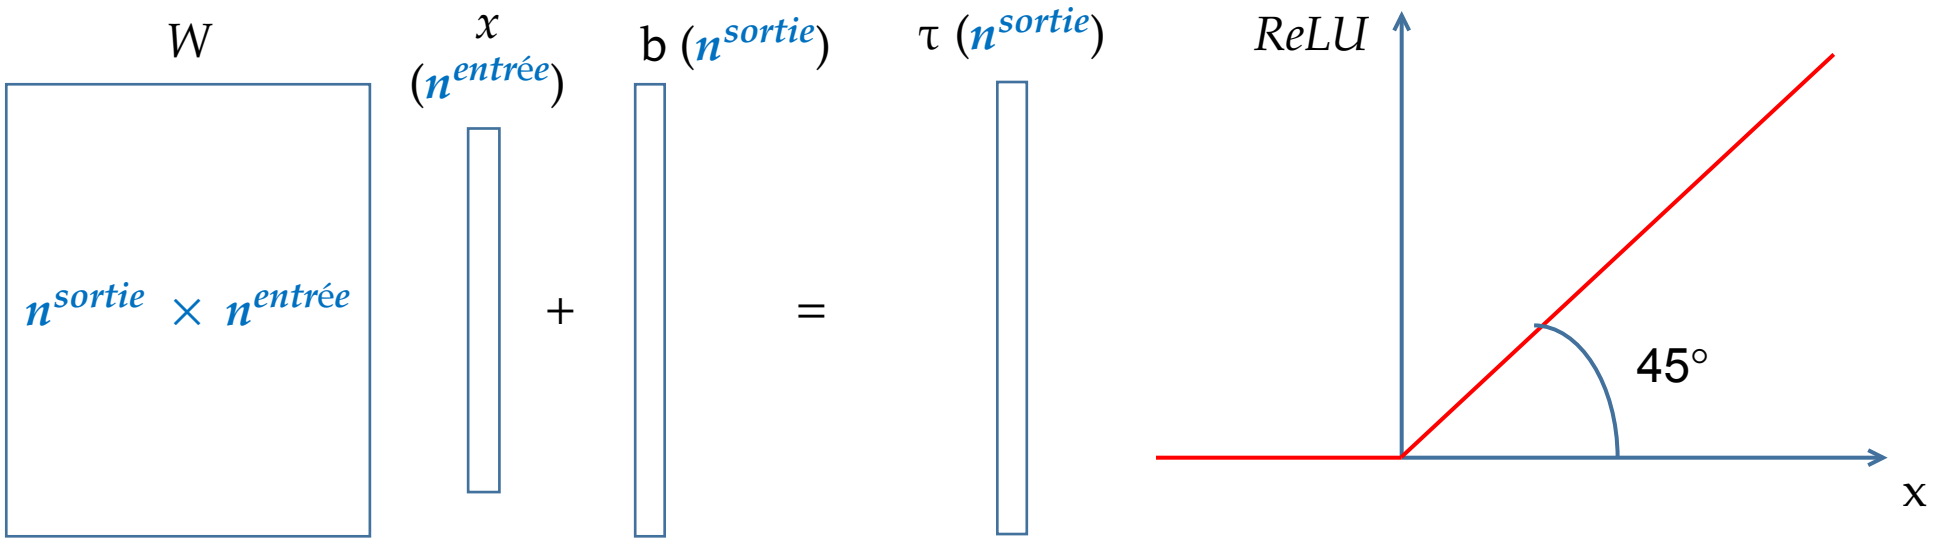

Self-attention : fenêtre de contexte maximale

Un modèle peut-il traiter une phrase de n'importe quelle longueur ?

Self-attention : fenêtre de contexte maximale

Un modèle peut-il traiter une phrase de n'importe quelle longueur ?

	il	a	posé	son	verre	sur	la	table
il	1.0	0.1	0.2	0.5	0.3	0.1	0.1	0.1
a	0.1	1.0	0.4	0.1	0.2	0.1	0.1	0.1
posé	0.2	0.4	1.0	0.1	0.6	0.4	0.1	0.5
son	0.5	0.1	0.1	1.0	0.5	0.1	0.1	0.1
verre	0.3	0.2	0.6	0.5	1.0	0.4	0.1	0.6
sur	0.1	0.1	0.4	0.1	0.4	1.0	0.1	0.6
la	0.1	0.1	0.1	0.1	0.1	0.1	1.0	0.5
table	0.1	0.1	0.5	0.1	0.6	0.6	0.5	1.0

la complexité temporelle et spatiale ?

Self-attention : fenêtre de contexte maximale

Un modèle peut-il traiter une phrase de n'importe quelle longueur ?

	il	a	posé	son	verre	sur	la	table
il	1.0	0.1	0.2	0.5	0.3	0.1	0.1	0.1
a	0.1	1.0	0.4	0.1	0.2	0.1	0.1	0.1
posé	0.2	0.4	1.0	0.1	0.6	0.4	0.1	0.5
son	0.5	0.1	0.1	1.0	0.5	0.1	0.1	0.1
verre	0.3	0.2	0.6	0.5	1.0	0.4	0.1	0.6
sur	0.1	0.1	0.4	0.1	0.4	1.0	0.1	0.6
la	0.1	0.1	0.1	0.1	0.1	0.1	1.0	0.5
table	0.1	0.1	0.5	0.1	0.6	0.6	0.5	1.0

la complexité temporelle et spatiale : $O(N^2)$

Exemple :

- 1 000 tokens → 1M calcul
- 10 000 tokens → 100M calcul
- 100 000 tokens → 10 milliards de calcul

Le «GRAND» des grandes modèles de langage

Modèle	#paramêtres (milliards)	Taille du vocabulaire (# jetons)	#jetons de la base d'entraînement (milliards)	Fenêtre de contexte maximale (#jetons)	La date limite pour acquérir des connaissances
GPT-3	175	50,257	292	2048	
GPT-4	?	100,000	?	32,768	
GPT-5	?	?	?	400,000	
Mistral Large 2	123	32,768	?	128,000	
Llama 3	405	128,000	15,000	128,000	12/2023
Claude 2	130	?	?	100,000	
Claude 3	?	65,000	?	500,000	

Fusionner le contexte d'entrée et celui de sortie : cross-attention

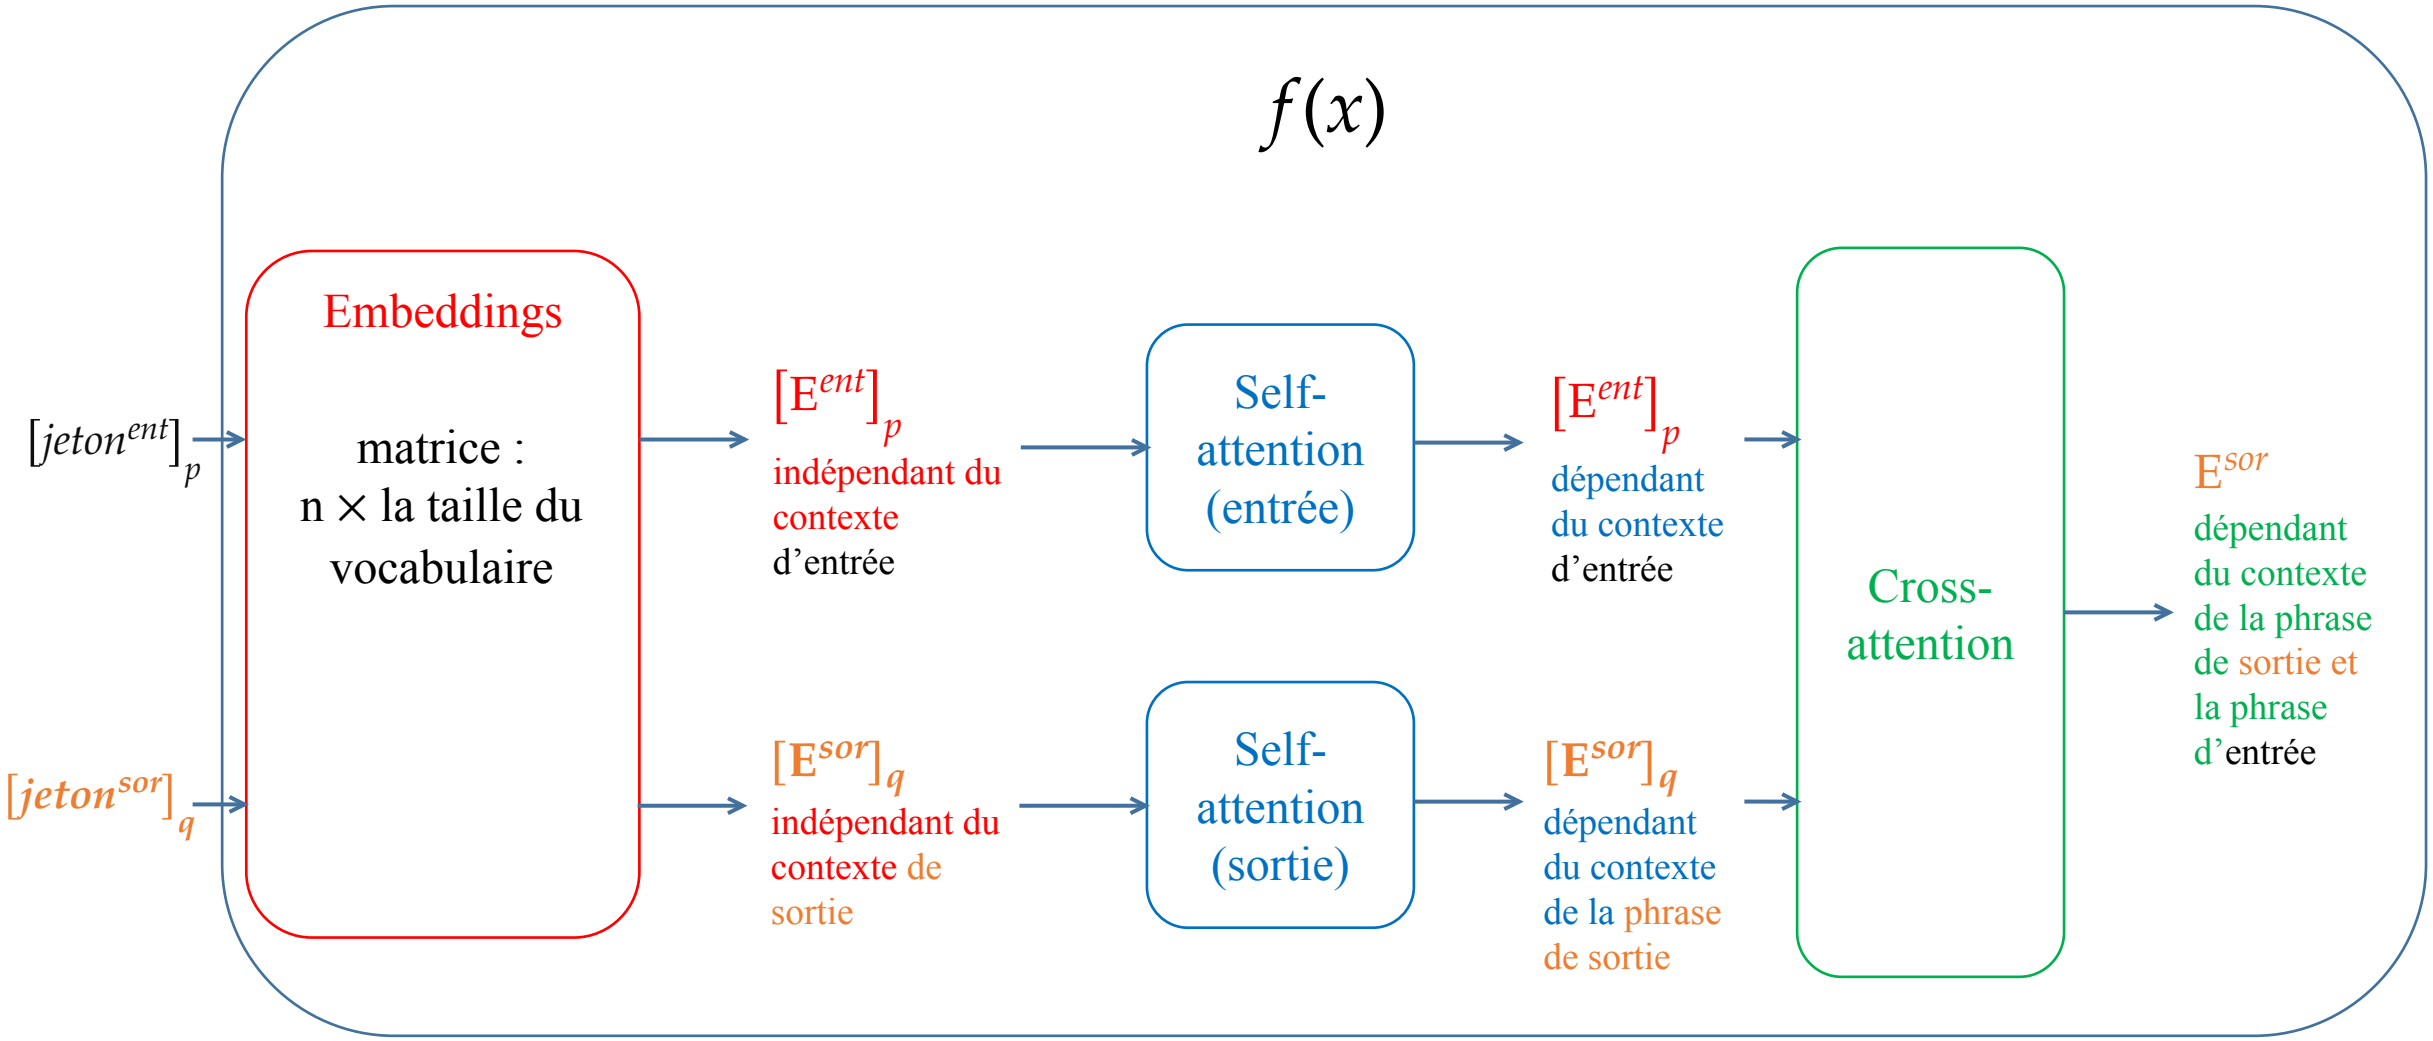

Prédire le mot suivant

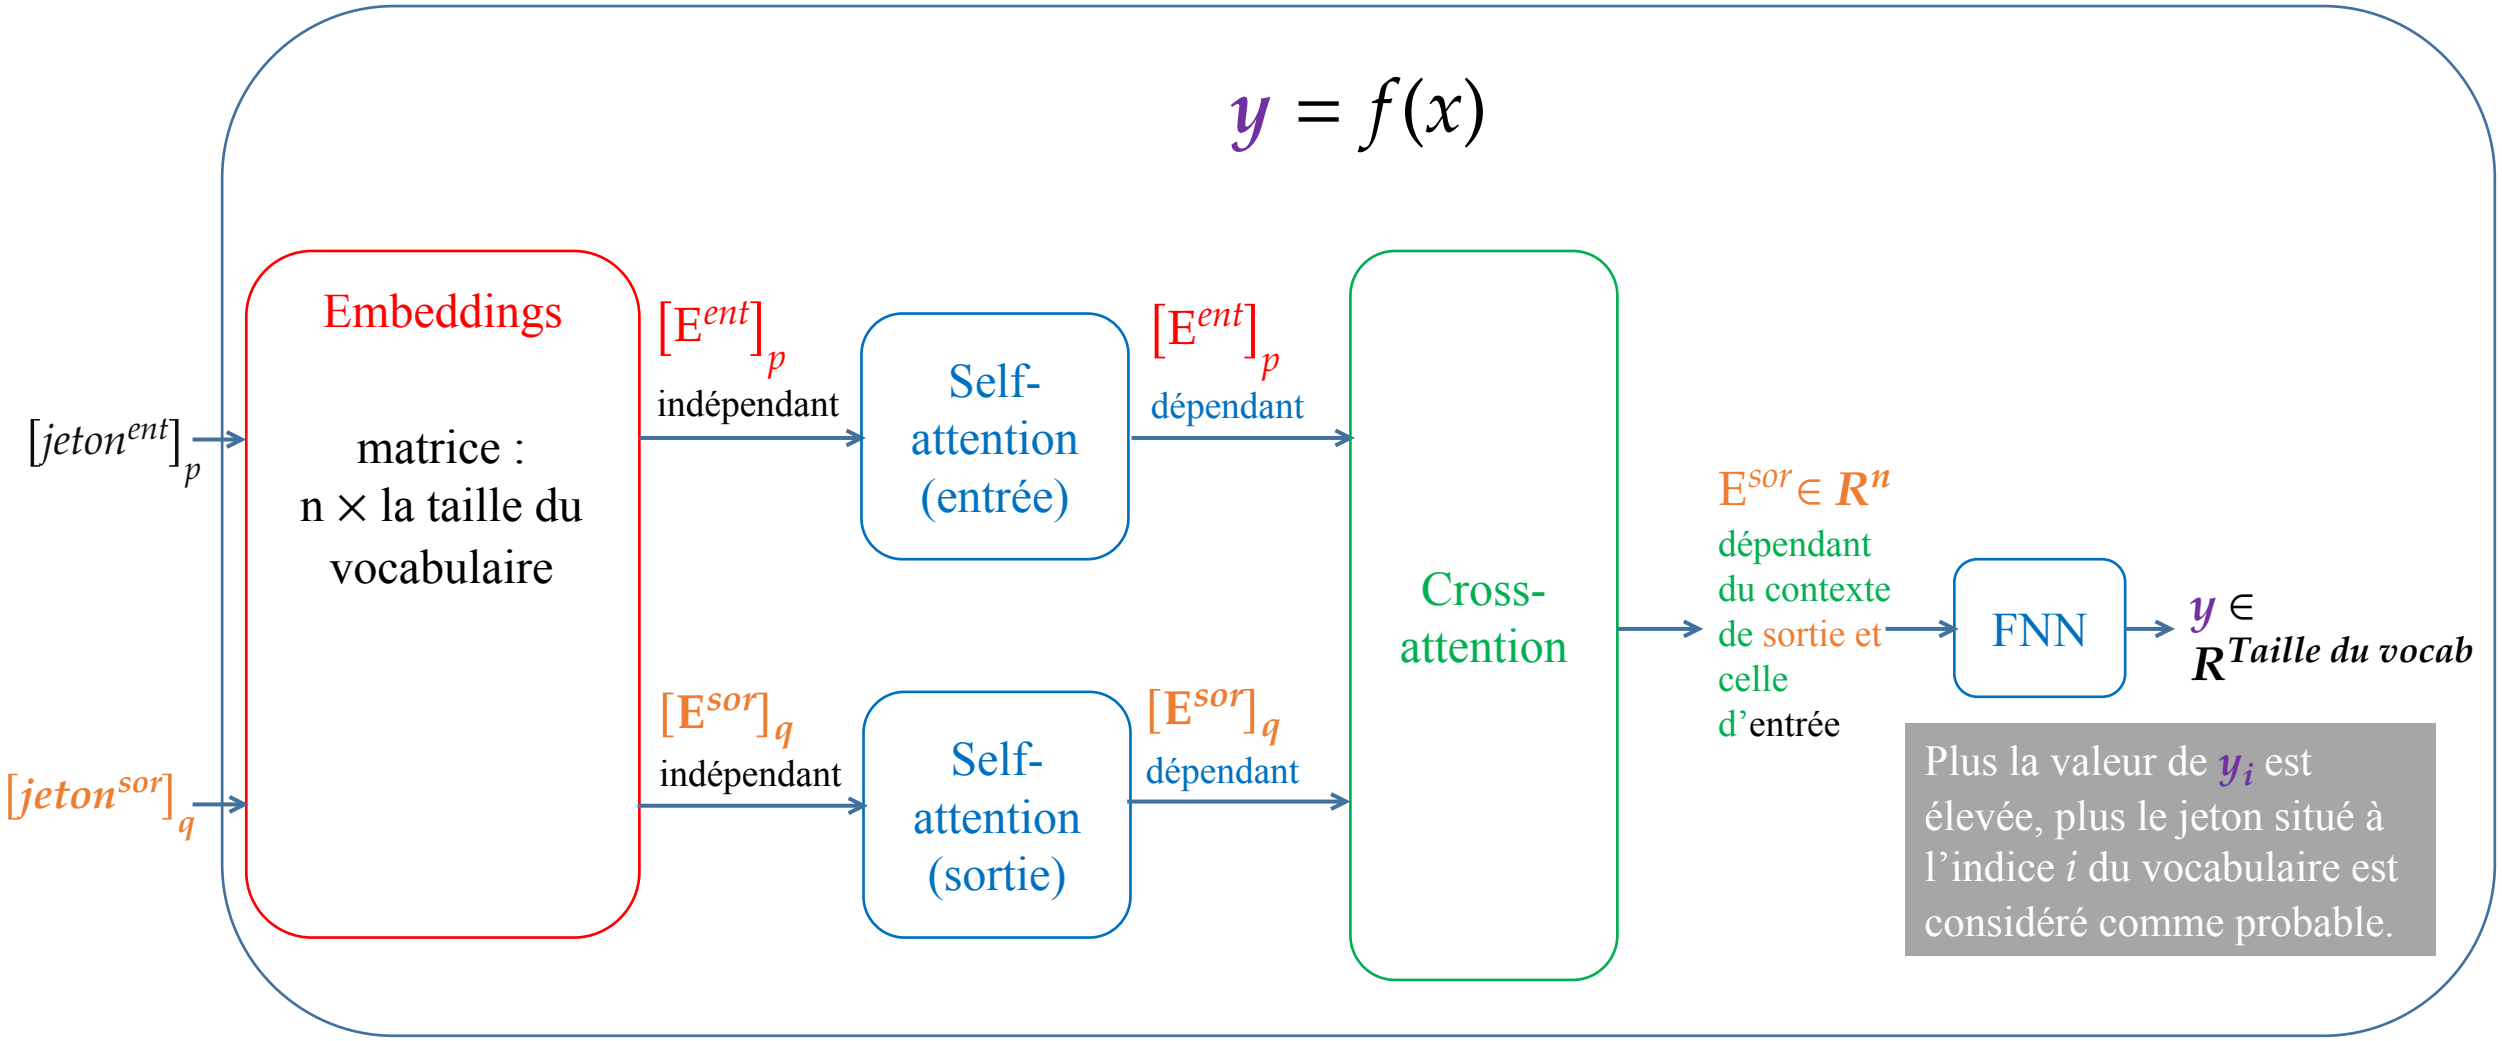

Prédire le mot suivant : du vecteur de valeurs réelles aux probabilités

Jetons d'entrée : [« sos », hello, world, « eos »]
Jetons de sortie : [« sos », hola]

$$y = \begin{bmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{taille\ du\ vocab} \end{bmatrix} \xrightarrow{\text{Softmax}} \begin{bmatrix} \exp\left(y_0/T\right) \Big/ \sum_i \exp\left(y_i/T\right) \\ \exp\left(y_1/T\right) \Big/ \sum_i \exp\left(y_i/T\right) \\ \exp\left(y_2/T\right) \Big/ \sum_i \exp\left(y_i/T\right) \\ \vdots \\ \exp\left(y_{taille\ du\ vocab}/T\right) \Big/ \sum_i \exp\left(y_i/T\right) \end{bmatrix}$$

$$-\infty < y_i < \infty$$

Plus la valeur de y_i est élevée, plus le jeton situé à l'indice i du vocabulaire est considéré comme probable.

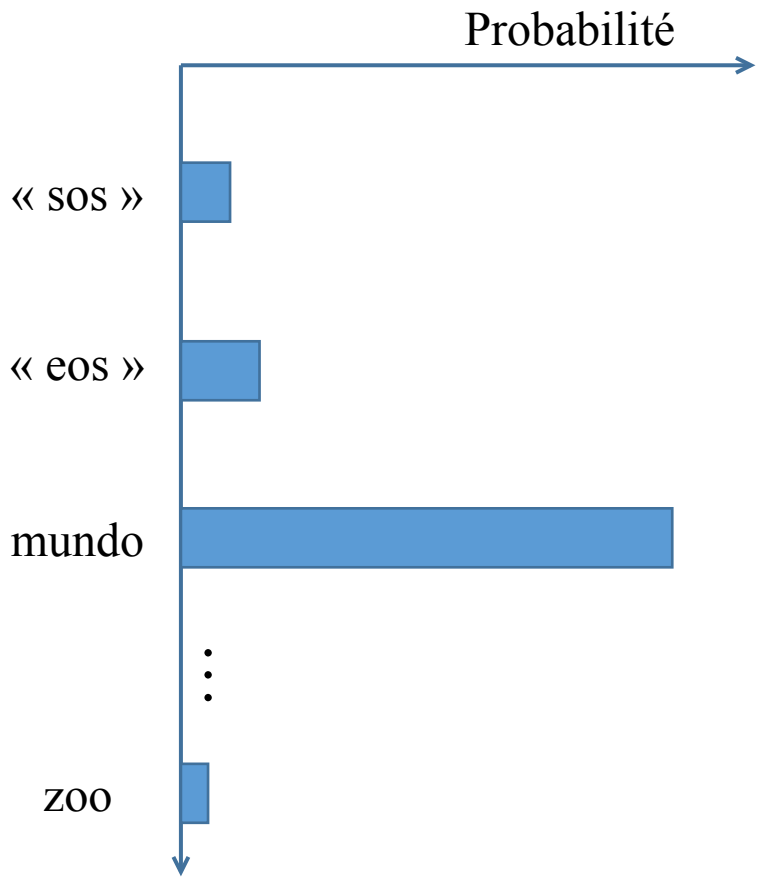

T est une constante appelée température

Composants essentiels des LLM

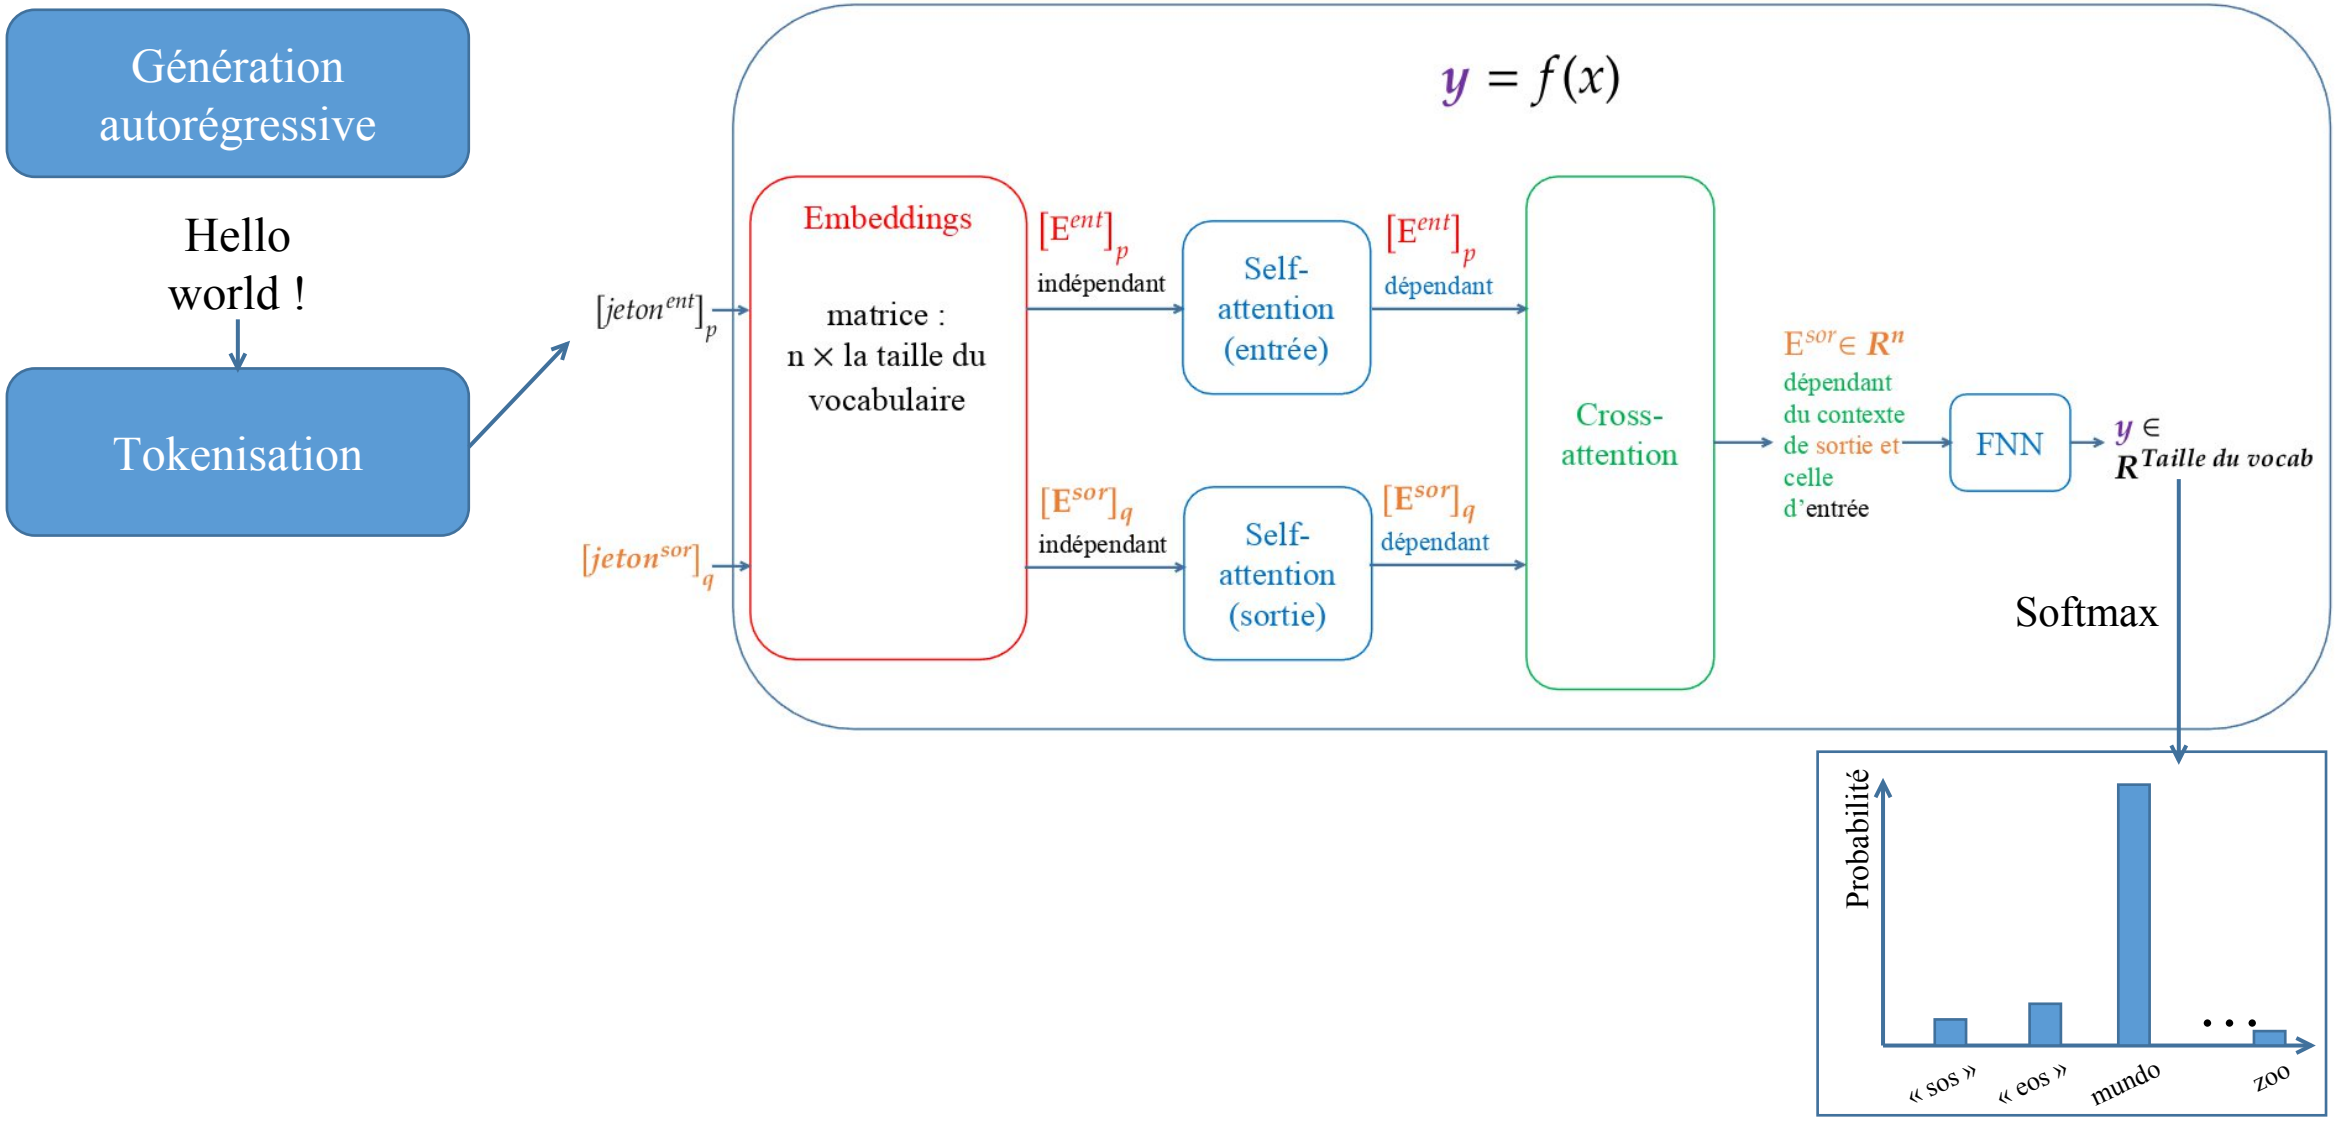

1.1.2 Choisir le mot suivant

Échantillonner la probabilité du mot suivant

L'échantillonnage glouton

$$\mathrm{i} = \mathrm{argmax}\{y_0 , y_1 , \cdots , y_{taille\ du\ vocab}\}$$

→ Choisissez le mot qui a la plus grande probabilité

1.2 Entraînement des LLM

Entraînement des LLM

Un LLM est une fonction qui transforme une chaîne de caractères en entrée en une distribution de probabilité du mot suivant.

Le chat s'assoit → Llama-8b →

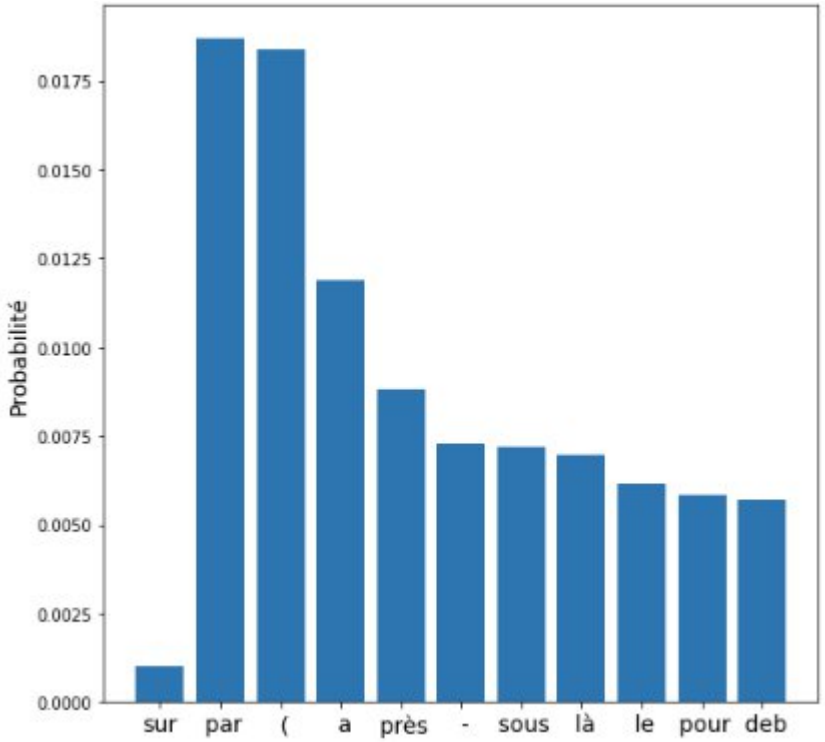

La distribution de probabilité du mot suivant prédite par Llama3-8b **lors de son initialisation** avant l'entraînement

Entraînement des LLM

Un LLM est une fonction qui transforme une chaîne de caractères en entrée en une distribution de probabilité du mot suivant.

Pour indiquer au modèle ce que signifie le mot suivant, nous devons lui montrer des exemples.

Le chat s'assoit → Llama-8b →

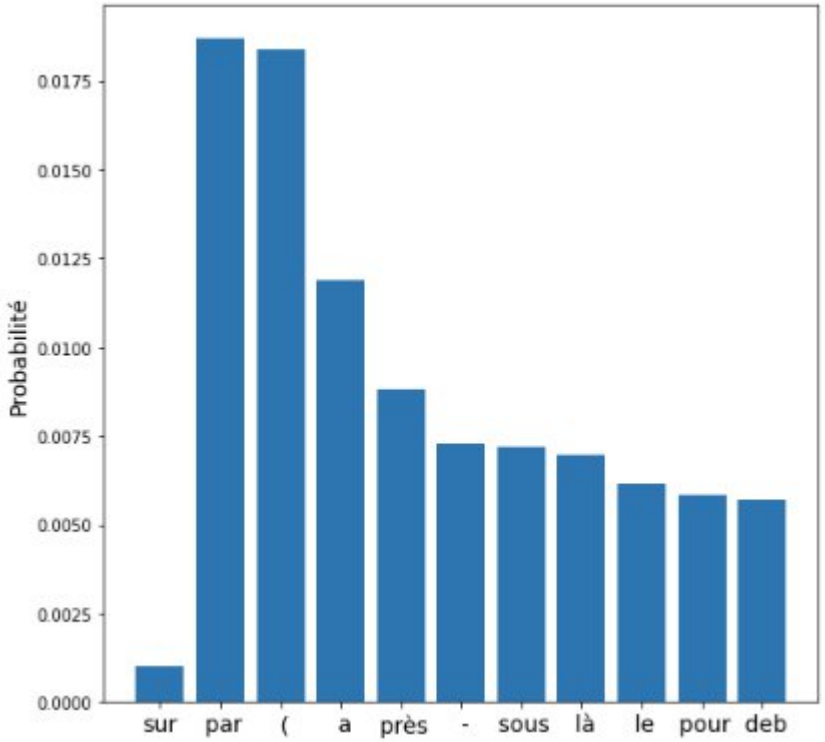

La distribution de probabilité du mot suivant prédite par Llama3-8b **lors de son initialisation** avant l'entraînement

Le mot suivant attendu :
sur

Entraînement des LLM

Entraînement := ajuster les poids du modèle afin de minimiser l'écart entre sa prédiction et le résultat souhaité.

La phrase d'entrée : Le chat s'assoit
Le mot suivant attendu : sur

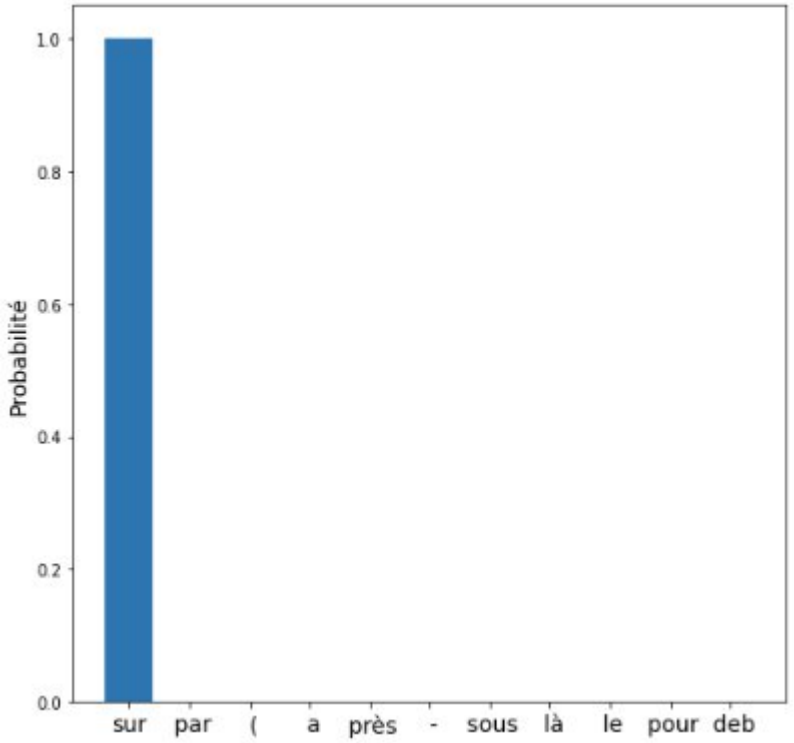

La distribution de probabilité **attendu**

ajuster les poids du modèle pour transformer en

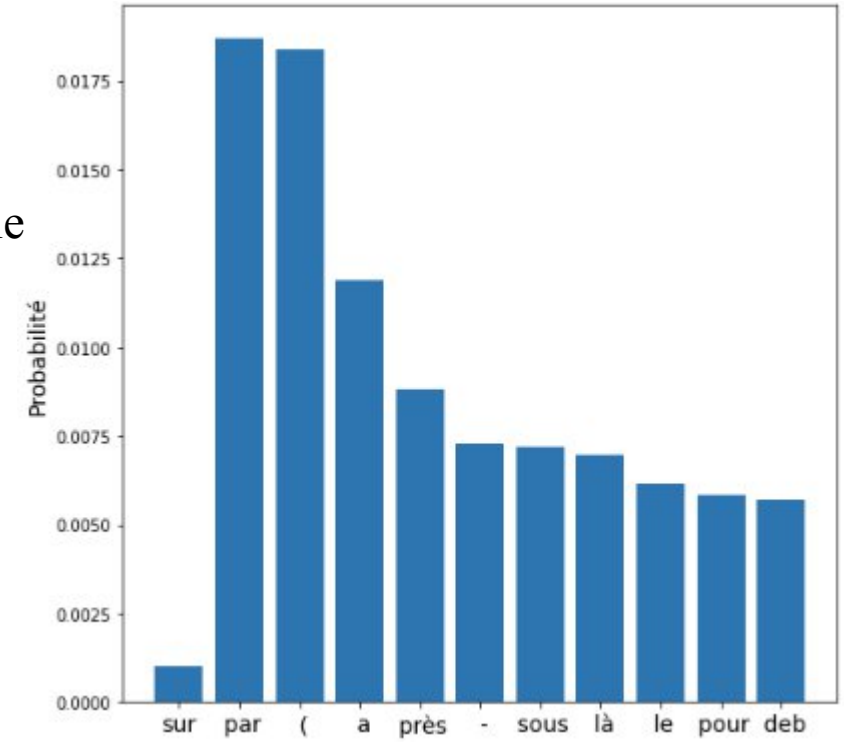

La distribution de probabilité du mot suivant **prédite** par Llama3-8b non entraîné

Entraînement des LLM

Entraînement := ajuster les poids du modèle afin de minimiser **l'écart** entre sa prédiction et le résultat souhaité.

La phrase d'entrée : Le chat s'assoit
Le mot suivant attendu : sur

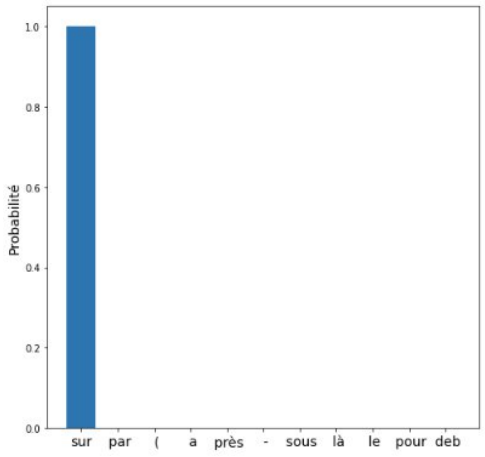

La distribution de probabilité **attendu** P_{att}

$$L = -\sum_{mot \in vocab} P_{att}(mot) \cdot log\left(P_{pre}(mot)\right)$$

$$L = -log\left(P_{pre}("sur")\right)$$

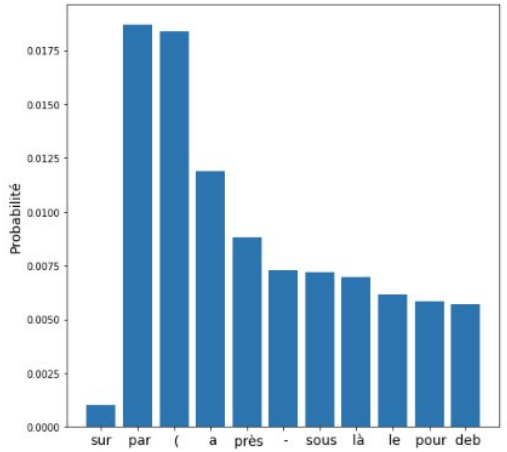

La distribution de probabilité du mot suivant **prédite** P_{pre} par Llama3-8b non entraîné

Entraînement des LLM

Entraînement := ajuster les poids du modèle θ afin de minimiser l'écart entre sa prédiction et le résultat souhaité.

La phrase d'entrée : Le chat s'assoit
Le mot suivant attendu : sur

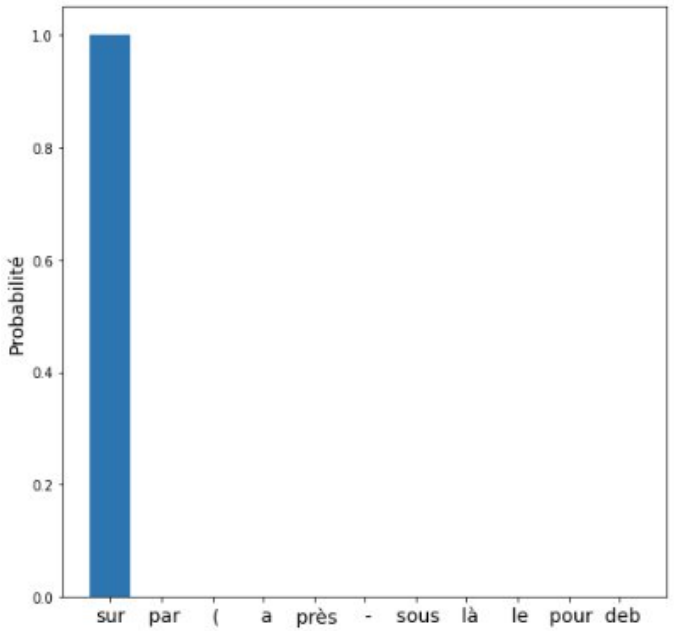

La distribution de probabilité **attendu**

$$L = -\log\left(P_{pre}(\text{"sur"})\right)$$

$$\theta = \theta - \gamma \nabla_{\theta} L$$

pour transformer en

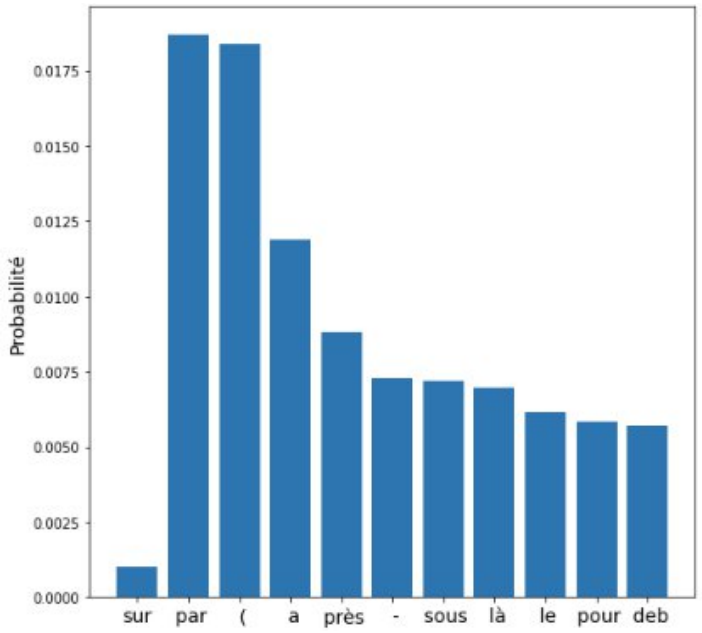

La distribution de probabilité du mot suivant **prédite** par Llama3-8b non entraîné

D’où proviennent les données d’entraînement ?

tout Internet

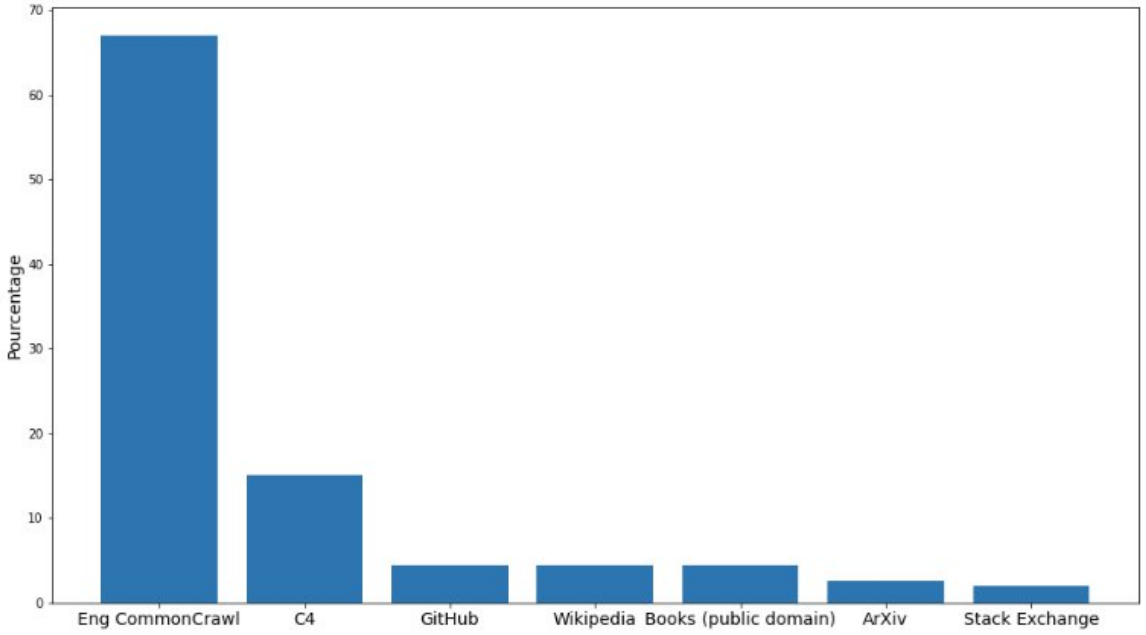

Distribution des données d'entraînement de Llama3

Common Crawl : Contient des données archivées provenant de toutes les données Internet depuis 2008

ArXiv : une platforme de partage de recherches. Ce site héberge désormais plus de deux millions d’articles scientifiques.

Stack Exchange : un réseau de sites web de questions-réponses (Q&R) portant sur des sujets dans des domaines variés (mathématiques, physique, chimie).

Le coût lié à l'entraînement des LLM

Modèle	Coût (millions d'heures GPU)	Type de GPU
Llama-3 8B	1.3	NVIDIA H100
Llama-3 70B	6.4	NVIDIA H100
GPT-3 175B	3.1	NVIDIA V100
DeepSeek-V3 671B	2.8	NVIDIA H800

une année compte 0,008766 heures

1900 tons CO2

Une voiture émet 4,9 tons de CO2 par an

Un centre de données d'une puissance de 1 mégawatt (MW) peut consommer jusqu'à 25,5 millions de litres d'eau par an rien que pour le refroidissement.

En moyenne, un Américain consomme 0,11 millions de litres d'eau litre par an

Source :
https://huggingface.co/meta-llama/Meta-Llama-3-8B
https://lambda.ai/blog/demystifying-gpt-3
https://arxiv.org/html/2412.19437v1
https://www.epa.gov/greenvehicles/greenhouse-gas-emissions-typical-passenger-vehicle#:~:text=typical%20passenger%20vehicle%3F-,A%20typical%20passenger%20vehicle%20emits%20about%204.6%20metric%20tons%20of,8%2C887%20grams%20of%20CO2.
https://www.weforum.org/stories/2024/11/circular-water-solutions-sustainable-data-centres/

Enjeux éthiques

1. Anthropic est poursuivi en justice pour avoir copié le contenu d'ouvrages non issus du domaine public. (https://www.reuters.com/sustainability/boards-policy-regulation/us-judge-approves-15-billion-anthropic-copyright-settlement-with-authors-2025-09-25/)

2. Le chatbot ChatGPT d'OpenAI a enfreint les lois allemandes sur le droit d'auteur en reproduisant des paroles de chansons du musicien Herbert Groenemeyer. (https://www.reuters.com/world/german-court-sides-with-plaintiff-copyright-case-against-openai-2025-11-11/)

3. Le juge de district américain William Orrick a statué que les sociétés Stability AI, Midjourney, DeviantArt et Runway AI violaient les droits des artistes. (https://www.theartnewspaper.com/2024/08/15/us-artists-score-victory-in-landmark-ai-copyright-case)

Comportements des LLM après l’entraînement

1. Complétion de texte
2. Mémoriser de textes de son base d'entraînement
3. Connaissances limitées