Théorème de Bayes

Soulignons que c'est un théorème très important à la fois en termes pratiques et par l'interprétation qu'on peut en faire. A ce stade, considérons que A et B sont juste des événements.

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)}$$

On peut déjà voir dans ce théorème la capacité à évaluer la probabilité de A sachant B, à partir de la probabilité de B sachant A. Souvent, A est une cause et B est un effet, dans le processus physique causal (ainsi, dans les exemples ci-dessous, le cause est la présence du voleur et l'effet est l'alarme qui sonne ; la cause est la maladie et l'effet est le test qui indique être positif, etc.). Néanmoins le lien entre A et B est probabiliste: la présence du voleur n'implique pas nécessairement l'alarme qui sonne, l'alarme qui sonne n'implique pas nécessairement la présence du voleur.

Le modèle physique de la situation va plutôt nous fournir $p(\text{alarme}|\text{voleur})$, mais c'est $p(\text{voleur}|\text{alarme})$ qui nous intéresse : le théorème de Bayes permet de passer de l'un à l'autre.

Souvent, le terme $p(B)$ n'est pas directement accessible mais est plus facilement calculable comme $p(B) = \sum_i p(B|A_i)p(A_i)$, c'est à dire la la somme des numérateurs de l'expression du théorème de Bayes, en balayant l'ensemble des valeurs possibles pour A.

On retrouvera le théorème de Bayes en statistiques, où il est très puissant pour construire des modèles probabilistes à partir de données.

Exercice 1

Soient deux événements : A "l'alarme sonne" et V "il y a un voleur". On suppose qu'on connait

- la sensibilité de l'alarme $p(A|V) = 0.8$
- la tendance à sonner à tort $p(A|\bar{V}) = 0.1$
- la probabilité qu'il y a un voleur $P(V) = 0.3$

Exprimer $p(V|A)$ en fonction de $p(A|V)$, $p(A)$ et $p(V)$. On appelle ce résultat le théorème de Bayes (appliqué à ce problème précis). En considérant que le voleur est ici la cause et l'alarme est l'effet, montrer que le théorème de Bayes permet de connaître la probabilité de la cause sachant l'effet, à partir de la probabilité de l'effet, sachant la cause. Préciser en pratique dans ce problème comment on peut calculer chacun des termes de l'expression.

Exercice 2

On dispose d'un test médical pour diagnostiquer si une personne testée a une maladie. Un malade a une probabilité 0.99 d'être positif au test. Un non malade a une probabilité 0.995 d'être négatif au test. La maladie touche en moyenne une personne sur un million. On teste une personne prise au hasard dans la population. Le résultat est positif. Que peut-il conclure ? Ce type de test est-il utile ?

Exercice 3

Trois usines installées de long d'une rivière sont incriminées dans une affaire de pollution. L'usine 1 fabrique des produits à base de chlore. Les usines 2 et 3 fabriquent des produits à base de chlore et à

base d'ammoniac, en proportions semblables, si bien que ces deux usines sont aussi susceptibles de fuir l'un ou l'autre des composés chimiques. On estime que les risque de pollution des usines 1 et 3 sont les mêmes car les usines ont le même âge. Par contre, le risque de pollution de l'usine 2 est deux fois plus faible car elle est plus récente. On suppose qu'une seule usine est cause de la pollution et qu'un seul type de pollution se produit.

Supposons qu'on est alerté d'une pollution, sans indication de la nature du polluant. Calculer, pour chacune des usines, la probabilité qu'elle soit à l'origine de la pollution. On appellera *probabilité a priori* ces valeurs.

Supposons maintenant que l'information précédente soit complétée : il y a du chlore dans la rivière, mais pas d'ammoniac. Réviser les probabilités pour prendre en compte cette nouvelle connaissance. Faire de même dans le cas où on observe de l'ammoniac mais pas de chlore. On appellera *probabilité a posteriori* ces valeurs. (ex. adapté de J. Blanchard/Polytech)

Indépendance

On dit que deux événements A et B sont indépendants si $p(A \cap B) = p(A)p(B)$.

Exercice 4

Montrer qu'en conséquence $p(A|B) = p(A)$, c'est à dire que la réalisation de l'événement A ne nous fait pas modifier notre connaissance sur B.

Loi de Bernoulli

On considère un sondage pour un référendum (les personnes interrogées répondent “oui” ou “non” pour indiquer qu’elles sont favorables ou non à une proposition). On considère qu’interroger ainsi une personne peut être modélisé par une variable aléatoire de Bernoulli:

- la probabilité d’une réponse “oui” est p ($p \in [0, 1]$)
- la probabilité d’une réponse “non” est 1-p.

Pour de nombreux besoins pratiques, on encode souvent une des réponses (par ex. “oui”) par 1 et l’autre par 0 et on parle de succès/échec à l’expérience aléatoire. On appelle aussi “tirage aléatoire de Bernoulli” ou “expérience de Bernoulli” cette expérience aléatoire. Bien que très simple, c’est une brique de base à partir de laquelle beaucoup d’autres modèles plus riches seront construits.

Exercice 5

Voici ci-dessous une manière de tirer une séquence de valeurs aléatoires d’une variable de Bernoulli. Programmer en python une autre manière de faire un tel tirage, mais qui utilise tirage aléatoire uniforme entre 0 et 1. Pour cette dernière fonction on pourra utiliser la fonction `random.uniform(0, 1)` du module python `random`.

```python
import random

# Set the probability of success (p)
p = 0.7  # Change this to your desired probability

# Number of samples
num_samples = 10


# Generate samples from a Bernoulli distribution
bernoulli_samples = [random.choices([0, 1], weights=[1 - p, p])[0]
                     for _ in range(num_samples)]

print("Bernoulli Samples:", bernoulli_samples)
```

Exercice 6

Reprenant votre solution à la question précédente, faire précéder votre tirage aléatoire de l’appel de fonction

```
random.seed(X)
```

où vous remplacerez X par un entier de votre choix. Vérifier que le tirage aléatoire est alors toujours le même à l’execution du programme. Dans quel contexte cette fonction `seed` pourrait-elle être utile ? Implicitement, quand l’appel `seed` n’est pas fait, l’horloge du système d’exploitation, qui tourne très rapidement, est affectée à X pour simuler l’aléatoire.

Espérance, variance

Sachant que de façon générale pour une variable aléatoire X discrète pouvant prendre les valeurs $x_1, x_2, ...x_n$ respectivement avec les probabilités $p(x_1), p(x_2), ..., p(x_n)$, l’espérance et la variance sont respectivement définies par :

$$E(X) = \sum_i x_i.p(x_i)$$

$$V(X) = E\Big((X - E(X))^2\Big)$$

Exercice 7

Calculer l'espérance d'une loi de Bernouilli de paramètre p.

Exercice 8

Interpréter (dans le cas général, pas spécifiquement pour la loi de Bernoulli) la définition de la formule de la variance ci-dessus.

L'espérance bénéficie des propriétés suivantes:
- la linéarité : E(aX+bY)=aE(X)+bE(Y) où $a \in \mathbb{R}$,$b \in \mathbb{R}$, X et Y sont deux variables aléatoires,
- E(a)=a, si a est une quantité non aléatoire

Exercice 9

En utilisant les propriétés ci-dessus, montrer que la variance peut également s'exprimer comme suit:

$$V(X) = E(X^2) - E(X)^2$$

Exercice 10

Montrer que la variance d'une loi de Bernoulli est $p(1-p)$ en utilisant celle de deux expressions qui vous parait la plus commode pour cela.

Exercice 11

Simulons une loi de Bernoulli en python : choisissez une valeur du paramètre p de la loi de Bernoulli, puis faites 100 tirages indépendants de cette distribution. Vérifier la concordance approximative entre :
- l'espérance de la distribution de probabilité et la moyenne (statistique) de votre échantillon
- la variance calculée sur la distribution de probabilité et la variance (statistique) de l'échantillon.

sachant que les deux statistiques moyenne et variance peuvent être calculées en python comme sur l'exemple suivant:

```
import numpy as np

# Example data sample
data = [2, 4, 5, 7, 9, 11, 13, 16, 18, 20]

# Compute mean and variance using numpy
mean_value = np.mean(data)
variance_value = np.var(data)
```

Séquence de lois de Bernoulli, premier scénario

Reprenant la question du référendum plus haut, on s'intéresse maintenant à la variable aléatoire "nombre de personnes successives à interroger jusqu'à obtenir un oui".

Exercice 12

Calculer de manière théorique la distribution de probabilité de cette variable, préciser son ou ses paramètres.

Exercice 13

Pour quelques valeurs de paramètres, tracer sa représentation graphique en python. Programmer maintenant une simulation par tirage aléatoire de ce processus et le superposer à la distribution théorique pour vérifier la cohérence.

Les deux codes ci-dessous donnent des exemples (à adapter) de tels tracés graphiques par des diagammes en barre :

- (barplot) dans le cas où les valeurs verticales sont déjà disponibles
- (histplot) dans le cas où les valeurs verticales doivent d'abord être calculées en tant que histogramme (découpage de l'axe horizontale en intervalles (communément nommés "bins") dont le nombre ou la largeur sont à convenir puis comptage du nombre de données dans chaque bins)

Le deuxième exemple illustre aussi la manière de faire se supposer deux histogrammes en permettant de voir ce qui se passe dans la zone de superposition. Notez aussi qu'à la place de la librairie de base

`matplotlib`

pour la visualisation, on utilise la librairie `seaborn` qui permet souvent des graphiques semblables avec une syntaxe plus simple.

Il vous reste néanmoins un peu de programmation à faire pour calculer les distributions théoriques et simulées avant de les afficher !

```
import seaborn as sns
import matplotlib.pyplot as plt

# Sample data
categories = ['Category A', 'Category B', 'Category C']
values = [25, 40, 30]

# Create a bar plot
sns.barplot(x=categories, y=values)

# Adding labels and title
plt.xlabel('Categories')
plt.ylabel('Values')
plt.title('Simple Bar Plot using Seaborn')

# Show the plot
plt.show()
```

```
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
```

```
# Generate example data
np.random.seed(42)
data1 = np.random.randn(1000)  # Sample data for histogram 1
data2 = np.random.randn(1000) + 2  # Sample data for histogram 2

# Create histograms using Seaborn
sns.histplot(data1, bins=30, kde=False, color='blue', label='Histogram 1',
alpha=0.3)
sns.histplot(data2, bins=30, kde=False, color='orange', label='Histogram 2',
alpha=0.3)

# Add labels and title
plt.xlabel('Value')
plt.ylabel('Frequency')
plt.title('Overlayed Histograms')

# Add legend
plt.legend()

# Show the plot
plt.show()
```

Exercice 14

Calculer l'espérance de cette distribution et vérifier que ce résultat est cohérent avec le comportement qualitatif observé graphiquement de la distribution en fonction de son paramètre.

la variable aléatoire étudiée ci-dessus suit une loi dite ' géométrique'

Séquence de lois de Bernoulli, deuxième scénario

Encore sur le scénario du référendum, programmer une fonction python qui interroge 100 personnes et compte le nombre de “oui” obtenus.

Expérience pratique

Exercice 15

En programmant une boucle, lancer n fois cette l’expérience pour produire un échantillon de taille suffisante pour suggérer visuellement, en traçant un histogramme, l’allure générale de la répartition du nombre de oui qu’on peut espérer parmi 100 personnes interrogées. Tracer ces histogrammes pour des valeurs de p égales à 0.5, 0.2, 0.9.

Distribution théorique

Exercice 16

Si on interroge 3 personnes pour le référendum et que chacune a une probabilité p de répondre “oui”, quelle est la probabilité théorique d’avoir exactement 2 fois “oui” parmi les 3 personnes interrogées? Si on interroge n personnes, quelle est la probabilité d’avoir k fois “oui” ? Tracer en python la distribution correspondante dans le cas $n = 100$ et la superposer à l’histogramme de la question précédente. Y a t-il bien une coincidence approximative ?

Exercice 17

Calculer l’espérance et variance de la loi “nombre de oui pour n=100 personnes interrogées”, par l’expression théorique. On pourra utiliser les résultats que vous avez trouvés pour la loi de Bernoulli et la propriété suivante sur la somme des variances de deux variables aléatoires X et Y supposées indépendantes (dont des éléments de démonstration figurent en annexe) :
$V(X + Y) = V(X) + V(Y)$

Exercice 18

Confirmer la cohérence de ces résultats relativement aux moyennes et variances statistiques.

Exercice 19

Le code ci-dessous utilise la fonction `binom.cdf` (cumulative distribution fonction, fonction de répartition en français) pour tracer la fonction indiquant la probabilité d’une valeur *inférieure ou égale* à la valeur passée en paramètre. Logiquement, cette fonction cumulative est croissante et prend ses valeurs de 0 à 1. En supposant que l’opinion de la population est partagée à 50%-50% entre “oui” et “non”, en utilisant la fonction `cdf`, calculer la probabilité que sur 100 personnes interrogées d’un échantillon représentatif de la population, le nombre de personnes interrogées qui répondent “oui” doit dans l’intervalle $[45, 55]$.

```
import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import binom
```

```
# Set the parameters of the binomial distribution
n = 100  # Number of trials
p = 0.5  # Probability of success

# Generate values for x (number of successes)
x = np.arange(0, n+1)

# Calculate the cumulative probability using the binom.cdf function
cdf = binom.cdf(x, n, p)

# Plot the cumulative probability distribution
plt.step(x, cdf, where='mid', label='Binomial CDF')
plt.title('Cumulative Probability Distribution of Binomial (n={}, p={})'.format(n,
p))
plt.xlabel('Number of Successes')
plt.ylabel('Cumulative Probability')
plt.legend()
plt.show()
```

Annexe :
Montrons que V(X+Y)=V(X)+V(Y):

$$V(X) = E(X^2) - E(X)^2$$

et

$$V(Y) = E(X^2) - E(X)^2)$$

$$V(X+Y) = E\left((X+Y)^2\right) - E(X+Y)^2$$

En utilisant la linéarité de l'espérance dans chacun des deux termes :

$$V(X+Y) = E(X^2) + 2E(XY) + E(Y^2) - E(X)^2) - E(Y)^2 - 2E(X)E(Y)$$

or, si X et Y sont indépendantes, alors $E(XY) = E(X)E(Y)$.

$$V(X+Y) = E(X^2) + E(Y^2) - E(X)^2 - E(Y)^2$$

$$V(X+Y) = V(X) + V(Y)$$

Ce résultat sera rencontré lors de l'étude des données multivariées, car $E(XY) - E(X)E(Y)$ est une quantité très souvent rencontrée, qui s'appelle la covariance entre X et Y.

la variable aléatoire étudiée ci-dessus suit une loi dite 'binômiale'

Somme de variables aléatoires continues

Dans la feuille précédente, on a vu que la somme de lois de Bernoulli indépendante donne une loi binomiale, dont la distribution de probabilité a cette forme particulière en forme de cloche discrète. On va maintenant étudier la même chose avec des lois continues (plutôt que discrètes)

Exercice 20

A partir d'un tirage selon une loi uniforme entre 0 et 1, fabriquer une fonction python qui réalise un tirage aléatoire uniforme entre -1 et 1 (facile !)

Exercice 21

On s'intéresse à la distribution de X1+X2, où X1 et X2 sont deux variables aléatoires indépendantes suivant chacune une loi uniforme entre -1 et 1. On souhaite étudier la distribution de cette somme. Pour cela, tirer aléatoirement un grand nombre de valeurs de cette somme. Les valeurs tirées sont-elles a priori toutes distinctes les unes des autres ? Si oui, pas facile de visualiser de quelle distribution de probabilité elles paraissent tirées. Pour contourner cette petite difficulté technique, vous pouvez utiliser un histogramme (à vous de régler le nombre de bins et donc leur largeur)

1. Répéter l'expérience pour 3 termes au lieu de 2 dans la somme
2. Répéter l'expérience pour un nombre n beaucoup plus élevé de termes dans la somme.

Variable aléatoire

Maintenant qu'on en a manipulé et utilisé l'expression, il est temps de revenir sur ce qu'est une variable aléatoire, à savoir un objet mathématique utilisé en probabilités et statistiques pour modéliser et quantifier l'incertain et la variabilité des issues possibles d'expériences.

Une variable aléatoire est une fonction dont l'ensemble de départ sont les issues de l'expérience et qui leur associe une distribution de probabilité.

On distinguera deux types de variables aléatoires : discrètes et continues :

- Les variables discrètes prennent leurs valeurs dans un ensemble dénombrable, fini (par ex. $\{1, 2, 3, 4, 5\}$) ou infini (par ex. $\mathbb{N}^+$). La distribution de probabilité prend alors la forme d'une fonction de masse, qui donne la probabilité de chaque issue de l'expérience aléatoire.
- Une variable aléatoire continue prend ses valeurs dans un ensemble indénombrable, par ex. $\mathbb{R}$, un intervalle ou un ensemble d'intervalles de $\mathbb{R}$. C'était par exemple le cas pour la distribution uniforme sur $[0, 1]$ rencontrée plus haut. Dans les cas des variables aléatoires continues, la distribution de probabilité est décrite par la fonction de densité de probabilité (souvent simplement appelée "densité de probabilité") sur l'intervalle ou l'union d'intervalles. Ce sont alors des intégrales sur des domaines qui ont des valeurs de probabilités (et non leurs valeurs en des points).

On appelle processus aléatoire une version plus riche de ce type d'objet mathématique, en ce qu'elle va aussi modéliser l'évolution temporelle et/ou spatial d'un phénomène aléatoire (par exemple les conditions météorologique, le traffic routier,...).

Loi normale

Une variable aléatoire X qui suit une loi normale, dite aussi loi gaussienne, est caractérisée par la distribution de probabilité suivante, où μ et σ sont deux paramètres :

$$p(X = x|\ \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{(x-\mu)^2}{-2\sigma^2}}$$

Exercice 22

Tracer des lois normales par exemple en utilisant le code ci-dessous (qui en superpose deux), pour explorer leur allure en fonction de la valeur des paramètres μ et σ. Il se trouve que l'espérance de X vaut μ et la variance de X vaut σ^2. L'allure générale de la distribution est due à la forme de type e^{-x^2}.

```
from scipy.stats import norm
import numpy as np
import matplotlib.pyplot as plt

# Parameters for the Gaussian distribution
mu = 0 # Mean
sigma = 1 # Standard deviation

# Generate data points
x = np.linspace(mu - 8 * sigma, mu + 8 * sigma, 1000)
y = norm.pdf(x, mu, sigma)

 # Plot the Gaussian distribution
plt.plot(x, y, label=f'N({mu}, {sigma**2})')

# Parameters for the Gaussian distribution
mu = 1 # Mean
sigma = 2 # Standard deviation

# Generate data points
y = norm.pdf(x, mu, sigma)

 # Plot the Gaussian distribution
plt.plot(x, y, label=f'N({mu}, {sigma**2})')

plt.title('Gaussian Distribution')
plt.xlabel('X-axis')
plt.ylabel('Probability Density Function (PDF)')
plt.legend()
plt.grid(True)
plt.show()
```

Exercice 23

Superposer une loi normale à l'histogramme tracé à la question (deux exercices plus haut), pour observer la qualité de l'approximation. Pour cela, vous aurez besoin de calculer (calcul théorique) l'espérance et la variance de la somme de n variables correspondant à la loi uniforme entre - 1 et 1. La solution est aussi sur wikipedia :)

Exercice 24

Conclure (au moins selon l'allure des graphiques) que la somme d'un grand nombre de variables aléatoires uniformes tend vers une loi normale. Si vous aviez le temps, vous pourriez tenter de faire une expérience similaire avec la somme d'autres types de lois élémentaires (somme de lois normales,

somme de lois beta,...) et vous constateriez que quelle que soit le cas, la somme d'un grand nombre de ces lois tend vers une loi normale. Cette propriété très importante en probabilités correspond à ce qu'on appelle le Théorème Central Limite.

Application à la fluctuation des moyennes d'échantillons

Considérons la distribution continue de probabilité uniforme entre 0 et 1.

Exercice 25

Programmer en python : Répéter m fois l'expérience "Tirer n valeurs d'une telle loi uniforme entre 0 et 1, puis calculer la moyenne de ces n valeurs".

Exercice 26

On s'intéresse aux caractéristiques de la répartition des m moyennes ainsi obtenues. Pour par exemple m=100 et n=100, visualiser un histogramme de ces moyennes (on s'attend à ce qu'elles fluctuent autour de 1/2), puis calculer (en python, en utilisant les librairies) leur moyenne et leur variance.

Exercice 27

Faire l'expérience ci-dessus pour diverses valeurs de n, pour observer comment évolue l'écart-type (statistique) de l'échantillon de moyennes en fonction de n. Est-ce conforme à votre intuition ? Quand vous multipliez n par 4, par quel facteur l'écart-type semble t-il multiplié ?

Ce qui s'est passé :
Il y a un lien étroit entre cette expérience sur les moyennes de variables aléatoire et l'expérience précédente sur les sommes :

Appelons X_1,...X_n les variables indépendantes d'espérance μ et de variance σ^2 dont on fait la somme

$$S_n = X_1 + ... + X_n$$

La moyenne M_n de ces variables aléatoires, qui est elle-même une variable aléatoire, se calcule simplement comme

$$M_n = \frac{X_1 + ... + X_n}{n}$$

Or l'espérance et la variance de la somme S_n s'expriment comme suit :

$$E(S_n) = n\mu$$

$$V(S_n) = n\sigma^2$$

d'où par linéarité de l'espérance

$$E(M_n) = \mu$$

et, en utilisant la propriété $V(aX) = a^2V(X)$ où X est une variable aléatoire et a un réel,

$$V(M_n) = \frac{\sigma^2}{n}$$

d'où l'écart-type de l'échantillon de moyennes :

$$\sqrt{V(M_n)} = \frac{\sigma}{\sqrt{n}}$$

où on constate que l'écart-type des moyennes d'échantillon se réduit "lentement" par rapport à la taille de l'échantillon, à cause de la racine carrée.

Processus de Poisson

On va à nouveau s'intéresser à un processus aléatoire de type "combien de fois un événement se produit". On en a déjà rencontré avec le cadre de la loi de Bernoulli : le résultat était 0 ou 1, puis pour la loi binômiale : le résultat était entre 0 et n (succession de n expériences de Bernoulli). Il s'agit maintenant de regarder un cas applicable au cas des événements sur un temps continu plutôt que discret : les événements peuvent se produire à n'importe quel instant sur un axe continu et le nombre d'événements prend maintenant sa valeur dans $\{0, 1, ..., \infty\}$. Par exemple, on s'intéresse au nombre de voyageurs arrivant sur le quai d'une gare depuis la ville, pendant un intervalle dans une tranche de dix minutes.

Pour la construction mathématique d'un tel phénomène aléatoire, considérons l'expérience binômiale comme un intervalle de temps découpé en n micro-intervalles, chacun étant l'objet d'une expérience de Bernoulli. Chaque micro-intervalle est susceptible de produire (avec une probabilité p) ou non l'événement. Supposons qu'on souhaite un processus aléatoire produisant en moyenne λ événements par intervalle de temps. λ, qui n'est pas nécessairement entier, est assimilable à l'espérance d'une loi binômiale où on fait évoluer $n \to \infty$ tout en imposant une espérance $\lambda = np$ fixée et finie, ce qui implique $p \to 0$. Par exemple, on considère un processus apportant des voyageurs sur le quai de la gare depuis la ville dans une tranche de dix minutes, le nombre de voyageurs est aléatoire mais est tel qu'il y a en moyenne (espérance) 20 voyageurs.

Exercice 28

Simulons cela avec le code ci-dessous, où vous pouvez régler sucessivement `simulation_time_step` à n=10,100,1000 pour découper l'intervalle de plus en plus finement sans changer le nombre moyen de réalisations de l'expérience pendant l'intervalle, puisque la probabilité p de réalisation dans chaque micro-intervalle décroît en proportion. L'expérience ci-dessus compte le nombre d'événements réalisés pendant l'intervalle de temps. Sur quelques exemples d'executions, vous devriez constater qu'en moyenne, le nombre d'événements semble en moyenne conforme à la valeur de λ que vous avez choisie.

```python
import numpy as np

def simulate_poisson_process(_lambda, time_steps):
    # _lambda: nombre moyen d'événement par unité de temps
    # time_steps: nombre de micro-intervalles dans la simulation
    # Calculate the probability of an event occurring in each time step
    p = _lambda / time_steps

    # Simulate the Poisson process using Bernoulli trials
    bernoulli_trials = np.random.rand(time_steps) < p
    # Count the number of successes (events)
    poisson_process_count = np.sum(bernoulli_trials)

    return poisson_process_count

# Example usage
mon_lambda = 2.5  # Adjust this value based on your specific scenario
simulation_time_steps = 100

simulated_count = simulate_poisson_process(mon_lambda,
simulation_time_steps)

print(f"Simulated number of events: {simulated_count}")
```

Exercice 29

Collecter maintenant les nombres d'événements produits sur 1000 simulations et tracer l'histogramme du résultat. Ce cas de la loi binômiale pris comme nombre d'événements très peu probables pendant un nombre élevé de micro-intervalles, c'est à dire un passage au temps continu, s'appelle loi de Poisson, et s'exprime comme suit, où k désigne le nombre d'événements :

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

C'est une version simplifiée de l'expression binomiale, pour les conditions aux limites ci-dessus. Pour savoir comment aboutir à cette expression depuis celle de la loi binômiale, vous pouvez regarder le détail de la démonstration ici (lien cliquable) https://www.youtube.com/watch?v=ceOwlHnVCqo

Une caractéristique essentielle de cette distribution est que, contrairement à la loi binomiale qui possède deux paramètres n et p, elle ne possède qu'un seul paramètre λ.

Exercice 30

Tracer la distribution théorique de X, par exemple avec le code ci-dessous, de manière superposée à votre simulation précédente, pour diverses valeurs de λ, pour vérifier que la loi théorique de Poisson semble un bon modèle de votre distribution statistique. Vérifier que cette distribution se conforme aux exemples ci-dessous.

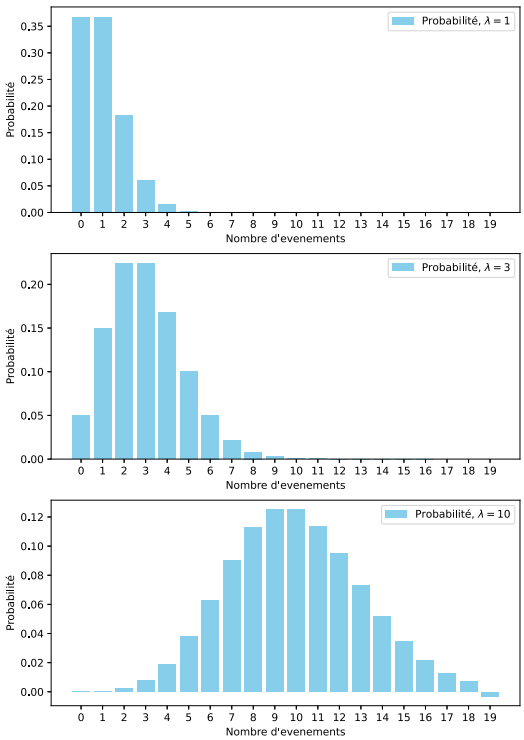

Figure 1: Des exemples de lois de Poisson pour diverses valeurs du paramètre λ.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import poisson

# Set the mean parameter for the Poisson distribution
lambda_parameter = 2.5

# Generate values from the Poisson distribution
x = np.arange(0, 11)  # Adjust the range based on your requirements
poisson_pmf = poisson.pmf(x, lambda_parameter)

# Plot the probability mass function (PMF) of the Poisson distribution
plt.bar(x, poisson_pmf, align='center', color='blue', alpha=0.7)
plt.xlabel('Number of Events')
plt.ylabel('Probability')
plt.title(f'Poisson Distribution (λ={lambda_parameter})')
plt.show()
```

Distribution de probabilité de la durée entre événements successifs

Dans le cas d'un processus de Poisson, la durée qui s'écoule entre deux événements successifs est aussi une variable aléatoire dont il est intéressant de connaître la distribution.

Cette question doit rappeler le scénario qui a mené à la loi géométrique dans le cas discret, avec ici le besoin de l'adapter au cas à temps continu. Dans le cas de la loi géométrique, nous interrogions des personnes sur un référendum. En supposant la réserve de personnes à interroger très grande, la probabilité d'une réponse "oui" était constante entre personnes successives. En conséquence, la probabilité d'une personne réponde "oui" ne dépend pas du nombre de personnes interrogée depuis le dernier "oui". C'est ce qu'on appelle un processus "sans mémoire". La même propriété, mais à

temps continu, caractérise le processus de Poisson : la probabilité qu'un événement se produise ne dépend pas du temps écoulé depuis l'événement précédent.

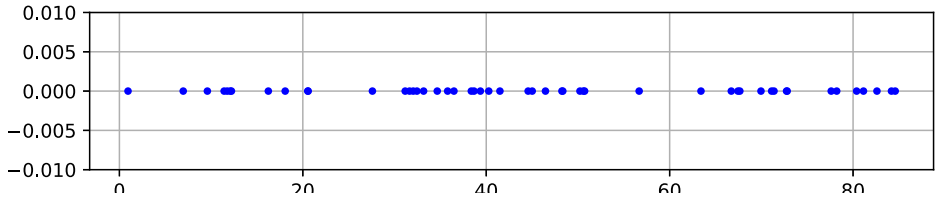

Figure 2: Arrivée d'événements espacés par des durées qui suivent une distribution exponentielle, ici $\lambda = 2$.

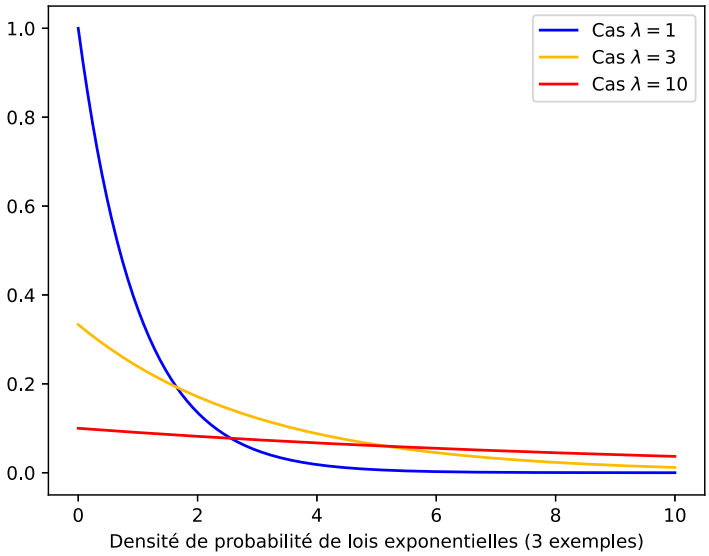

Figure 3: Exemples de densités de probabilité exponentielles.

On peut montrer que pour un processus de Poisson de paramètre λ, la durée entre événements successifs suit une distribution de probabilité exponentielle:

$$f(t) = \lambda e^{-\lambda t}$$

,

La loi exponentielle permet, sur un temps continu, de modéliser un processus aléatoire générateur d'événements tels qu'on contrôle l'espacement moyen entre les événements.

Exercice 31

Ajoute à la simulation précédente du processus de Poisson la collecte des différences de temps observées entre événements successifs et en tracer l'histogramme (pour avoir des histogrammes suffisamment peuplés, cumuler la collecte sur plusieurs simulations).

Calculer (à la main) son espérance (ça servira très bientôt !)

Soit X une variable aléatoire qui désigne la probabilité de la durée t entre l'instant actuel et le prochain événement. suit une distribution exponentielle. Montrons que la propriété suivante est vraie:

$$p(X > s + t | X > s) = p(X > t)$$

où t est l'instant actuel On part de :

$$p(X > s + t) = \int_{s+t}^{\infty} f(u)\,\mathrm{d}u = \int_{s+t}^{\infty} \lambda e^{-\lambda u}\,\mathrm{d}u = e^{-\lambda(s+t)}$$

$$p(X > s + t \mid X > s) = \frac{p(X > s + t)}{p(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = p(X > t)$$

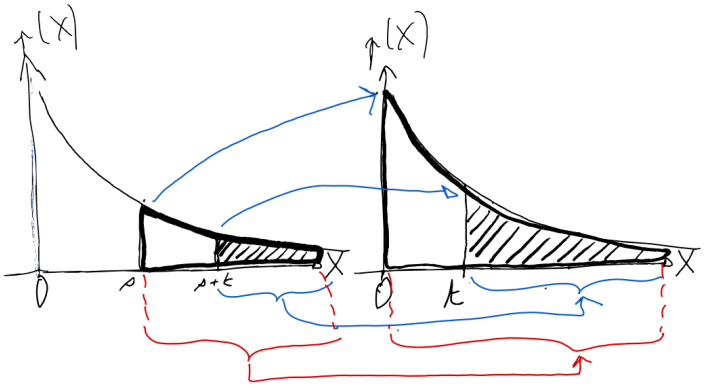

Figure 4: A gauche : sachant qu'il s'est déjà passé s secondes depuis l'événement précédent (qui correspond à 0 sur l'axe des abscisses), la zone hachurée représente la probabilité $p(X > s + t|X > s)$ que l'événement suivant se produise dans plus de t secondes, c'est à dire après plus de $s + t$ secondes depuis l'événement précédent. A droite : La propriété $p(X > s + t|X > s) = p(X > t)$ est illustrée par l'équivalence entre les deux zones hachurées et entre les deux zones encadrées en gras : à l'instant courant, la probabilité d'attendre plus que t secondes d'ici le prochain événement est indépendant du temps écoulé depuis l'événement précédent.

Exercice 32

Supposons qu'on attend à un arrêt de bus où les bus arrivent selon un processus de Poisson de paramètre λ. Supposons qu'un bus passe en moyenne tous les 10 minutes.

- Pourquoi n'est-ce pas très réaliste pour un service de bus bien coordonné, mais réaliste pour un service non coordonné ?
- Calculer avec la loi de Poisson la probabilité qu'aucun bus n'arrive dans la prochaine minute.
- Retrouver le résultat en calculant, avec la loi exponentielle, la probabilité d'attendre plus d'une seconde.

Exemples :

- occurence de maladies rares
- fréquence des arrivées aux urgences (dimensionnement)

loi normale : qualifier d'anormal un résultat de l'analyse de labo (hors des 95% des gens normaux)